ANALYSE DU STOCK ET DES VENTES DU SITE BOTTLENECK

Index

- Etape 1 - Importation des librairies et chargement des fichiers
  - 1.1 - Importation des librairies
  - 1.2 - Chargements des fichiers
- Etape 2 - Analyse exploratoire/Traitement des fichiers
  - 2.1 - Analyse exploratoire du fichier erp.xlsx
    - 2.1.1 - Modification colonnes 'product_id' et 'onsale_web' en type "Object"
    - 2.1.2 - Vérifications des valeurs négatives colonnes 'price' et 'stock_quantity'
    - 2.1.3 - Traitement de la colonnes 'stock_status' en fonction de la colonne stock_quantity
    - 2.1.4 - Traitement de la colonne 'onsale_web' et création d'une variable 'ProduitsAMettreEnLigne'
    - 2.1.5 - Vérification si prix de ventes > prix d'achats et création d'une variable 'PrixAchatAVerifier'
  - 2.2 - Analyse exploratoire du fichier liaison.xlsx
  - 2.3 - Analyse exploratoire du fichier web.xlsx
    - 2.3.1 - Codes articles manquants
    - 2.3.2 - Remplacement des articles manquants pars le product_id (4 derniers caractères du lien https)
    - 2.3.3 - Remplacement des sku table df_liaison
    - 2.3.4 - Liste des codes articles ne respectant pas la régle de codification
    - 2.3.5 - Création du df_web_produit fonction de post_type
    - 2.3.6 - Vérifications des valeurs négatives colonne 'total_sales'
    - 2.3.7 - Renommer la colonne 'sku' en 'id_web'
    - 2.3.8 - Suppression du code promo
- Etape 3 - Jonction des fichiers
  - 3.1 - Réalisation de la jointure entre df_erp et df_liaison
  - 3.2 - Réalisation de la jointure entre df_merge et df_web
  - 3.3 - Vérification des différences entre df_merge et df_web
- Etape 4 - Analyse univarié
  - 4.1 - Analyse de la variable 'price'
    - 4.1.1 Exploration graphique 'price'
    - 4.1.2 Exploration Statistique 'price'
    - 4.1.3 Identification avec le z-score 'price'
    - 4.1.4 Identification par l'interval interquartile 'price'
- Etape 5 - Calcul et analyse du CA et de la marge. Analyses complémentaire des quantités vendues et des stocks
  - 5.1 - Analyse des ventes en CA
    - 5.1.1 Calculer le CA su site web
    - 5.1.2 Palmares des articles en CA
    - 5.1.3 Calculer le 20 / 80 en CA
  - 5.2 - Analyse des quantités vendus
    - 5.2.1 Palmares des articles en quantité vendus
    - 5.1.2 Calculer le 20 / 80 ventes en quantité
    - 5.3.3 Valorisation du nombre de produit en stock
  - 5.3 - Analyse des stocks
    - 5.3.1 Calcule le nombre de mois de stock
    - 5.3.2 Valorisation des stocks en euros
    - 5.3.3 Nombre de produit en stock
  - 5.4 -Analyse du taux de marge
    - 5.4.1 Création du taux de marge
    - 5.4.2 Analyse du taux de marge
- Etape 6 - Analyse bivarié et études des corrélations

Etape 1 - Importation des librairies et chargement des fichiers

1.1 - Importation des librairies

In [1]:
```
#Importation de la librairie Pandas
import pandas as pd
```

In [2]:
```
#Importation de la librairie plotly express
import plotly.express as px
```

In [3]:
```
# Importation librairie Numpy
import numpy as np
```

In [4]:
```
# Pour afficher un nombre maximum de colonnes
pd.set_option('display.max_columns', None)
```

In [5]:
```
# Importation librairie matplotlib
import matplotlib.pyplot as plt
```

In [6]:
```
#Importation de Seaborn
import seaborn as sns
```

1.2 - Chargements des fichiers

In [7]:
```
#Importation du fichier web.xlsx
df_web = pd.read_excel('C:\\Users\\wadja\\Desktop\\Openclassroom\\Projet 6\\Data+Bottleneck\\web.xlsx')
```

```
#Importation du fichier erp.xlsx
df_erp = pd.read_excel('C:\\Users\\wadja\\Desktop\\Openclassroom\\Projet 6\\Data+Bottleneck\\erp.xlsx')
#importation du fichier liaison.xlsx
df_liaison = pd.read_excel('C:\\Users\\wadja\\Desktop\\Openclassroom\\Projet 6\\Data+Bottleneck\\liaison.xlsx')
```

```
C:\Users\WadJa\AppData\Local\Packages\PythonSoftwareFoundation.Python.3.12_qbz5n2kfra8p0\LocalCache\local-packages\Python312\site-packages\openpyxl\worksheet\_reader.p
y:329: UserWarning: Unknown extension is not supported and will be removed
  warn(msg)
C:\Users\WadJa\AppData\Local\Packages\PythonSoftwareFoundation.Python.3.12_qbz5n2kfra8p0\LocalCache\local-packages\Python312\site-packages\openpyxl\worksheet\_reader.p
y:329: UserWarning: Unknown extension is not supported and will be removed
  warn(msg)
C:\Users\WadJa\AppData\Local\Packages\PythonSoftwareFoundation.Python.3.12_qbz5n2kfra8p0\LocalCache\local-packages\Python312\site-packages\openpyxl\worksheet\_reader.p
y:329: UserWarning: Unknown extension is not supported and will be removed
  warn(msg)
```

Etape 2 - Analyse exploratoire/Traitement des fichiers

2.1 - Analyse exploratoire du fichier erp.xlsx

In [8]:
```
df_erp.head()
```

Out[8]:

	product_id	onsale_web	price	stock_quantity	stock_status	purchase_price
0	3847	1	24.2	16	instock	12.88
1	3849	1	34.3	10	instock	17.54
2	3850	1	20.8	0	outofstock	10.64
3	4032	1	14.1	26	instock	6.92
4	4039	1	46.0	3	outofstock	23.77

In [9]:
```
df_erp.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 825 entries, 0 to 824
Data columns (total 6 columns):
 #   Column          Non-Null Count  Dtype
---  ------          --------------  -----
 0   product_id      825 non-null    int64
 1   onsale_web      825 non-null    int64
 2   price           825 non-null    float64
 3   stock_quantity  825 non-null    int64
 4   stock_status    825 non-null    object
 5   purchase_price  825 non-null    float64
dtypes: float64(2), int64(3), object(1)
memory usage: 38.8+ KB
```

In [10]:
```
df_erp.describe(include='all')
```

Out[10]:

	product_id	onsale_web	price	stock_quantity	stock_status	purchase_price
count	825.000000	825.000000	825.000000	825.000000	825	825.000000
unique	NaN	NaN	NaN	NaN	2	NaN
top	NaN	NaN	NaN	NaN	instock	NaN
freq	NaN	NaN	NaN	NaN	733	NaN
mean	5162.597576	0.867879	32.187697	21.589091	NaN	16.940582
std	902.644635	0.338828	26.712077	21.933807	NaN	14.561840
min	3847.000000	0.000000	-20.000000	-10.000000	NaN	2.740000
25%	4348.000000	1.000000	14.500000	7.000000	NaN	7.590000
50%	4907.000000	1.000000	24.300000	18.000000	NaN	12.710000
75%	5805.000000	1.000000	42.000000	30.000000	NaN	22.020000
max	7338.000000	1.000000	225.000000	145.000000	NaN	137.810000

In [11]:
```
# Conclusion :
# - Transformations des colonnes 'product_id' et 'onsale_web' en type Object afin d'analyser les valeurs unique avec .describe
```

2.1.1 - Modification colonnes 'product_id' et 'onsale_web' en type "Object"

In [12]:
```
df_erp['product_id'] = df_erp['product_id'].astype(object)

df_erp['onsale_web'] = df_erp['onsale_web'].astype(object)
```

In [13]:
```
df_erp.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 825 entries, 0 to 824
Data columns (total 6 columns):
 #   Column          Non-Null Count  Dtype
---  ------          --------------  -----
 0   product_id      825 non-null    object
 1   onsale_web      825 non-null    object
 2   price           825 non-null    float64
 3   stock_quantity  825 non-null    int64
 4   stock_status    825 non-null    object
 5   purchase_price  825 non-null    float64
dtypes: float64(2), int64(1), object(3)
memory usage: 38.8+ KB
```

In [14]:
```
df_erp.describe(include='all')
```

Out[14]:

	product_id	onsale_web	price	stock_quantity	stock_status	purchase_price
count	825.0	825.0	825.000000	825.000000	825	825.000000
unique	825.0	2.0	NaN	NaN	2	NaN
top	3847.0	1.0	NaN	NaN	instock	NaN
freq	1.0	716.0	NaN	NaN	733	NaN
mean	NaN	NaN	32.187697	21.589091	NaN	16.940582
std	NaN	NaN	26.712077	21.933807	NaN	14.561840
min	NaN	NaN	-20.000000	-10.000000	NaN	2.740000
25%	NaN	NaN	14.500000	7.000000	NaN	7.590000
50%	NaN	NaN	24.300000	18.000000	NaN	12.710000
75%	NaN	NaN	42.000000	30.000000	NaN	22.020000
max	NaN	NaN	225.000000	145.000000	NaN	137.810000

In [15]:
```
# Conclusion :

# - Colonne 'product_id' : Pas de doublon

# - Colonne 'onsale_web' : 716 Referances de bouteilles en ligne

# - Colonne 'price' : Valeur négative à analyser

# - Colonne 'stock_quantity' : Valeur négative à analyser

# - Colonne 'stock_status' : 733 References de bouteilles en stock

# - Colonne 'purchase_price' : Pas de valeurs manquantes

# Taches à réaliser :

# 2.1.2 Vérifications des valeurs négatives colonnes 'price' et 'stock_quantity'
# 2.1.3 Traitement de la colonne 'stock_status' en fonction de la colonne 'stock_quantity'
# 2.1.4 Traitement de la colonne 'onsale_web' en fonction de la colonne 'stock_status'
# 2.1.5 Vérification si le prix de ventes > prix d'achats
```

2.1.2 Vérifications des valeurs négatives colonnes 'price' et 'stock_quantity'

In [16]:
```
###############
#### price ####
###############

#Affichier les prix inférieurs à 0
print("Prix inférieurs à 0:\n", df_erp[df_erp['price'] < 0])
```

```
Prix inférieurs à 0:
     product_id onsale_web  price  stock_quantity stock_status  purchase_price
151       4233          0  -20.0               0   outofstock           10.33
469       5017          0   -8.0               0   outofstock            4.34
739       6594          0   -9.1              19      instock            4.61
```

In [17]:
```
# Trabsformer en valeurs négatives en valeurs positives :
df_erp['price'] = np.abs(df_erp['price'])
```

In [18]:
```
#Vérification : afficher les valeurs pour les lignes 151, 469, et 739
print(df_erp['price'].iloc[[151, 469, 739]])
```

```
151    20.0
469     8.0
739     9.1
Name: price, dtype: float64
```

In [19]:
```
#Vérification : affichier les prix inférieurs à 0
print("Prix inférieurs à 0:\n", df_erp[df_erp['price'] < 0])
```

```
Prix inférieurs à 0:
 Empty DataFrame
Columns: [product_id, onsale_web, price, stock_quantity, stock_status, purchase_price]
Index: []
```

In [20]:
```
#######################
### stock_quantity  ###
#######################

#Affichier les stocks inférieurs à 0
print("Stocks inférieurs à 0:\n", df_erp[df_erp['stock_quantity'] < 0])
```

```
Stocks inférieurs à 0:
     product_id onsale_web  price  stock_quantity stock_status  purchase_price
449       4973          0   10.0             -10   outofstock            4.96
573       5700          1   44.5              -1   outofstock           22.30
```

In [21]:
```
#Valeurs abérante et stock_status 'outofstock' : Corriger les données incohérentes
#Corriger 'stock_quantity' par 0 pour les lignes 449 et 573

df_erp.at[449, "stock_quantity"] = 0
df_erp.at[573, "stock_quantity"] = 0
```

In [22]:
```
#Vérification : afficher les valeurs pour les lignes 449 et 573
print(df_erp.iloc[[449, 573]])
```

```
    product_id onsale_web  price  stock_quantity stock_status  purchase_price
449       4973          0   10.0               0   outofstock            4.96
573       5700          1   44.5               0   outofstock           22.30
```

In [23]:
```
#Vérification : affichier les stocks inférieurs à 0
print("Stocks inférieurs à 0:\n", df_erp[df_erp['stock_quantity'] < 0])
```

```
Stocks inférieurs à 0:
 Empty DataFrame
Columns: [product_id, onsale_web, price, stock_quantity, stock_status, purchase_price]
Index: []
```

2.1.3 Traitement de la colonne 'stock_status' en fonction de la colonne 'stock_quantity'

In [24]:
```
#Si la valeur de la colonne "stock_quantity" est inferieur ou égale à 0, indiquer dans la colonne 'stock_status' : "outofstock" sinon "instock"

df_erp['stock_status'] = np.where(df_erp['stock_quantity'] <= 0, "outofstock", "instock")
df_erp
```

Out[24]:

	product_id	onsale_web	price	stock_quantity	stock_status	purchase_price
0	3847	1	24.2	16	instock	12.88
1	3849	1	34.3	10	instock	17.54
2	3850	1	20.8	0	outofstock	10.64
3	4032	1	14.1	26	instock	6.92
4	4039	1	46.0	3	instock	23.77
...	...	...	...	...	...	...
820	7203	0	45.0	30	instock	23.48
821	7204	0	45.0	9	instock	24.18
822	7247	1	54.8	6	instock	27.18
823	7329	0	26.5	14	instock	13.42
824	7338	1	16.3	40	instock	8.00

825 rows × 6 columns

2.1.4 Traitement de la colonne 'onsale_web' et création d'une variable 'ProduitsAMettreEnLigne'

In [25]:
```
# Valeurs unique onsale_web : [1 0]
# Signifie en ligne sur le site web 1=oui 0=non

# Condition: Si stock_quantity est égal à 0, alors onsale_web est mis à 0
df_erp.loc[df_erp['stock_quantity'] == 0, 'onsale_web'] = 0
```

In [26]:
```
# onsale_web2 = 1 si stock_status = 'instock' sinon onsale_web2= 0
df_erp['onsale_web_2'] = np.where(df_erp['stock_status'] == "instock", 1, 0)

#Liste des lignes différentes entre 'onsale_web' et 'onsale_web2'
lignesOnsale_web = df_erp[df_erp["onsale_web"] != df_erp["onsale_web_2"]]
lignesOnsale_web
```

Out[26]:

	product_id	onsale_web	price	stock_quantity	stock_status	purchase_price	onsale_web_2
123	4200	0	5.8	33	instock	3.12	1
234	4565	0	30.5	3	instock	15.92	1
238	4577	0	49.0	1	instock	24.05	1
239	4578	0	40.0	3	instock	20.05	1
318	4692	0	12.0	48	instock	6.39	1
...	...	...	...	...	...	...	...
818	7200	0	31.0	6	instock	15.54	1
819	7201	0	31.0	18	instock	16.02	1
820	7203	0	45.0	30	instock	23.48	1
821	7204	0	45.0	9	instock	24.18	1
823	7329	0	26.5	14	instock	13.42	1

65 rows × 7 columns

In [27]:
```
# 65 References produits à mettre en lignes :

#Création d'une variable 'ProduitsAMettreEnLigne' pour lister les poduct_id à mettre en ligne sur le site web'

ProduitsAMettreEnLigne = lignesOnsale_web['product_id'].tolist()

print(ProduitsAMettreEnLigne)
```

```
[4200, 4565, 4577, 4578, 4692, 4697, 4738, 4744, 5559, 5560, 5569, 5808, 6324, 6594, 6821, 6824, 6825, 6826, 6864, 6866, 6869, 6875, 6898, 6899, 6902, 6903, 6904, 6905, 6906, 6907, 6908, 6909, 7008, 7009, 7010, 7015, 7081, 7084, 7085, 7086, 7087, 7088, 7131, 7132, 7133, 7136, 7137, 7159, 7161, 7162, 7163, 7164, 7168, 7169, 7170, 7192, 7193, 7194, 7195, 7196, 7200, 7201, 7203, 7204, 7329]
```

In [28]:
```
#Suppression de la colonne 'onsale_web2'
df_erp = df_erp.drop('onsale_web_2', axis=1)
```

2.1.5 Vérification si prix de ventes > prix d'achats et création d'une variable 'PrixAchatAVerifier'

In [29]:
```
# Pour vérifier si 'purchase_price' est supérieure ou égale à 'price'
VenteAPerte = df_erp[df_erp['purchase_price'] >= df_erp['price']]

print(VenteAPerte)
```

```
    product_id onsale_web  price  stock_quantity stock_status  purchase_price
210       4355          1  12.65              97      instock           77.48
391       4864          0   8.30               0   outofstock            9.99
724       6324          0  92.00              18      instock           99.00
817       7196          0  31.00              55      instock           31.20
```

In [30]:
```
# Conclusion : Promotion de destockage ou erreur de saisie ?
# Création d'une liste avec les id_produit :

VentesApertes = VenteAPerte['product_id'].tolist()
VentesApertes
```

Out[30]:
```
[4355, 4864, 6324, 7196]
```

In [31]:
```
df_erp.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 825 entries, 0 to 824
Data columns (total 6 columns):
 #   Column          Non-Null Count  Dtype
---  ------          --------------  -----
 0   product_id      825 non-null    object
 1   onsale_web      825 non-null    object
 2   price           825 non-null    float64
 3   stock_quantity  825 non-null    int64
 4   stock_status    825 non-null    object
 5   purchase_price  825 non-null    float64
dtypes: float64(2), int64(1), object(3)
memory usage: 38.8+ KB
```

In [32]:
```
df_erp.describe(include='all')
```

Out[32]:

	product_id	onsale_web	price	stock_quantity	stock_status	purchase_price
count	825.0	825.0	825.000000	825.000000	825	825.000000
unique	825.0	2.0	NaN	NaN	2	NaN
top	3847.0	1.0	NaN	NaN	instock	NaN
freq	1.0	668.0	NaN	NaN	733	NaN
mean	NaN	NaN	32.277636	21.602424	NaN	16.940582
std	NaN	NaN	26.603196	21.917863	NaN	14.561840
min	NaN	NaN	5.200000	0.000000	NaN	2.740000
25%	NaN	NaN	14.500000	7.000000	NaN	7.590000
50%	NaN	NaN	24.300000	18.000000	NaN	12.710000
75%	NaN	NaN	42.000000	30.000000	NaN	22.020000
max	NaN	NaN	225.000000	145.000000	NaN	137.810000

2.2 - Analyse exploratoire du fichier liaison.xlsx

In [33]:
```
df_liaison.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 825 entries, 0 to 824
Data columns (total 2 columns):
 #   Column      Non-Null Count  Dtype
---  ------      --------------  -----
 0   id_web      734 non-null    object
 1   product_id  825 non-null    int64
dtypes: int64(1), object(1)
memory usage: 13.0+ KB
```

2.1.1 - Modification colonnes 'product_id' et 'onsale_web' en type "Object"

In [34]:
```
df_liaison['product_id'] = df_liaison['product_id'].astype(object)
```

In [35]:
```
df_liaison.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 825 entries, 0 to 824
Data columns (total 2 columns):
 #   Column      Non-Null Count  Dtype
---  ------      --------------  -----
 0   id_web      734 non-null    object
 1   product_id  825 non-null    object
dtypes: object(2)
memory usage: 13.0+ KB
```

In [36]:
```
df_liaison.describe(include='all')
```

Out[36]:

	id_web	product_id
count	734	825
unique	734	825
top	15298	3847
freq	1	1

In [37]:
```
# Les valeurs de la colonne "id_web" et "product_id" sont toutes uniques

# Calcul du nombre d'occurrences dans chaque colonne
Unique_product_id = set(df_liaison['product_id'].dropna())
Unique_id_web = set(df_liaison['id_web'].dropna())

nb_product_id = len(Unique_product_id )
```

```
nb_id_web = len(Unique_id_web)

# Calcul des lignes sans correspondances
id_web_manquants = nb_product_id - nb_id_web

print(f"Nombre d'éléments 'product_id' : {nb_product_id}")
print(f"Nombre d'éléments 'id_web' : {nb_id_web}")

print('Il y a :',id_web_manquants,'id_web sans corespondances')
```

```
Nombre d'éléments 'product_id' : 825
Nombre d'éléments 'id_web' : 734
Il y a : 91 id_web sans corespondances
```

2.3 - Analyse exploratoire du fichier web.xlsx

In [38]:
```
df_web.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1513 entries, 0 to 1512
Data columns (total 29 columns):
 #   Column                 Non-Null Count  Dtype
---  ------                 --------------  -----
 0   sku                    1428 non-null   object
 1   virtual                1513 non-null   int64
 2   downloadable           1513 non-null   int64
 3   rating_count           1513 non-null   int64
 4   average_rating         1430 non-null   float64
 5   total_sales            1430 non-null   float64
 6   tax_status             716 non-null    object
 7   tax_class              0 non-null      float64
 8   post_author            1430 non-null   float64
 9   post_date              1430 non-null   datetime64[ns]
 10  post_date_gmt          1430 non-null   datetime64[ns]
 11  post_content           0 non-null      float64
 12  product_type           1429 non-null   object
 13  post_title             1430 non-null   object
 14  post_excerpt           716 non-null    object
 15  post_status            1430 non-null   object
 16  comment_status         1430 non-null   object
 17  ping_status            1430 non-null   object
 18  post_password          0 non-null      float64
 19  post_name              1430 non-null   object
 20  post_modified          1430 non-null   datetime64[ns]
 21  post_modified_gmt      1430 non-null   datetime64[ns]
 22  post_content_filtered  0 non-null      float64
 23  post_parent            1430 non-null   float64
 24  guid                   1430 non-null   object
 25  menu_order             1430 non-null   float64
 26  post_type              1430 non-null   object
 27  post_mime_type         714 non-null    object
 28  comment_count          1430 non-null   float64
dtypes: datetime64[ns](4), float64(10), int64(3), object(12)
memory usage: 342.9+ KB
```

In [39]:
```
# Suppression des colonnes vides ou inultiles à l'analyse des ventes :
df_web = df_web.drop(
columns=['virtual','downloadable', 'rating_count', 'average_rating','tax_status', 'tax_class', 'post_author','post_author','post_date', 'post_date_gmt',
        'post_content','post_excerpt', 'post_status', 'comment_status', 'ping_status',
        'post_password','post_name','post_modified','post_modified_gmt', 'post_content_filtered', 'post_parent', 'menu_order',
        'post_mime_type', 'comment_count' ], axis=1 )
```

In [40]:
```
df_web.describe(include = 'all')
```

Out[40]:

	sku	total_sales	product_type	post_title	guid	post_type
count	1428.0	1430.000000	1429	1430	1430	1430
unique	714.0	NaN	7	713	1430	2
top	11862.0	NaN	Vin	Clos du Mont-Olivet Châteauneuf-du-Pape 2007	https://www.bottle-neck.fr/wp-content/uploads/...	product
freq	2.0	NaN	1318	4	1	716
mean	NaN	8.223077	NaN	NaN	NaN	NaN
std	NaN	6.721899	NaN	NaN	NaN	NaN
min	NaN	-56.000000	NaN	NaN	NaN	NaN
25%	NaN	5.000000	NaN	NaN	NaN	NaN
50%	NaN	8.000000	NaN	NaN	NaN	NaN
75%	NaN	11.000000	NaN	NaN	NaN	NaN
max	NaN	122.000000	NaN	NaN	NaN	NaN

In [41]:
```
# sku comporte 714 valeurs unique sur 1428 valeurs.
# Freq = 2 Cela indique que les valeurs sont présentes 2 fois maximum (doubllon)
# Conclusions :
# pas de doublon sku produits, les doublons sont dus à post_type (produit ou attachment ) sur le site web.
# Crée une table df_web_produit pour les poduits avec pour clé primaire sku afin d'éviter la redondance des données

# - Colonne 'total_sales' : Valeur négative à analyser
```

In [42]:
```
df_web.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1513 entries, 0 to 1512
Data columns (total 6 columns):
 #   Column        Non-Null Count  Dtype
---  ------        --------------  -----
 0   sku           1428 non-null   object
 1   total_sales   1430 non-null   float64
 2   product_type  1429 non-null   object
 3   post_title    1430 non-null   object
 4   guid          1430 non-null   object
 5   post_type     1430 non-null   object
dtypes: float64(1), object(5)
memory usage: 71.1+ KB
```

In [43]:
```
# Calcul du nombre de lignes qui sont entièrement vides
LigneNan = df_web.isna().all(axis=1).sum()

print("Il y a",LigneNan,"Lignes vide à supprimer")
```

```
Il y a 83 Lignes vide à supprimer
```

In [44]:
```
df_web.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1513 entries, 0 to 1512
Data columns (total 6 columns):
 #   Column        Non-Null Count  Dtype
---  ------        --------------  -----
 0   sku           1428 non-null   object
 1   total_sales   1430 non-null   float64
 2   product_type  1429 non-null   object
 3   post_title    1430 non-null   object
 4   guid          1430 non-null   object
 5   post_type     1430 non-null   object
dtypes: float64(1), object(5)
memory usage: 71.1+ KB
```

In [45]:
```
df_web.head(5)
```

Out[45]:

	sku	total_sales	product_type	post_title	guid	post_type
0	11862	3.0	Vin	Gilles Robin Hermitage Rouge 2012	https://www.bottle-neck.fr/wp-content/uploads/...	attachment
1	16057	5.0	Vin	Domaine Pellé Sancerre Rouge La Croix Au Garde...	https://www.bottle-neck.fr/wp-content/uploads/...	attachment
2	14692	5.0	Vin	Château Fonréaud Bordeaux Blanc Le Cygne 2016	https://www.bottle-neck.fr/?post_type=product&...	product
3	16295	14.0	Vin	Moulin de Gassac IGP Pays d'Hérault Guilhem Ro...	https://www.bottle-neck.fr/wp-content/uploads/...	attachment
4	15328	2.0	Vin	Agnès Levet Côte Rôtie Maestria 2017	https://www.bottle-neck.fr/?post_type=product&...	product

2.3.1 Codes articles manquants

In [46]:
```
# Affichage des lignes avec valeurs manquantes dans 'sku'
sku_valeurs_manquantes = df_web[df_web['sku'].isna()]
sku_valeurs_manquantes['sku']
```

Out[46]:
```
8       NaN
20      NaN
30      NaN
37      NaN
41      NaN
       ...
1384    NaN
1429    NaN
1432    NaN
1445    NaN
1457    NaN
Name: sku, Length: 85, dtype: object
```

In [47]:
```
sku_valeurs_manquantes.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 85 entries, 8 to 1457
Data columns (total 6 columns):
 #   Column        Non-Null Count  Dtype
---  ------        --------------  -----
 0   sku           0 non-null      object
 1   total_sales   2 non-null      float64
 2   product_type  2 non-null      object
 3   post_title    2 non-null      object
 4   guid          2 non-null      object
 5   post_type     2 non-null      object
dtypes: float64(1), object(5)
memory usage: 4.6+ KB
```

In [48]:
```
# > Suppression des lignes totalement vides :
df_web = df_web.dropna(how='all')
```

In [49]:
```
# Vérifications :
sku_valeurs_manquantes = df_web[df_web['sku'].isna()]
sku_valeurs_manquantes.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 2 entries, 1084 to 1087
Data columns (total 6 columns):
 #   Column        Non-Null Count  Dtype
---  ------        --------------  -----
 0   sku           0 non-null      object
 1   total_sales   2 non-null      float64
 2   product_type  2 non-null      object
 3   post_title    2 non-null      object
 4   guid          2 non-null      object
 5   post_type     2 non-null      object
dtypes: float64(1), object(5)
memory usage: 112.0+ bytes
```

2.3.2 Remplacement des articles manquants par le product_id (4 derniers caractères du lien https)

In [50]:
```
# Filtrez pour obtenir seulement les lignes avec des valeurs manquantes dans 'sku' et 'guid' non NaN
sku_valeurs_manquantes2 = df_web[df_web['sku'].isna()]
sku_valeurs_manquantes2
```

Out[50]:

	sku	total_sales	product_type	post_title	guid	post_type
1084	NaN	-56.0	Vin	Pierre Jean Villa Condrieu Jardin Suspendu 2018	https://www.bottle-neck.fr/?post_type=product&...	product
1087	NaN	-17.0	Vin	Pierre Jean Villa Côte Rôtie Fongeant 2017	https://www.bottle-neck.fr/?post_type=product&...	product

In [51]:
```
# Mise à jour de 'sku' pour les lignes 1084 et 1087
df_web.loc[[1084, 1087], 'sku'] = df_web.loc[[1084, 1087], 'guid'].apply(lambda x: x[-4:])

print(df_web.loc[[1084, 1087], ['sku','guid']])
```

```
      sku                                          guid
1084  5075  https://www.bottle-neck.fr/?post_type=product&...
1087  5070  https://www.bottle-neck.fr/?post_type=product&...
```

In [52]:
```
df_web.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 1430 entries, 0 to 1512
Data columns (total 6 columns):
 #   Column        Non-Null Count  Dtype
---  ------        --------------  -----
 0   sku           1430 non-null   object
 1   total_sales   1430 non-null   float64
 2   product_type  1429 non-null   object
 3   post_title    1430 non-null   object
 4   guid          1430 non-null   object
 5   post_type     1430 non-null   object
dtypes: float64(1), object(5)
memory usage: 110.5+ KB
```

2.3.3 Remplacement des sku table df_liaison

In [53]:
```
# Recherche des sku coresspondants dans la table df_liaison

# Affichage des lignes où 'product_id' est 5075 ou 5070
resultat = df_liaison.loc[df_liaison['product_id'].isin([5075, 5070])]

print(resultat)
```

```
   id_web product_id
486    NaN       5070
487    NaN       5075
```

In [54]:
```
# Les sku sont manquants, remplacement par le product_id

# Lignes où 'product_id' est égale à 5075 ou 5070
condition = df_liaison['product_id'].isin([5075, 5070])

# Remplacer la valeur de 'id_web' par celle de 'product_id' pour ces lignes spécifiques
df_liaison.loc[condition, 'id_web'] = df_liaison.loc[condition, 'product_id']

# Afficher les lignes modifiées pour vérification
print(df_liaison[condition])
```

```
   id_web product_id
486   5070       5070
487   5075       5075
```

2.3.4 Liste des codes articles ne respectant pas la régle de codification

In [55]:
```
# Filtrage des valeurs non manquantes qui ne correspondent pas au format de 5 caractères
sku_non_conformes = df_web[df_web['sku'].notna() & ~df_web['sku'].astype(str).str.match(r'^.{5}$')]

ListeSkuNonConformes = sku_non_conformes['sku'].tolist()
```

In [56]:
```
ListeSkuNonConformes
```

Out[56]:
```
[9636,
 804,
 3506,
 9937,
 802,
 4679,
 3509,
 2534,
 791,
 793,
 '13127-1',
 304,
 7033,
 791,
 3568,
 7086,
 805,
 7819,
 4679,
 2179,
 38,
 8463,
 9562,
 531,
 7086,
 2361,
 1366,
 793,
 812,
 3383,
 1366,
 804,
 3510,
 8365,
 3507,
 1364,
 2179,
 9937,
 9636,
 8193,
 798,
 1662,
 7032,
 5646,
 8344,
 3506,
 3568,
 1360,
 'bon-cadeau-25-euros',
 7032,
 523,
 3383,
 3510,
 38,
 41,
 7819,
 8344,
 1662,
 807,
 1364,
 7818,
 3507,
 '5075',
 '5070',
 812,
 3509,
 '13127-1',
 41,
 2361,
 7818,
 807,
 6616,
 1360,
 8365,
 304,
 5646,
 802,
 8193,
 8463,
 7033,
 'bon-cadeau-25-euros',
 523,
 9562,
 805,
 531,
 2534,
 798,
 6616]
```

2.3.5 Création du df_web_produit fonction de post_type

In [57]:
```
# Filtrer le DataFrame pour ne garder que les lignes où 'post_type' est 'product'
df_web_produits = df_web[df_web['post_type'] == 'product']

# Vérifier l'unicité des valeurs dans la colonne 'sku'

unique_sku = df_web_produits['sku'].nunique()
total_products = df_web_produits['sku'].count()
sku_unique = unique_sku == total_products

sku_unique
```

Out[57]:
```
True
```

In [58]:
```
df_web_produits.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 716 entries, 2 to 1509
Data columns (total 6 columns):
 #   Column        Non-Null Count  Dtype
---  ------        --------------  -----
 0   sku           716 non-null    object
 1   total_sales   716 non-null    float64
 2   product_type  715 non-null    object
 3   post_title    716 non-null    object
 4   guid          716 non-null    object
 5   post_type     716 non-null    object
dtypes: float64(1), object(5)
memory usage: 39.2+ KB
```

In [59]:
```
df_web_produits.describe(include='all')
```

Out[59]:

	sku	total_sales	product_type	post_title	guid	post_type
count	716.0	716.000000	715	716	716	716
unique	716.0	NaN	6	713	716	1
top	14692.0	NaN	Vin	Domaine Hauvette IGP Alpilles Jaspe 2017	https://www.bottle-neck.fr/?post_type=product&...	product
freq	1.0	NaN	660	2	1	716
mean	NaN	7.930168	NaN	NaN	NaN	NaN
std	NaN	4.885616	NaN	NaN	NaN	NaN
min	NaN	-56.000000	NaN	NaN	NaN	NaN
25%	NaN	5.000000	NaN	NaN	NaN	NaN
50%	NaN	8.000000	NaN	NaN	NaN	NaN
75%	NaN	11.000000	NaN	NaN	NaN	NaN
max	NaN	36.000000	NaN	NaN	NaN	NaN

2.3.6 Vérifications des valeurs négatives colonne 'total_sales'

In [60]:
```
#Affichier Total des ventes inférieurs à 0 :

df_web_produits[df_web_produits['total_sales'] < 0]
```

Out[60]:

	sku	total_sales	product_type	post_title	guid	post_type
1084	5075	-56.0	Vin	Pierre Jean Villa Condrieu Jardin Suspendu 2018	https://www.bottle-neck.fr/?post_type=product&...	product
1087	5070	-17.0	Vin	Pierre Jean Villa Côte Rôtie Fongeant 2017	https://www.bottle-neck.fr/?post_type=product&...	product

In [61]:
```
# Erreur d'irrégularité pour les lignes 1084 et 1087

# Trabsformer en valeurs négatives en valeurs positives :
df_web_produits.loc[:, 'total_sales'] = np.abs(df_web_produits['total_sales'])
```

In [62]:
```
#Vérification :
df_web_produits.loc[[1084,1087]]
```

Out[62]:

	sku	total_sales	product_type	post_title	guid	post_type
1084	5075	56.0	Vin	Pierre Jean Villa Condrieu Jardin Suspendu 2018	https://www.bottle-neck.fr/?post_type=product&...	product
1087	5070	17.0	Vin	Pierre Jean Villa Côte Rôtie Fongeant 2017	https://www.bottle-neck.fr/?post_type=product&...	product

2.3.7 - Renommer la colonne 'sku' en 'id_web'

In [63]:
```
df_web_produits.rename(columns={'sku': 'id_web'}, inplace=True)

df_web_produits
```

```
C:\Users\WadJa\AppData\Local\Temp\ipykernel_25860\3560282825.py:1: SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html#returning-a-view-versus-a-copy
  df_web_produits.rename(columns={'sku': 'id_web'}, inplace=True)
```

Out[63]:

	id_web	total_sales	product_type	post_title	guid	post_type
2	14692	5.0	Vin	Château Fonréaud Bordeaux Blanc Le Cygne 2016	https://www.bottle-neck.fr/?post_type=product&...	product
4	15328	2.0	Vin	Agnès Levet Côte Rôtie Maestria 2017	https://www.bottle-neck.fr/?post_type=product&...	product
6	16515	10.0	Vin	Château Turcaud Bordeaux Rouge Cuvée Majeure 2018	https://www.bottle-neck.fr/?post_type=product&...	product
11	16585	15.0	Vin	Xavier Frissant Touraine Sauvignon 2019	https://www.bottle-neck.fr/?post_type=product&...	product
14	12869	7.0	Vin	Stéphane Tissot Arbois D.D. 2016	https://www.bottle-neck.fr/?post_type=product&...	product
...	...	...	...	...	...	...
1503	13074	4.0	Vin	Château de Vaudieu Châteauneuf-du-Pape L'Avenu...	https://www.bottle-neck.fr/?post_type=product&...	product
1505	16322	0.0	Vin	Moulin de Gassac IGP Pays d'Hérault Guilhem Ro...	https://www.bottle-neck.fr/?post_type=product&...	product
1507	12365	10.0	Vin	Parés Baltà Penedès Electio 2013	https://www.bottle-neck.fr/?post_type=product&...	product
1508	16326	5.0	Vin	Camin Larredya Jurançon Moelleux Au Capcéu 2018	https://www.bottle-neck.fr/?post_type=product&...	product
1509	15662	15.0	Vin	Chermette Domaine du Vissoux Beaujolais Griott...	https://www.bottle-neck.fr/?post_type=product&...	product

716 rows × 6 columns

2.3.8 - Suppression du code promo

In [64]:
```
# Création d'un masque pour identifier les lignes où product_type est NaN
masque_nan = df_web_produits['product_type'].isna()

# Utilisation du masque pour filtrer df_web et afficher la ligne vide
lignes_avec_nan = df_web_produits[masque_nan]

lignes_avec_nan
```

Out[64]:

	id_web	total_sales	product_type	post_title	guid	post_type
1387	bon-cadeau-25-euros	7.0	NaN	Bon cadeau de 25€	https://www.bottle-neck.fr/?post_type=product&...	product

In [65]:
```
# Code promo à supprimer car inutile pour l'analyse des ventes

df_web_produits = df_web_produits[df_web_produits['id_web'] != 'bon-cadeau-25-euros']
```

In [66]:
```
df_web_produits.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 715 entries, 2 to 1509
Data columns (total 6 columns):
 #   Column        Non-Null Count  Dtype
---  ------        --------------  -----
 0   id_web        715 non-null    object
 1   total_sales   715 non-null    float64
 2   product_type  715 non-null    object
 3   post_title    715 non-null    object
 4   guid          715 non-null    object
 5   post_type     715 non-null    object
dtypes: float64(1), object(5)
memory usage: 39.1+ KB
```

Etape 3 - Jonction des fichiers

3.1 Réalisation de la jointure entre df_erp et df_liaison

In [67]:
```
df_merge = pd.merge(df_liaison, df_erp,how="inner", on='product_id',validate='one_to_one')

df_merge.head(10)
```

Out[67]:

	id_web	product_id	onsale_web	price	stock_quantity	stock_status	purchase_price
0	15298	3847	1	24.2	16	instock	12.88
1	15296	3849	1	34.3	10	instock	17.54
2	15300	3850	0	20.8	0	outofstock	10.64
3	19814	4032	1	14.1	26	instock	6.92
4	19815	4039	1	46.0	3	instock	23.77
5	15303	4040	1	34.3	12	instock	18.25
6	14975	4041	1	32.7	12	instock	17.57
7	16042	4042	1	31.2	15	instock	15.48
8	14980	4043	0	60.0	0	outofstock	29.45
9	16041	4045	1	42.6	5	instock	22.01

In [68]:
```
df_merge.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 825 entries, 0 to 824
Data columns (total 7 columns):
 #   Column          Non-Null Count  Dtype
---  ------          --------------  -----
 0   id_web          736 non-null    object
 1   product_id      825 non-null    object
 2   onsale_web      825 non-null    object
 3   price           825 non-null    float64
 4   stock_quantity  825 non-null    int64
 5   stock_status    825 non-null    object
 6   purchase_price  825 non-null    float64
dtypes: float64(2), int64(1), object(4)
memory usage: 45.2+ KB
```

In [69]:
```
# Vérification de la jointure

# Calculer le nombre d'occurrences

nb_erp = len(df_erp)
nb_liaison = len(df_liaison)
nb_merge = len(df_merge)

print("Nombre d'occurrences dataframe df_erp", nb_erp)
print("Nombre d'occurrences dataframe df_liaison", nb_liaison)
print("Nombre d'occurrences dataframe df_werge", nb_merge)
```

```
Nombre d'occurrences dataframe df_erp 825
Nombre d'occurrences dataframe df_liaison 825
Nombre d'occurrences dataframe df_werge 825
```

In [70]:
```
df_merge.describe(include='all')
```

Out[70]:

	id_web	product_id	onsale_web	price	stock_quantity	stock_status	purchase_price
count	736.0	825.0	825.0	825.000000	825.000000	825	825.000000
unique	736.0	825.0	2.0	NaN	NaN	2	NaN
top	15298.0	3847.0	1.0	NaN	NaN	instock	NaN
freq	1.0	1.0	668.0	NaN	NaN	733	NaN
mean	NaN	NaN	NaN	32.277636	21.602424	NaN	16.940582
std	NaN	NaN	NaN	26.603196	21.917863	NaN	14.561840
min	NaN	NaN	NaN	5.200000	0.000000	NaN	2.740000
25%	NaN	NaN	NaN	14.500000	7.000000	NaN	7.590000
50%	NaN	NaN	NaN	24.300000	18.000000	NaN	12.710000
75%	NaN	NaN	NaN	42.000000	30.000000	NaN	22.020000
max	NaN	NaN	NaN	225.000000	145.000000	NaN	137.810000

3.2 Réalisation de la jointure entre df_merge et df_web

In [71]:
```
df_web_erp = pd.merge(df_merge, df_web_produits, on='id_web', how="inner")

df_web_erp.head(10)
```

Out[71]:

	id_web	product_id	onsale_web	price	stock_quantity	stock_status	purchase_price	total_sales	product_type	post_title	guid	post_type
0	15298	3847	1	24.2	16	instock	12.88	6.0	Vin	Pierre Jean Villa Saint-Joseph Préface 2018	https://www.bottle-neck.fr/?post_type=product&...	product
1	15296	3849	1	34.3	10	instock	17.54	9.0	Vin	Pierre Jean Villa Saint-Joseph Rouge Tildé 2017	https://www.bottle-neck.fr/?post_type=product&...	product
2	15300	3850	0	20.8	0	outofstock	10.64	0.0	Vin	Pierre Jean Villa Crozes-Hermitage Accroche Co...	https://www.bottle-neck.fr/?post_type=product&...	product
3	19814	4032	1	14.1	26	instock	6.92	12.0	Vin	Pierre Jean Villa IGP Collines Rhodaniennes Ga...	https://www.bottle-neck.fr/?post_type=product&...	product
4	19815	4039	1	46.0	3	instock	23.77	3.0	Vin	Pierre Jean Villa Côte Rôtie Carmina 2017	https://www.bottle-neck.fr/?post_type=product&...	product
5	15303	4040	1	34.3	12	instock	18.25	7.0	Vin	Pierre Jean Villa Saint-Joseph Saut De l'Ange ...	https://www.bottle-neck.fr/?post_type=product&...	product
6	14975	4041	1	32.7	12	instock	17.57	6.0	Vin	Pierre Gaillard Condrieu 2018	https://www.bottle-neck.fr/?post_type=product&...	product
7	16042	4042	1	31.2	15	instock	15.48	8.0	Vin	Pierre Gaillard Cornas 2017	https://www.bottle-neck.fr/?post_type=product&...	product
8	14980	4043	0	60.0	0	outofstock	29.45	0.0	Vin	Pierre Gaillard Côte Rôtie Esprit de Blonde 2017	https://www.bottle-neck.fr/?post_type=product&...	product
9	16041	4045	1	42.6	5	instock	22.01	3.0	Vin	Pierre Gaillard Côte Rôtie 2018	https://www.bottle-neck.fr/?post_type=product&...	product

In [72]:
```
df_web_erp.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 713 entries, 0 to 712
Data columns (total 12 columns):
 #   Column          Non-Null Count  Dtype
---  ------          --------------  -----
 0   id_web          713 non-null    object
 1   product_id      713 non-null    object
 2   onsale_web      713 non-null    object
 3   price           713 non-null    float64
 4   stock_quantity  713 non-null    int64
 5   stock_status    713 non-null    object
 6   purchase_price  713 non-null    float64
 7   total_sales     713 non-null    float64
 8   product_type    713 non-null    object
 9   post_title      713 non-null    object
 10  guid            713 non-null    object
 11  post_type       713 non-null    object
dtypes: float64(3), int64(1), object(8)
memory usage: 67.0+ KB
```

In [73]:
```
df_web_erp.describe(include='all')
```

Out[73]:

	id_web	product_id	onsale_web	price	stock_quantity	stock_status	purchase_price	total_sales	product_type	post_title	guid	post_type
count	713.0	713.0	713.0	713.000000	713.000000	713	713.000000	713.000000	713	713	713	713
unique	713.0	713.0	2.0	NaN	NaN	2	NaN	NaN	6	710	713	1
top	15298.0	3847.0	1.0	NaN	NaN	instock	NaN	NaN	Vin	Clos du Mont-Olivet Châteauneuf-du-Pape 2007	https://www.bottle-neck.fr/?post_type=product&...	product
freq	1.0	1.0	667.0	NaN	NaN	668	NaN	NaN	658	2	1	713
mean	NaN	NaN	NaN	32.343969	23.446003	NaN	16.909060	8.056101	NaN	NaN	NaN	NaN
std	NaN	NaN	NaN	27.614335	22.234835	NaN	14.837177	4.164078	NaN	NaN	NaN	NaN
min	NaN	NaN	NaN	5.200000	0.000000	NaN	2.740000	0.000000	NaN	NaN	NaN	NaN
25%	NaN	NaN	NaN	14.050000	9.000000	NaN	7.240000	5.000000	NaN	NaN	NaN	NaN
50%	NaN	NaN	NaN	23.400000	20.000000	NaN	12.280000	8.000000	NaN	NaN	NaN	NaN
75%	NaN	NaN	NaN	42.100000	30.000000	NaN	22.030000	11.000000	NaN	NaN	NaN	NaN
max	NaN	NaN	NaN	225.000000	145.000000	NaN	137.810000	36.000000	NaN	NaN	NaN	NaN

3.3 Vérification des différences entre df_merge et df_web

In [74]:

```
# df_merge + df_web_produit = df_web_erp


nb_web_produits = len(df_liaison)
nb_web_erp = len(df_web_erp)


print("df_web_produits",nb_web_produits," valeurs non null")
print("Les même colonnes de df_web_erp possede", nb_web_erp ,"valeurs non null")
```

```
df_web_produits 825  valeurs non null
Les même colonnes de df_web_erp possede 713 valeurs non null
```

In [75]:

```
# Fusionner les deux DataFrames avec un indicateur pour identifier les deux lignes manquantes apres le merge :
merged_df = pd.merge(df_web_produits, df_merge, on=['id_web'], how='outer', indicator=True)

# Filtrer pour garder uniquement les lignes Qui n'ont pas été ajouté après le merge
diff_df = merged_df[merged_df['_merge'] == 'left_only'].drop(columns=['_merge'])


diff_df
```

Out[75]:

	id_web	total_sales	product_type	post_title	guid	post_type	product_id	onsale_web	price	stock_quantity	stock_status	purchase_price
735	5070	17.0	Vin	Pierre Jean Villa Côte Rôtie Fongeant 2017	https://www.bottle-neck.fr/?post_type=product&...	product	NaN	NaN	NaN	NaN	NaN	NaN
736	5075	56.0	Vin	Pierre Jean Villa Condrieu Jardin Suspendu 2018	https://www.bottle-neck.fr/?post_type=product&...	product	NaN	NaN	NaN	NaN	NaN	NaN

In [76]:

```
# Verifier si les valeurs 5075 et 5070  ['id_web'] sont présent dans df_merge

# Vérification de la présence des valeurs
presence_5075 = 5075 in df_web_produits['id_web'].values
presence_5070 = 5070 in df_web_produits['id_web'].values

presence_5075, presence_5070
```

Out[76]:

```
(False, False)
```

In [77]:

```
# Fusionner les deux DataFrames avec un indicateur pour identifier les deux lignes manquantes apres le merge :
merged_df2 = pd.merge(df_merge, df_web_erp, on=['id_web'], how='outer', indicator=True)

# Filtrer pour garder uniquement les lignes Qui n'ont pas été ajouté après le merge
diff_df2 = merged_df2[merged_df2['_merge'] == 'left_only'].drop(columns=['_merge'])


diff_df2
```

Out[77]:

	id_web	product_id_x	onsale_web_x	price_x	stock_quantity_x	stock_status_x	purchase_price_x	product_id_y	onsale_web_y	price_y	stock_quantity_y	stock_status_y	purchase_pri
27	5070	5070	0	84.7	0	outofstock	47.43	NaN	NaN	NaN	NaN	NaN	
28	5075	5075	0	43.3	0	outofstock	21.70	NaN	NaN	NaN	NaN	NaN	
83	12601	4741	0	12.4	0	outofstock	6.66	NaN	NaN	NaN	NaN	NaN	
129	13577	5957	0	39.0	0	outofstock	20.75	NaN	NaN	NaN	NaN	NaN	
141	13771	4289	0	22.8	0	outofstock	11.90	NaN	NaN	NaN	NaN	NaN	
...	...	...	...	...	...	...	...	...	...	...	...	...	
820	NaN	7196	0	31.0	55	instock	31.20	NaN	NaN	NaN	NaN	NaN	
821	NaN	7200	0	31.0	6	instock	15.54	NaN	NaN	NaN	NaN	NaN	
822	NaN	7201	0	31.0	18	instock	16.02	NaN	NaN	NaN	NaN	NaN	
823	NaN	7203	0	45.0	30	instock	23.48	NaN	NaN	NaN	NaN	NaN	
824	NaN	7204	0	45.0	9	instock	24.18	NaN	NaN	NaN	NaN	NaN	

112 rows × 18 columns

In [78]:

```
# Identification des id_web dans df_merge non présents dans df_web_produits
ids_non_presents = df_merge[~df_merge['id_web'].isin(df_web_produits['id_web'])]['id_web']
```

```
ids_non_presents.info()
```

```
<class 'pandas.core.series.Series'>
Index: 112 entries, 19 to 823
Series name: id_web
Non-Null Count  Dtype
--------------  -----
23 non-null     object
dtypes: object(1)
memory usage: 1.8+ KB
```

In [79]:
```
# Les id_web du df_merge ne sont pas présent dans df_web produits c'est pour cela qu'il n'ont pas été ajouté au df_web_erp
```

Etape 4 - Analyse univarié

4.1 - Analyse de la variable 'price'

In [80]:
```
# Variable quantitative Continue = Analyse boite à moustache et histogramme
```

4.1.1 Exploration graphique 'price'

In [81]:
```
#Création d'une Boite à moustache de la répartition des prix
fig = px.box(df_web_erp, y='price', title='Répartition des prix')
fig.show()
```

In [82]:
```
# Création de l'histogramme de répartition des prix


fig = px.histogram(df_web_erp, x='price', title='Distribution des prix')
fig.update_layout(bargap=0.2)

fig.show()
```

4.1.2 Exploration Statistique 'price'

In [83]:
```
# Définition des classes
bins = np.linspace(df_web_erp['price'].min(), df_web_erp['price'].max(), num=10)

# Agrégation des données en classes
df_web_erp['classe_price'] = pd.cut(df_web_erp['price'], bins=bins, include_lowest=True)

# Calcul des effectifs et fréquences par classe
tab = df_web_erp['classe_price'].value_counts().reset_index()
tab.columns = ['Classe', 'Effectif']
tab['Fréquence'] = tab['Effectif'] / len(df_web_erp)

# Calcul des fréquences cumulées
tab = tab.sort_values('Classe')
tab['Fréquence Cumulée'] = tab['Fréquence'].cumsum()

print(tab)
```

```
               Classe  Effectif  Fréquence  Fréquence Cumulée
0     (5.199, 29.622]       441   0.618513           0.618513
1    (29.622, 54.044]       158   0.221599           0.840112
2    (54.044, 78.467]        77   0.107994           0.948107
4   (78.467, 102.889]        14   0.019635           0.967742
3  (102.889, 127.311]        15   0.021038           0.988780
6  (127.311, 151.733]         2   0.002805           0.991585
5  (151.733, 176.156]         3   0.004208           0.995792
8  (176.156, 200.578]         1   0.001403           0.997195
7    (200.578, 225.0]         2   0.002805           1.000000
```

4.1.3 Identification avec le z-score 'price'

In [84]:
```
# Calcul de la moyenne et de l'écart-type du prix
moyenne_prix = df_web_erp['price'].mean()
ecart_type_prix = df_web_erp['price'].std()

# Calcul du Z-score pour chaque prix
# Z-score = (valeur - moyenne) / écart-type
df_web_erp['z_score'] = (df_web_erp['price'] - moyenne_prix) / ecart_type_prix

# Prix avec un Z-score supérieur à 3
prix_zscore_sup3 = df_web_erp[df_web_erp['z_score'] > 3]['price']

print(prix_zscore_sup3)
```

```
199    225.0
218    176.0
221    157.0
381    137.0
425    217.5
510    124.8
552    175.0
586    191.3
602    122.0
641    135.0
647    116.4
653    121.0
656    121.0
Name: price, dtype: float64
```

4.1.4 Identification par l'interval interquartile 'price'

In [85]:
```
#Supprimer les colonnes  guid  post_type  classe_price  z_score du df_web_erp
df_web_erp1 = df_web_erp.drop(columns=['guid','post_type','classe_price','z_score'])
```

In [86]:
```
# Définir les seuils pour les outliers
Q3, Q1 = np.percentile(df_web_erp1['price'], [75, 25])
iqr = Q3 - Q1
seuil_bas = Q1 - 1.5 * iqr
seuil_haut = Q3 + 1.5 * iqr

# Identifier les outliers
outliers = df_web_erp1[df_web_erp1['price'] > seuil_haut]

# Analyser les outliers
nombre_outliers = outliers.shape[0]
proportion_outliers = round(nombre_outliers / df_web_erp.shape[0],2)

print(seuil_bas,seuil_haut)
print(f"Nombre d'outliers: {nombre_outliers}")
print(f"Proportion d'outliers: {proportion_outliers}")
```

```
-28.025000000000002 84.17500000000001
Nombre d'outliers: 31
Proportion d'outliers: 0.04
```

In [87]:
```
fig = px.pie(values=[0.04, 99.96], names=['Proportion des valeurs outliners', 'Reste du catalogue'],
             title='Proportion des valeurs price outliners')

fig.show()
```

In [88]:
```
# Filtrage des lignes outliers

# Définir la largeur maximale des colonnes sur None pour afficher tout le texte
pd.set_option('display.max_colwidth', None)

outliers
```

Out[88]:

	id_web	product_id	onsale_web	price	stock_quantity	stock_status	purchase_price	total_sales	product_type	post_title
63	15382	4115	1	100.0	12	instock	52.70	1.0	Vin	Zind-Humbrecht Riesling Grand Cru Rangen De Thann Clos Saint-Urbain 2017
65	11668	4132	1	88.4	7	instock	44.30	5.0	Vin	Zind-Humbrecht Pinot Gris Grand Cru Rangen De Thann Clos Saint-Urbain 2012
199	15940	4352	0	225.0	0	outofstock	137.81	11.0	Champagne	Champagne Egly-Ouriet Grand Cru Millésimé 2008
205	13853	4359	1	85.6	112	instock	51.93	7.0	Champagne	Champagne Larmandier-Bernier Grand Cru Les Chemins d'Avize 2011
218	3510	4402	1	176.0	11	instock	78.25	3.0	Cognac	Cognac Frapin VIP XO
219	3507	4404	1	108.5	17	instock	52.22	4.0	Cognac	Cognac Frapin Château de Fontpinot XO
221	7819	4406	1	157.0	12	instock	69.08	4.0	Cognac	Cognac Frapin Château de Fontpinot 1989 20 Ans d'Age
222	3509	4407	1	104.0	14	instock	46.71	5.0	Cognac	Cognac Frapin Cigar Blend
227	12857	4582	1	109.6	18	instock	53.80	1.0	Vin	Château de Meursault Puligny-Montrachet 1er Cru Champ Canet 2014
380	14805	4903	1	102.3	12	instock	51.80	2.0	Vin	Domaine Des Croix Corton Grand Cru Les Grèves 2017
381	14220	4904	1	137.0	9	instock	67.95	3.0	Vin	Domaine Des Croix Corton Charlemagne Grand Cru 2016
425	14581	5001	1	217.5	18	instock	116.87	2.0	Vin	David Duband Charmes-Chambertin Grand Cru 2014
430	12791	5007	1	105.0	15	instock	55.88	3.0	Vin	Domaine des Comtes Lafon Volnay 1er Cru Santenots du Milieu 2014
431	11602	5008	1	105.0	12	instock	56.42	7.0	Vin	Domaine des Comtes Lafon Volnay 1er Cru Santenots du Milieu 2013
436	13914	5025	1	112.0	136	instock	68.60	6.0	Champagne	Champagne Agrapart & Fils L'Avizoise Extra Brut Blanc de Blancs Grand Cru 2012
437	13913	5026	1	86.8	101	instock	50.13	9.0	Champagne	Champagne Agrapart & Fils Minéral Extra Brut Blanc de Blancs Grand Cru 2012
501	19822	5565	0	92.0	0	outofstock	46.11	1.0	Vin	Tempier Bandol Cabassaou 2017
510	14915	5612	1	124.8	19	instock	66.41	1.0	Vin	Domaine Weinbach Gewurztraminer Grand Cru Furstentum SGN 2010 1/2
552	15185	5767	1	175.0	12	instock	90.42	4.0	Vin	Camille Giroud Clos de Vougeot 2016
586	14983	5892	1	191.3	98	instock	116.06	6.0	Champagne	Coteaux Champenois Egly-Ouriet Ambonnay Rouge 2016
601	14774	5916	1	93.0	1	instock	40.49	1.0	Whisky	Wemyss Malts Single Cask Scotch Whisky Chocolate Moka Cake 2005 Strathclyde
602	14775	5917	1	122.0	12	instock	54.24	3.0	Whisky	Wemyss Malts Single Cask Scotch Whisky Choc 'n' Nut Pretzel 2001 Bunnahabhain
603	14773	5918	1	114.0	12	instock	52.25	3.0	Whisky	Wemyss Malts Single Cask Scotch Whisky Chai Caramel Latte 2002 Craigellachie
641	14923	6126	1	135.0	138	instock	80.33	5.0	Champagne	Champagne Gosset Célébris Vintage 2007
646	14596	6201	1	105.6	16	instock	57.29	6.0	Vin	David Duband Chambolle-Musigny 1er Cru Les Sentiers 2016
647	15126	6202	1	116.4	12	instock	63.15	5.0	Vin	Domaine Clerget Echezeaux Grand Cru En Orveaux 2015
652	13996	6212	1	115.0	16	instock	59.42	7.0	Vin	Domaine des Comtes Lafon Volnay 1er Cru Santenots du Milieu 2015
653	15072	6213	1	121.0	9	instock	63.14	3.0	Vin	Domaine des Comtes Lafon Volnay 1er Cru Santenots du Milieu 2016
654	11601	6214	1	99.0	9	instock	49.62	6.0	Vin	Domaine des Comtes Lafon Volnay 1er Cru Champans 2013
655	12790	6215	1	115.0	14	instock	56.45	4.0	Vin	Domaine des Comtes Lafon Volnay 1er Cru Champans 2014
656	15070	6216	1	121.0	14	instock	60.02	2.0	Vin	Domaine des Comtes Lafon Volnay 1er Cru Champans 2016

In [89]:
```
# Il s'agit de grand cru donc les valeurs outlier prix peuvent etre justifier.

# L'écart de prix entre le prix d'achat et le prix de ventre semble choérant.
```

In [90]:
```
#Création du df_web_erp2 sans les lignes outliers

df_web_erp2 = df_web_erp[~df_web_erp['product_id'].isin(outliers['product_id'])]
```

Etape 5 - Calcul et analyse du CA et de la marge. Analyses complémentaire des quantités vendues et des stocks

5.1 - Analyse des ventes en CA

5.1.1 Calculer le CA su site web

In [91]:
```
# Exclusion des 4 lignes avec des prix d'achat par rapport au prix de ventes qui supposent des valeurs abérantes
df_web_erp = df_web_erp[~df_web_erp['product_id'].isin([4355, 4864, 6324, 7196])]
```

In [92]:
```
# Création de la colonne calculant le CA par article
df_web_erp['ca_par_article'] = df_web_erp['price'] * df_web_erp['total_sales']

# Calcul de la somme de la colonne "ca_par_article"
ca_total_site_web = df_web_erp['ca_par_article'].sum()

print("Le chiffre d'affaires total du site web est de :",round(ca_total_site_web,2),"€ du 1 octobre au 31 octobre.")
```

```
Le chiffre d'affaires total du site web est de : 143505.1 € du 1 octobre au 31 octobre.
```

In [93]:
```
# Dans le datafram sous outliers

# Création de la colonne calculant le CA par article
df_web_erp2['ca_par_article'] = df_web_erp2['price'] * df_web_erp2['total_sales']

# Calcul de la somme de la colonne "ca_par_article"
ca_total_site_web2 = df_web_erp2['ca_par_article'].sum()

print("Le chiffre d'affaires total du site web est de :",round(ca_total_site_web2,2),"€ du 1 octobre au 31 octobre.")
```

```
Le chiffre d'affaires total du site web est de : 126895.3 € du 1 octobre au 31 octobre.
```

In [94]:
```
#Proportion du chiffre d'affaire ou les valeurs outliners ne sont pas présentes :

CAoutliner = ( (143505 - 126895)  / 143505 ) * 100

print(round(CAoutliner,1),'%')
```

```
11.6 %
```

In [95]:
```
fig = px.pie(values=[11.57, 88.43], names=['Proportion du C.A ou les valeurs outliners ne sont pas présentes', 'Reste du catalogue'],
             title='Proportion du C.A des valeurs price outliners')

fig.show()
```

5.1.2 Palmares des articles en CA

In [96]:
```
import plotly.express as px

# 1. Trier le DataFrame dans l'ordre décroissant du CA
df_web_erp_sorted = df_web_erp.sort_values(by='ca_par_article', ascending=False)

# 2. Réinitialiser l'index du DataFrame
df_web_erp_sorted.reset_index(drop=True, inplace=True)

# 3. Sélectionner les 20 premiers articles
top_20_ca = df_web_erp_sorted.head(20)

# 4. Créer un graphique en barre des 20 premiers articles par CA
fig = px.bar(top_20_ca, x='post_title', y='ca_par_article',
             title="Top 20 des articles par chiffre d'affaires",
             labels={'post_title': "Titre de l'article", 'ca_par_article': "Chiffre d'affaires"},
             color='ca_par_article',  # Optionnel: colorier les barres par valeur de CA
             height=600)
fig.update_layout(xaxis_title="Article",
                  yaxis_title="Chiffre d'affaires",
                  xaxis={'categoryorder':'total descending'})
fig.show()
```

5.1.3 Calculer le 20 / 80 en CA

In [97]:
```
# 1. Créer une colonne calculant la part du CA de la ligne dans le dataset
ca_total = df_web_erp['ca_par_article'].sum()
df_web_erp['part_ca'] = df_web_erp['ca_par_article'] / ca_total

# 2. Créer une colonne réalisant la somme cumulative de la part du CA
df_web_erp['cumulative_part_ca'] = df_web_erp['part_ca'].cumsum()

# 3. Calculer le nombre d'articles représentant 80% du CA
# Trouver l'indice de la première occurrence où la somme cumulative dépasse 80%
nombre_articles_80pc_ca = df_web_erp[df_web_erp['cumulative_part_ca'] <= 0.80].shape[0]

# 4. Afficher la proportion que représentent ce groupe d'articles dans le catalogue entier
proportion_catalogue = ( nombre_articles_80pc_ca / df_web_erp.shape[0] ) *100
```

```
print("Nombre d'articles représentant 80% du CA :",nombre_articles_80pc_ca)
print("Proportion des articles représentant 80% du CA :",round(proportion_catalogue,2),"%")
```

```
Nombre d'articles représentant 80% du CA : 588
Proportion des articles représentant 80% du CA : 82.58 %
```

In [98]:
```
fig = px.pie(values=[82.61, 17.39], names=['589 articles représentant 80% du C.A', 'Reste des articles du catalogue 20% du C.A'],
             title='Proportion du C.A')

fig.show()
```

In [ ]:

5.2 - Analyse des quantités vendus

5.2.1 Palmares des articles en quantité vendus

In [99]:
```
# Trier df_merge dans l'ordre décroissant de quantités vendues
df_web_erp_trié = df_web_erp.sort_values('total_sales', ascending=False)

# Réinitialiser l'index du DataFrame après le tri
df_web_erp_trié.reset_index(drop=True, inplace=True)

# Sélectionner les 20 premiers articles
top_20_articles =df_web_erp_trié.head(20)

import plotly.express as px

# Générer le graphique en barre pour les 20 premiers articles
fig = px.bar(top_20_articles, x='post_title', y='total_sales',
             title="Top 20 des articles par quantités vendues",
             labels={'post_title': '', 'total_sales': 'Quantités Vendues'},
             color='total_sales')

fig.show()
```

5.1.2 Calculer le 20 / 80 ventes en quantité

In [100…
```
# Total des ventes en quantité pour tout le site
total_quantite_ventes = df_web_erp['total_sales'].sum()

# Part en quantité de chaque article
df_web_erp['part_quantite'] = df_web_erp['total_sales'] / total_quantite_ventes

# Calcul de la somme cumulative de la part en quantité
df_web_erp['cumulative_part_quantite'] = df_web_erp['part_quantite'].cumsum()

# Identifier le seuil où 80% des ventes sont atteintes
seuil_80 = df_web_erp[df_web_erp['cumulative_part_quantite'] <= 0.80]

# Calculer le nombre d'articles nécessaires pour atteindre ce seuil
nombre_articles_80pc_ventes = seuil_80.shape[0]

# Calculer la proportion de ces articles dans le catalogue entier
proportion_catalogue = nombre_articles_80pc_ventes / df_web_erp.shape[0]

print(f"Nombre d'articles représentant 80% des quantitées vendus : {nombre_articles_80pc_ventes}")
print(f"Proportion de ces articles représentant 80% des quantitées vendus : {proportion_catalogue:.2%}")
```

```
Nombre d'articles représentant 80% des quantitées vendus : 558
Proportion de ces articles représentant 80% des quantitées vendus : 78.37%
```

In [101…
```
fig = px.pie(values=[78.40, 21.60], names=["Proportion des articles représentant 80% des quantitées vendus ", 'Proportion des articles représentant 20% des quantitées
             title="Proportion des articles représentant 80% des quantitées vendus")

fig.show()
```

5.3 - Analyse des stocks

5.3.1 Estimation de la durée du stock

In [102…
```
# "Concernant les données, c'est une extraction au 31 octobre et pour les ventes c'est du 1 octobre au 31 octobre."
# Nicolas
# Responsable vente chez Bottleneck
```

In [103…
```
df_web_erp
```

Out[103…

	id_web	product_id	onsale_web	price	stock_quantity	stock_status	purchase_price	total_sales	product_type	post_title	guid	post_type	classe_pri
0	15298	3847	1	24.2	16	instock	12.88	6.0	Vin	Pierre Jean Villa Saint-Joseph Préface 2018	https://www.bottle-neck.fr/?post_type=product&p=3847	product	(5.19 29.62
1	15296	3849	1	34.3	10	instock	17.54	9.0	Vin	Pierre Jean Villa Saint-Joseph Rouge Tildé 2017	https://www.bottle-neck.fr/?post_type=product&p=3849	product	(29.62 54.04
2	15300	3850	0	20.8	0	outofstock	10.64	0.0	Vin	Pierre Jean Villa Crozes-Hermitage Accroche Coeur 2018	https://www.bottle-neck.fr/?post_type=product&p=3850	product	(5.19 29.62
3	19814	4032	1	14.1	26	instock	6.92	12.0	Vin	Pierre Jean Villa IGP Collines Rhodaniennes Gamine 2018	https://www.bottle-neck.fr/?post_type=product&p=4032	product	(5.19 29.62
4	19815	4039	1	46.0	3	instock	23.77	3.0	Vin	Pierre Jean Villa Côte Rôtie Carmina 2017	https://www.bottle-neck.fr/?post_type=product&p=4039	product	(29.62 54.04
...	...	...	...	...	...	...	...	...	...	...	...	...	
708	16135	6930	1	8.4	28	instock	4.34	9.0	Vin	Mouthes Le Bihan Côtes de Duras L'Aimé Chai 2015	https://www.bottle-neck.fr/?post_type=product&p=6930	product	(5.19 29.62
709	15891	7023	1	27.5	23	instock	14.21	9.0	Vin	Camin Larredya Jurançon Sec La Virada 2018	https://www.bottle-neck.fr/?post_type=product&p=7023	product	(5.19 29.62
710	15887	7025	1	69.0	8	instock	34.22	5.0	Vin	Domaine Jamet Côte Rôtie Fructus Voluptas 2018	https://www.bottle-neck.fr/?post_type=product&p=7025	product	(54.04 78.46
711	13127-1	7247	1	54.8	6	instock	27.18	4.0	Vin	Clos du Mont-Olivet Châteauneuf-du-Pape 2007	https://www.bottle-neck.fr/?post_type=product&p=7247	product	(54.04 78.46
712	16230	7338	1	16.3	40	instock	8.00	13.0	Vin	Domaine Saint-Nicolas Vin de France Blanc Les Clous 2019	https://www.bottle-neck.fr/?post_type=product&p=7338	product	(5.19 29.62

712 rows × 19 columns

In [104…

```
#Calculer la rotation de stock

# Calcul du CMV pour chaque ligne
df_web_erp['cmv'] = df_web_erp['purchase_price'] * df_web_erp['total_sales']

# Calcul de la valeur du stock pour chaque ligne
df_web_erp['stock_value'] = df_web_erp['stock_quantity'] * df_web_erp['purchase_price']

# Calcul du CMV total et de la valeur totale du stock
cmv_total = df_web_erp['cmv'].sum()
stock_value_total = df_web_erp['stock_value'].sum()

# Calcul de la rotation des stocks pour l'ensemble des produits
stock_rotation_total = cmv_total / stock_value_total

print(f"Rotation des Stocks Totale: {stock_rotation_total:.2f}")
```

```
Rotation des Stocks Totale: 0.28
```

In [105…

```
# Conclusion :

# Une rotation des stocks de 0,28 signifie que pour la période étudiée, l'entreprise n'a pas vendu la totalité de son stock moyen; elle n'a vendu que 28% de celui-ci.

# Un nombre inférieur à 1 suggère que la rotation des stocks est lente. Cela peut indiquer que le stock est en surabondance ou que la demande pour les produits est plus
```

In [106…

```
# Calcul de la rotation des stocks pour chaque article
# Vérifier si 'stock_value' est zéro et traiter ces cas pour éviter la division par zéro
df_web_erp['stock_rotation_per_item'] = df_web_erp.apply(
    lambda row: row['cmv'] / row['stock_value'] if row['stock_value'] != 0 else 0,
    axis=1
)
```

In [107…

```
# Sélection du Flop 20 des produits ayant la rotation de stock les plus importantes

df_web_erp.sort_values(by='stock_rotation_per_item', ascending=False, inplace=True)
flop_20_rotation_stock = df_web_erp[['stock_rotation_per_item','post_title']].head(20)

flop_20_rotation_stock
```

Out[107…

	stock_rotation_per_item	post_title
599	1.428571	Darnley's London Dry Gin Original
357	1.000000	Domaine Peyre Rose Clos des Cistes 2008
208	1.000000	Wemyss Malts Blended Malt Scotch Whisky Spice King
257	1.000000	Marcel Windholtz Eau de Vie de Coing
254	1.000000	Marcel Windholtz Eau de Vie de Poire Williams Réserve Particulière
695	1.000000	Catherine et Claude Maréchal Pommard La Chanière 2017
504	1.000000	Domaine Huet Vouvray Le Mont Moelleux Première Trie 2008
236	1.000000	Catherine et Claude Maréchal Savigny-Lès-Beaune Rouge 2016
68	1.000000	Zind-Humbrecht Gewurztraminer Grand Cru Rangen De Thann Clos Saint-Urbain 2013
689	1.000000	Weingut Besson-Strasser Zürich Fumé 2017
188	1.000000	Domaine de La Tour Du Bon Bandol Rouge En Sol 2017
269	1.000000	Thierry Germain Saumur Blanc Terres 2014
566	1.000000	Château Carbonnieux Graves Blanc 2017
157	1.000000	Domaine Huet Vouvray Le Clos du Bourg Moelleux Première Trie 2008
595	1.000000	Domaine de Montbourgeau L'Etoile Vin Jaune 2009
600	1.000000	Darnley's London Dry Gin Spiced
601	1.000000	Wemyss Malts Single Cask Scotch Whisky Chocolate Moka Cake 2005 Strathclyde
604	1.000000	Albert Mann Pinot Noir Clos de la Faille 2017
258	1.000000	Marcel Windholtz Eau de Vie de Baie de Houx
230	1.000000	Marc Colin Et Fils Saint-Aubin Blanc En Montceau 2017

In [108…

```
# Graphique en barre avec Plotly Express
import plotly.express as px
fig = px.bar(flop_20_rotation_stock, x='post_title', y='stock_rotation_per_item',
             title="Flop 20 des produits avec la rotation de stock la plus importante",
             labels={'post_title': "Article", 'stock_rotation_per_item': "rotation de stocks"},
             height=600)
fig.show()
```

In [109…

```
# Estimation de la durée du stock

# Correction avant division pour éviter division par zéro et gérer les NaN
df_web_erp['vente_quotidienne_moyenne'] = df_web_erp.apply(lambda x: x['total_sales'] / 31 if pd.notna(x['total_sales']) and x['total_sales'] > 0 else 0, axis=1)

# Calcul de 'duree_stock_jours'
df_web_erp['duree_stock_jours'] = df_web_erp.apply(lambda x: x['stock_quantity'] / x['vente_quotidienne_moyenne'] if pd.notna(x['vente_quotidienne_moyenne']) and x['ve

# Identifier les 20 produits avec la plus longue durée de stock
df_web_erp.sort_values(by='duree_stock_jours', ascending=False, inplace=True)

# Affichage des résultats
df_web_erp[['stock_quantity', 'total_sales', 'duree_stock_jours', 'post_title']].head(20)
```

Out[109…

	stock_quantity	total_sales	duree_stock_jours	post_title
70	125	4.0	968.750000	Champagne Gosset Grand Millésime 2006
641	138	5.0	855.600000	Champagne Gosset Célébris Vintage 2007
202	81	3.0	837.000000	Champagne Egly-Ouriet Premier Cru Les Vignes de Vrigny
197	125	5.0	775.000000	Champagne Egly-Ouriet Grand Cru Brut Tradition
74	71	3.0	733.666667	Champagne Mailly Grand Cru Brut Rosé
203	115	5.0	713.000000	Champagne Larmandier-Bernier Latitude
71	91	4.0	705.250000	Champagne Gosset Grand Rosé
436	136	6.0	702.666667	Champagne Agrapart & Fils L'Avizoise Extra Brut Blanc de Blancs Grand Cru 2012
198	145	7.0	642.142857	Champagne Egly-Ouriet Grand Cru Extra Brut V.P.
76	123	6.0	635.500000	Champagne Mailly Grand Cru Intemporelle 2010
194	142	7.0	628.857143	Champagne Gosset Grand Blanc de Blancs
75	101	5.0	626.200000	Champagne Mailly Grand Cru Intemporelle Rosé 2009
510	19	1.0	589.000000	Domaine Weinbach Gewurztraminer Grand Cru Furstentum SGN 2010 1/2
227	18	1.0	558.000000	Château de Meursault Puligny-Montrachet 1er Cru Champ Canet 2014
435	103	6.0	532.166667	Champagne Agrapart & Fils Les 7 Crus Brut Blanc de Blancs
414	100	6.0	516.666667	Champagne Larmandier-Bernier Terre de Vertus Premier Cru 2011
586	98	6.0	506.333333	Coteaux Champenois Egly-Ouriet Ambonnay Rouge 2016
205	112	7.0	496.000000	Champagne Larmandier-Bernier Grand Cru Les Chemins d'Avize 2011
69	123	8.0	476.625000	Champagne Gosset Grande Réserve
72	86	6.0	444.333333	Champagne Mailly Grand Cru Brut Réserve

In [110…

```
# Sélection du Flop 20 des produits ayant la plus longue durée de stock
flop_20_duree_stock = df_web_erp[['duree_stock_jours','post_title']].head(20)

# Graphique en barre avec Plotly Express
import plotly.express as px
fig = px.bar(flop_20_duree_stock, x='post_title', y='duree_stock_jours',
             title="Flop 20 des produits avec la plus longue durée de stock éstimée",
             labels={'post_title': "Produit", 'duree_stock_jours': "Durée du stock (jours)"},
```

```
            height=600)
fig.show()
```

5.3.2 Valorisation des stocks en euros

In [111…

```
print("La somme totale de la valorisation des stocks en euros est de :", stock_value_total, "€")
```

```
La somme totale de la valorisation des stocks en euros est de : 269506.61 €
```

5.3.3 Nombre de produit en stock

In [112…

```
ProduitsEnStock = df_web_erp['stock_quantity'].sum()
print("ProduitsEnStock")
```

```
ProduitsEnStock
```

5.4 -Analyse du taux de marge

5.4.1 Création du taux de marge

In [113…

```
taux_taxe = 0.20  # 20%


# Création de la colonne 'prix HT'
df_web_erp['prix_HT'] = df_web_erp['price'] / (1 + taux_taxe)

# Création de la colonne "Taux de marge"
# Taux de marge=((Prix HT – Prix d'achat) / Prix HT ) ×100

df_web_erp['Taux de marge'] = ((df_web_erp['prix_HT'] - df_web_erp['purchase_price']) / df_web_erp['prix_HT']) * 100

print("Le taux de marge minimum est :",round(df_web_erp['Taux de marge'].min(),2),"%")
print("Le taux de marge maximum est :",round(df_web_erp['Taux de marge'].max(),2),"%")
```

```
Le taux de marge minimum est : 22.78 %
Le taux de marge maximum est : 47.76 %
```

In [114…

```
#Affichier Taux de marge inférieurs à 0 :

df_web_erp[df_web_erp['Taux de marge'] < 0]
```

Out[114…

id_web	product_id	onsale_web	price	stock_quantity	stock_status	purchase_price	total_sales	product_type	post_title	guid	post_type	classe_price	z_score	ca_par_article	part_ca

In [115…

```
# Il s'agit des lignes stockées précedament dans la variable VenteAPerte
```

5.4.2 Analyse du taux de marge

In [116…

```
# Affichage du nombres totales de références pour chaque type de produit :
product_type_info = df_web_erp['product_type'].value_counts()
product_type_info
```

Out[116…

```
product_type
Vin              658
Champagne         27
Whisky            14
Cognac             8
Huile d'olive      3
Gin                2
Name: count, dtype: int64
```

In [117…

```
# Calcul du taux de marge moyen par type de produit
df_marge_moyenne_par_type = df_web_erp.groupby('product_type')['Taux de marge'].mean().reset_index()

print(df_marge_moyenne_par_type)
```

```
   product_type  Taux de marge
0     Champagne      28.488539
1        Cognac      45.067614
2           Gin      42.800000
3  Huile d'olive      24.998198
4           Vin      38.012262
5        Whisky      44.918865
```

In [118…

```
fig = px.bar(df_marge_moyenne_par_type, x='product_type', y='Taux de marge',
             title="Taux de marge moyen par type de produit",
             labels={'product_type': 'Type de Produit', 'Taux de marge': 'Taux de Marge (%)'},
             color='Taux de marge', barmode='group')

fig.update_layout(xaxis_title="Type de Produit",
                  yaxis_title="Taux de Marge (%)",
                  xaxis={'categoryorder':'total descending'})

fig.show()
```

In [119…

```
# Suppression des colonnes inultiles à l'analyse de corréllation :
df_web_erp = df_web_erp.drop(columns=['prix_HT','Taux de marge','purchase_price','z_score','cumulative_part_ca', 'ca_par_article','part_quantite', 'cumulative_part_qua
```

Etape 6 - Analyse bivarié et études des corrélations

In [120…

```
############################
# Analyse des correlations #
############################

#Création d'un heatmap de correlation avec les variables stock, sales et price
#on peut également créer un mask pour n'afficher qu'une demi heatmap

# Selection des colonnes numeric pour le calcul de correlation
df_numeric = df_web_erp.select_dtypes(include=[np.number])

# Calcul de la matrice de corrélation
corr = df_numeric.corr()

# Création d'un mask pour n'afficher que la partie supérieure de la heatmap
mask = np.triu(np.ones_like(corr, dtype=bool))

# Configuration de la heatmap
sns.set_theme(style="white")

# Dessin de la heatmap avec le mask et le ratio d'aspect correct
plt.figure(figsize=(10,8))
sns.heatmap(corr, mask=mask, cmap="coolwarm", vmax=.3, center=0,
            square=True, linewidths=.5, cbar_kws={"shrink": .5}, annot=True)

plt.show()
```

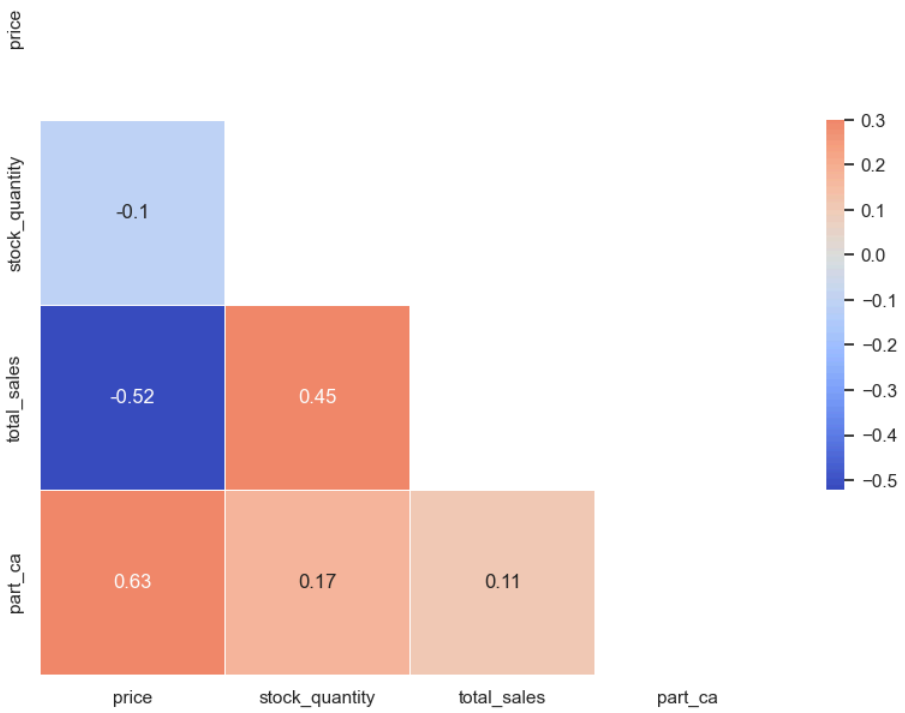

In [121…

```
import plotly.express as px

# Tracé d'un nuage de points entre 'price' et 'CA'.
fig = px.scatter(df_web_erp, x='price', y='part_ca', title='Nuage de points entre Prix et Chiffre d\'Affaires')

# Affichage du graphique.
fig.show()
```

In [122…

```
import plotly.express as px

# Tracé d'un nuage de points entre 'price' et 'CA'.
fig = px.scatter(df_web_erp, x='price', y='total_sales', title='Nuage de points entre le prix et les quantités vendues')

# Affichage du graphique.
fig.show()
```