[17/02/25]

[ZBAKH Jason]

DATA ANALYST

bottleneck
fine wine spirit

Optimisez la gestion des données d'une boutique avec Python

Présentation des datasets

- L'extraction du site Web comportant les codes SKU, les quantités vendues, et la description des produits.

- Table de liaison qui permet de lier la base de données du site web à l'extraction de l'ERP de l'entreprise.

- L'extraction du logiciel ERP comprenant les codes produits, les prix de vente et les prix d'achat, ainsi que l'état du stock.

Analyses Exploratoires des Données

— *df_erp*

```python
#Affichier les prix inférieurs à 0
print("Prix inférieurs à 0:\n", df_erp[df_erp['price'] < 0])
```

✓ 0.0s

```
Prix inférieurs à 0:
     product_id onsale_web  price  stock_quantity stock_status  purchase_price
151        4233          0  -20.0               0   outofstock           10.33
469        5017          0   -8.0               0   outofstock            4.34
739        6594          0   -9.1              19      instock            4.61
```

3 références avec des erreurs de saisie des prix de vente.

Erreur de type pour les variables product_id et onsale_web : int64 -> object.

Identification de 65 références de produits en stock qui ne sont pas en vente sur le site web.

```python
#Affichier les stocks inférieurs à 0
print("Stocks inférieurs à 0:\n", df_erp[df_erp['stock_quantity'] < 0])
```

✓ 0.0s

```
Stocks inférieurs à 0:
     product_id onsale_web  price  stock_quantity stock_status  purchase_price
449        4973          0   10.0             -10   outofstock            4.96
573        5700          1   44.5              -1   outofstock           22.30
```

2 références avec des valeurs stocks négatives

Identification de 4 références de produits vendus à perte.

	product_id	onsale_web	price	stock_quantity	stock_status	purchase_price
210	4355	1	12.65	97	instock	77.48
391	4864	0	8.30	0	outofstock	9.99
724	6324	0	92.00	18	instock	99.00
817	7196	0	31.00	55	instock	31.20

Reprogrammation de l'ERP pour signaler une erreur si une valeur négative est saisie.

Analyses Exploratoires des Données

— *df_liaison*

Erreur de type variables product_id et onsale_web :
int64 --> object

```
id_web      734 non-null    object
product_id  825 non-null    int64
```

```
df_liaison['product_id'] = df_liaison['product_id'].astype(object)
```

```
Data columns (total 2 columns):
 #   Column      Non-Null Count  Dtype
---  ------      --------------  -----
 0   id_web      734 non-null    object
 1   product_id  825 non-null    object
dtypes: object(2)
```

```
df_liaison.describe(include='all')
```

	id_web	product_id
count	734	825
unique	734	825
top	15298	3847
freq	1	1

Identification de 91 références produits avec un id_web manquants

Analyses Exploratoires des Données
— *df_web_produits*

Identification de 88 codes SKUne respectant pas la codification en cinq chiffres.

```
df_web_produits = df_web_produits[df_web_produits['id_web'] != 'bon-cadeau-25-euros']
```

Identification 85 références produits sans code sku

Renommer la colonne 'sku' en 'id_web'

"Filtre 'post_type' = 'product' Le dataframe 'df_web' contient 716 produits.

Afin d'éviter la redondance des données, il faudrait scinder la table en deux tables distinctes."

```
Index: 716 entries, 2 to 1509
Data columns (total 6 columns):
 #   Column        Non-Null Count  Dtype
---  ------        --------------  -----
 0   sku           716 non-null    object
 1   total_sales   716 non-null    float64
 2   product_type  715 non-null    object
 3   post_title    716 non-null    object
 4   guid          716 non-null    object
 5   post_type     716 non-null    object
dtypes: float64(1), object(5)
```

```
#Affichier Total des ventes inférieurs à 0 :

df_web_produits[df_web_produits['total_sales'] < 0]
```

✓ 0.0s

	sku	total_sales	product_type	post_title
1084	5075	-56.0	Vin	Pierre Jean Villa Condrieu Jardin Suspendu 2018
1087	5070	-17.0	Vin	Pierre Jean Villa Côte Rôtie Fongeant 2017

Identification de deux erreurs d'irrégularité : valeurs négatives dans le total des ventes.

Récupération de 2 codes id_product depuis le lien https

Ajout des références dans le df_liaison

id_web	product_id
5070	5070
5075	5075

Fusion ou consolidations des données

— *df_liaison et df_erp*

df_erp : 825 lignes, aucune valeurs manquantes.

df_liaison : 825 valeurs et 91 id_web sans correspondances

+ 2 id_web avec le code produit du lien https
id_web 736 non nulles.

erp + liaison = df_merge :

```
RangeIndex: 825 entries, 0 to 824
Data columns (total 7 columns):
 #   Column          Non-Null Count  Dtype
---  ------          --------------  -----
 0   id_web          736 non-null    object
 1   product_id      825 non-null    object
 2   onsale_web      825 non-null    object
 3   price           825 non-null    float64
 4   stock_quantity  825 non-null    int64
 5   stock_status    825 non-null    object
 6   purchase_price  825 non-null    float64
dtypes: float64(2), int64(1), object(4)
```

```
df_merge = pd.merge(df_liaison, df_erp,how="inner", on='product_id',validate='one_to_one')

df_merge.head(10)
```

0.0s

id_web	product_id	onsale_web	price	stock_quantity	stock_status	purchase_price
15298	3847	1	24.2	16	instock	12.88
15296	3849	1	34.3	10	instock	17.54
15300	3850	0	20.8	0	outofstock	10.64
19814	4032	1	14.1	26	instock	6.92
19815	4039	1	46.0	3	instock	23.77
15303	4040	1	34.3	12	instock	18.25
14975	4041	1	32.7	12	instock	17.57
16042	4042	1	31.2	15	instock	15.48
14980	4043	0	60.0	0	outofstock	29.45
16041	4045	1	42.6	5	instock	22.01

Fusion ou consolidations des données

— *df_merge et df_web_produits*

```
df_web_erp = pd.merge(df_merge, df_web_produits, on='id_web', how="inner")
```

df_web_erp

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 713 entries, 0 to 712
Data columns (total 12 columns):
 #   Column          Non-Null Count  Dtype
---  ------          --------------  -----
 0   id_web          713 non-null    object
 1   product_id      713 non-null    object
 2   onsale_web      713 non-null    object
 3   price           713 non-null    float64
 4   stock_quantity  713 non-null    int64
 5   stock_status    713 non-null    object
 6   purchase_price  713 non-null    float64
 7   total_sales     713 non-null    float64
 8   product_type    713 non-null    object
 9   post_title      713 non-null    object
 10  guid            713 non-null    object
 11  post_type       713 non-null    object
dtypes: float64(3), int64(1), object(8)
memory usage: 67.0+ KB
```

df_merge

```
RangeIndex: 825 entries, 0 to 824
Data columns (total 7 columns):
 #   Column          Non-Null Count  Dtype
---  ------          --------------  -----
 0   id_web          736 non-null    object
 1   product_id      825 non-null    object
 2   onsale_web      825 non-null    object
 3   price           825 non-null    float64
 4   stock_quantity  825 non-null    int64
 5   stock_status    825 non-null    object
 6   purchase_price  825 non-null    float64
dtypes: float64(2), int64(1), object(4)
```

Df_web_produits

```
Index: 715 entries, 2 to 1509
Data columns (total 6 columns):
 #   Column        Non-Null Count  Dtype
---  ------        --------------  -----
 0   id_web        715 non-null    object
 1   total_sales   715 non-null    float64
 2   product_type  715 non-null    object
 3   post_title    715 non-null    object
 4   guid          715 non-null    object
 5   post_type     715 non-null    object
```

df_merge : id_web 736 valeurs + df_web_produits : id_web 715 valeurs = df_wer_erp : 713 valeurs

Fusion ou consolidations des données — df_merge et df_web_produits

bottleneck
fine wine spirit

Identification des différences entre df_web_produits et df_web_erp :

```
# Fusionner les deux DataFrames avec un indicateur pour identifier les deux lignes manquantes apres le merge
merged_df = pd.merge(df_web_produits, df_web_erp, on=['id_web'], how='outer', indicator=True)

# Filtrer pour garder uniquement les lignes Qui n'ont pas été ajouté après le merge
diff_df = merged_df[merged_df['_merge'] == 'left_only'].drop(columns=['_merge'])
```

id_web	total_sales_x	product_type_x	post_title_x	guid_x	post_type_x	product_id	onsale_web	price	stock_quantity	stock_status	purchase_price
5070	17.0	Vin	Pierre Jean Villa Côte Rôtie Fongeant 2017	https://www.bottle-neck.fr/?post_type=product&...	product	NaN	NaN	NaN	NaN	NaN	NaN
5075	56.0	Vin	Pierre Jean Villa Condrieu Jardin	https://www.bottle-neck.fr/?post_type=product&...	product	NaN	NaN	NaN	NaN	NaN	NaN

```
# Verifier si les id_web 5075 et 5070 sont présent dans df_web_produits['id_web']

resultat = df_web_produits.loc[df_web_produits['id_web'].isin([5075, 5070])]

resultat
0.0s
```

id_web	total_sales	product_type	post_title	guid	post_type

Les id_web 5075 et 5070 ne sont pas présents dans df_web_produits :
Par conséquent, ils n'ont pas été ajoutés.

Ils ne présentent pas d'informations essentielles.

Différences entre df_merge et df_web_erp :

```
# Identification des id_web dans df_merge non présents dans df_web_produits
ids_non_presents = df_merge[~df_merge['id_web'].isin(df_web_produits['id_web'])]['id_web']
```

```
23 non-null      object
dtypes: object(1)
```

Les id_web du df_merge qui ne sont pas présents dans df_web_produits n'ont donc pas été ajoutés à df_web_erp.

Analyses univariées du prix
— Hstogramme

```
# Création de l'histogramme de répartition des prix


fig = px.histogram(df_web_erp, x='price', title='Distribution des prix')
fig.update_layout(bargap=0.2)

fig.show()
```
0.0s

Analyses univariées du prix
— Z-score et IQR (Interval interquartile)

Le z-score mesure à quel point un prix est éloigné de la moyenne des prix.

- Un z-score élevé indique que le prix est beaucoup plus haut que ce que l'on observe habituellement.

```python
# Calcul de la moyenne et de l'écart-type du prix
moyenne_prix = df_web_erp['price'].mean()
ecart_type_prix = df_web_erp['price'].std()

# Calcul du Z-score pour chaque prix
# Z-score = (valeur - moyenne) / écart-type
df_web_erp['z_score'] = (df_web_erp['price'] - moyenne_prix) / ecart_type_prix

# Prix avec un Z-score supérieur à 3
prix_zscore_sup3 = df_web_erp[df_web_erp['z_score'] > 3]['price']

print(prix_zscore_sup3)
```

✓ 0.0s

```
199    225.0
218    176.0
221    157.0
381    137.0
425    217.5
510    124.8
552    175.0
586    191.3
602    122.0
641    135.0
647    116.4
653    121.0
656    121.0
```

L'IQR mesure la différence entre le prix en dessous duquel se trouvent 25% des prix les plus bas et le prix en dessous duquel se situent 75% des prix.

En d'autres termes, il calcule l'écart entre le prix médian des 25% de prix inférieurs et celui des 75% de prix inférieurs

```python
# Définir les seuils pour les outliers
Q3, Q1 = np.percentile(df_web_erp['price'], [75, 25])
iqr = Q3 - Q1
seuil_bas = Q1 - 1.5 * iqr
seuil_haut = Q3 + 1.5 * iqr

# Identifier les outliers
outliers = df_web_erp[(df_web_erp['price'] < seuil_bas) | (df_web_erp['price'] > seuil_haut)]

# Analyser les outliers
nombre_outliers = outliers.shape[0]
proportion_outliers = nombre_outliers / df_web_erp.shape[0]

print(seuil_bas,seuil_haut)
print(f"Nombre d'outliers: {nombre_outliers}")
print(f"Proportion d'outliers: {proportion_outliers}")
```

✓ 0.0s

```
-28.025000000000002 84.17500000000001
Nombre d'outliers: 31
Proportion d'outliers: 0.043478260869565216
```

Analyses univariées du prix

Visualisation de l'interval interquartile

```
#Création d'une Boite à moustache de la répartition des prix
fig = px.box(df_web_erp, y='price', title='Répartition des prix')
fig.show()
```

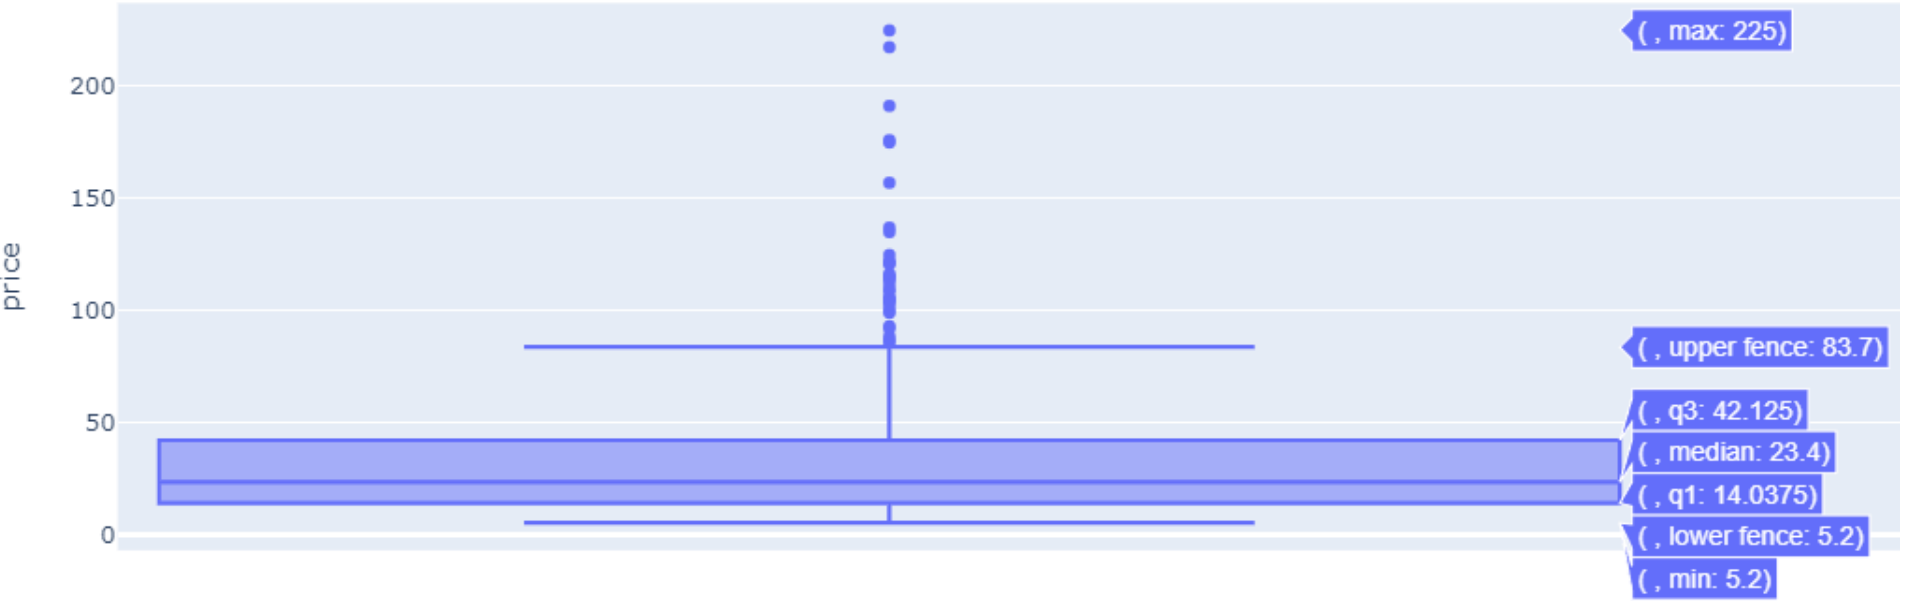

Analyses univariées du prix
— Affichage des outliers

id_web	product_id	onsale_web	price	stock_quantity	stock_status	purchase_price	total_sales	product_type	post_title
15382	4115	1	100.0	12	instock	52.70	1.0	Vin	Zind-Humbrecht Riesling Grand Cru Rangen De Thann Clos Saint-Urbain 2017
11668	4132	1	88.4	7	instock	44.30	5.0	Vin	Zind-Humbrecht Pinot Gris Grand Cru Rangen De Thann Clos Saint-Urbain 2012
15940	4352	0	225.0	0	outofstock	137.81	11.0	Champagne	Champagne Egly-Ouriet Grand Cru Millésimé 2008
13853	4359	1	85.6	112	instock	51.93	7.0	Champagne	Champagne Larmandier-Bernier Grand Cru Les Chemins d'Avize 2011
3510	4402	1	176.0	11	instock	78.25	3.0	Cognac	Cognac Frapin VIP XO
3507	4404	1	108.5	17	instock	52.22	4.0	Cognac	Cognac Frapin Château de Fontpinot XO
7819	4406	1	157.0	12	instock	69.08	4.0	Cognac	Cognac Frapin Château de Fontpinot 1989 20 Ans d'Age
3509	4407	1	104.0	14	instock	46.71	5.0	Cognac	Cognac Frapin Cigar Blend
12857	4582	1	109.6	18	instock	53.80	1.0	Vin	Château de Meursault Puligny-Montrachet 1er Cru Champ Canet 2014
14805	4903	1	102.3	12	instock	51.80	2.0	Vin	Domaine Des Croix Corton Grand Cru Les Grèves 2017
14220	4904	1	137.0	9	instock	67.95	3.0	Vin	Domaine Des Croix Corton Charlemagne Grand Cru 2016
14581	5001	1	217.5	18	instock	116.87	2.0	Vin	David Duband Charmes-Chambertin Grand Cru 2014
12791	5007	1	105.0	15	instock	55.88	3.0	Vin	Domaine des Comtes Lafon Volnay 1er Cru Santenots du Milieu 2014
11602	5008	1	105.0	12	instock	56.42	7.0	Vin	Domaine des Comtes Lafon Volnay 1er Cru Santenots du Milieu 2013
13914	5025	1	112.0	136	instock	68.60	6.0	Champagne	Champagne Agrapart & Fils L'Avizoise Extra Brut Blanc de Blancs Grand Cru 2012
13913	5026	1	86.8	101	instock	50.13	9.0	Champagne	Champagne Agrapart & Fils Minéral Extra Brut Blanc de Blancs Grand Cru 2012
19822	5565	0	92.0	0	outofstock	46.11	1.0	Vin	Tempier Bandol Cabassaou 2017
14915	5612	1	124.8	19	instock	66.41	1.0	Vin	Domaine Weinbach Gewurztraminer Grand Cru Furstentum SGN 2010 1/2
15185	5767	1	175.0	12	instock	90.42	4.0	Vin	Camille Giroud Clos de Vougeot 2016
14983	5892	1	191.3	98	instock	116.06	6.0	Champagne	Coteaux Champenois Egly-Ouriet Ambonnay Rouge 2016
14774	5916	1	93.0	1	instock	40.49	1.0	Whisky	Wemyss Malts Single Cask Scotch Whisky Chocolate Moka Cake 2005 Strathclyde
14775	5917	1	122.0	12	instock	54.24	3.0	Whisky	Wemyss Malts Single Cask Scotch Whisky Choc 'n' Nut Pretzel 2001 Bunnahabhain
14773	5918	1	114.0	12	instock	52.25	3.0	Whisky	Wemyss Malts Single Cask Scotch Whisky Chai Caramel Latte 2002 Craigellachie
14923	6126	1	135.0	138	instock	80.33	5.0	Champagne	Champagne Gosset Célébris Vintage 2007
14596	6201	1	105.6	16	instock	57.29	6.0	Vin	David Duband Chambolle-Musigny 1er Cru Les Sentiers 2016
15126	6202	1	116.4	12	instock	63.15	5.0	Vin	Domaine Clerget Echezeaux Grand Cru En Orveaux 2015
13996	6212	1	115.0	16	instock	59.42	7.0	Vin	Domaine des Comtes Lafon Volnay 1er Cru Santenots du Milieu 2015
15072	6213	1	121.0	9	instock	63.14	3.0	Vin	Domaine des Comtes Lafon Volnay 1er Cru Santenots du Milieu 2016
11601	6214	1	99.0	9	instock	49.62	6.0	Vin	Domaine des Comtes Lafon Volnay 1er Cru Champans 2013
12790	6215	1	115.0	14	instock	56.45	4.0	Vin	Domaine des Comtes Lafon Volnay 1er Cru Champans 2014
15070	6216	1	121.0	14	instock	60.02	2.0	Vin	Domaine des Comtes Lafon Volnay 1er Cru Champans 2016

Analyses complémentaires — C.A

```
# Exclusion des 4 lignes avec des taux de marge négatif
df_web_erp_filtered = df_web_erp[~df_web_erp['product_id'].isin([4355, 4864, 6324, 7196])]
```

Le chiffre d'affaires total est de :143 505 .09 € (du 1 octobre au 31 octobre)

Le chiffre d'affaires total outliers exclut : 126 895.€

```
Nombre d'articles représentant 80% du CA : 589
Proportion de ces articles dans le catalogue entier : 82.61 %
```

Proportion du C.A

Proportion des valeurs price outliners

Proportion du C.A des valeurs price outliners

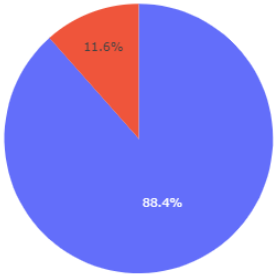

Analyses complémentaires
CA

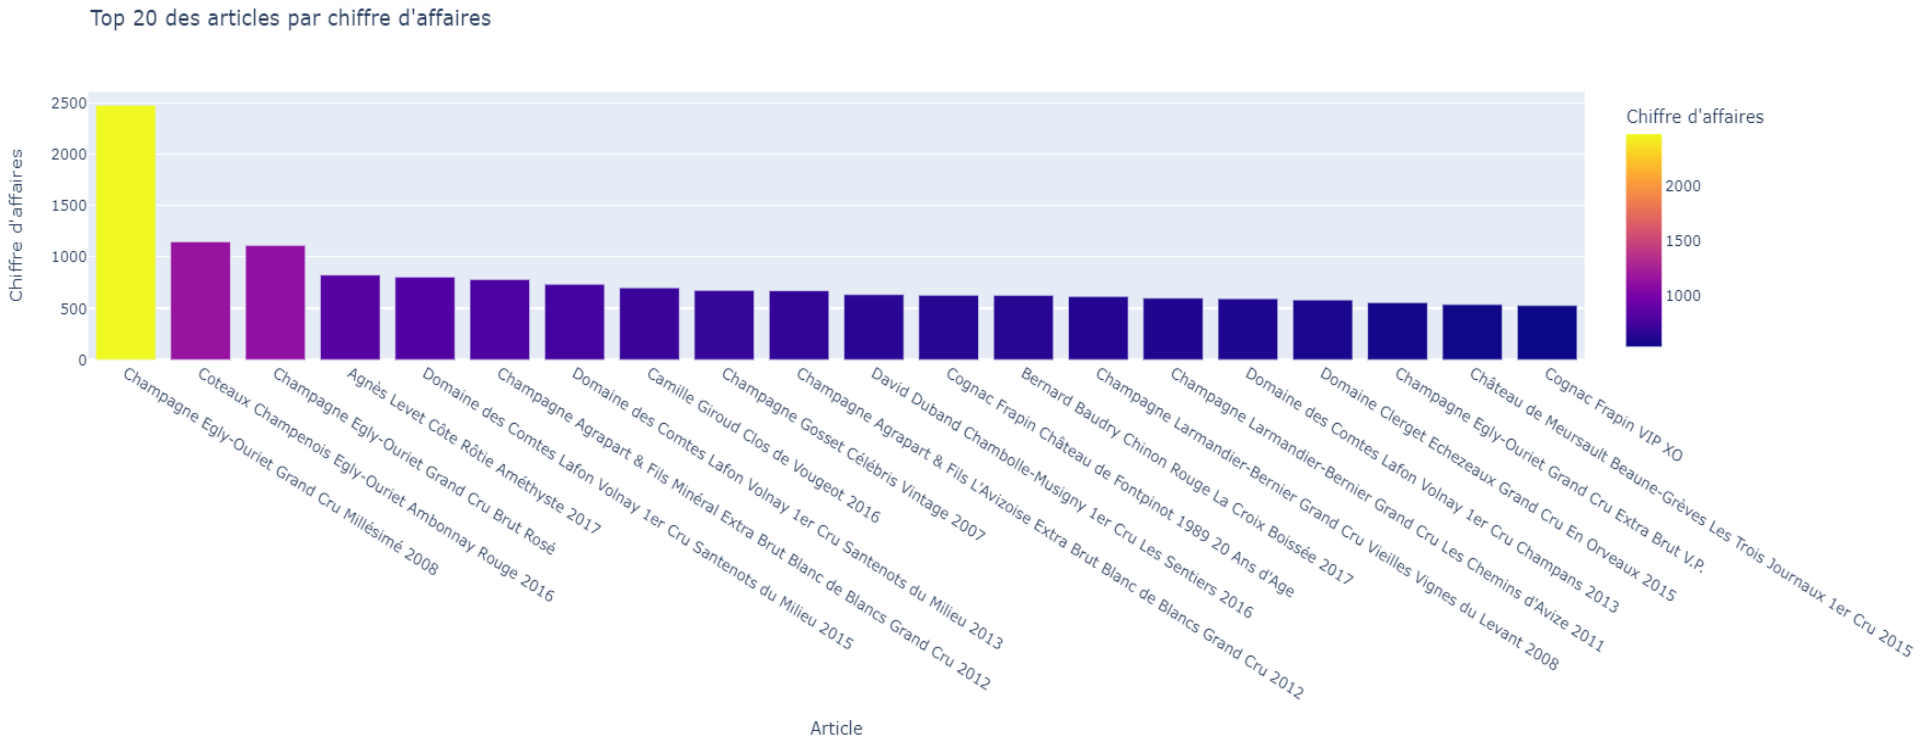

Analyses complémentaires
— Quantitiés vendues

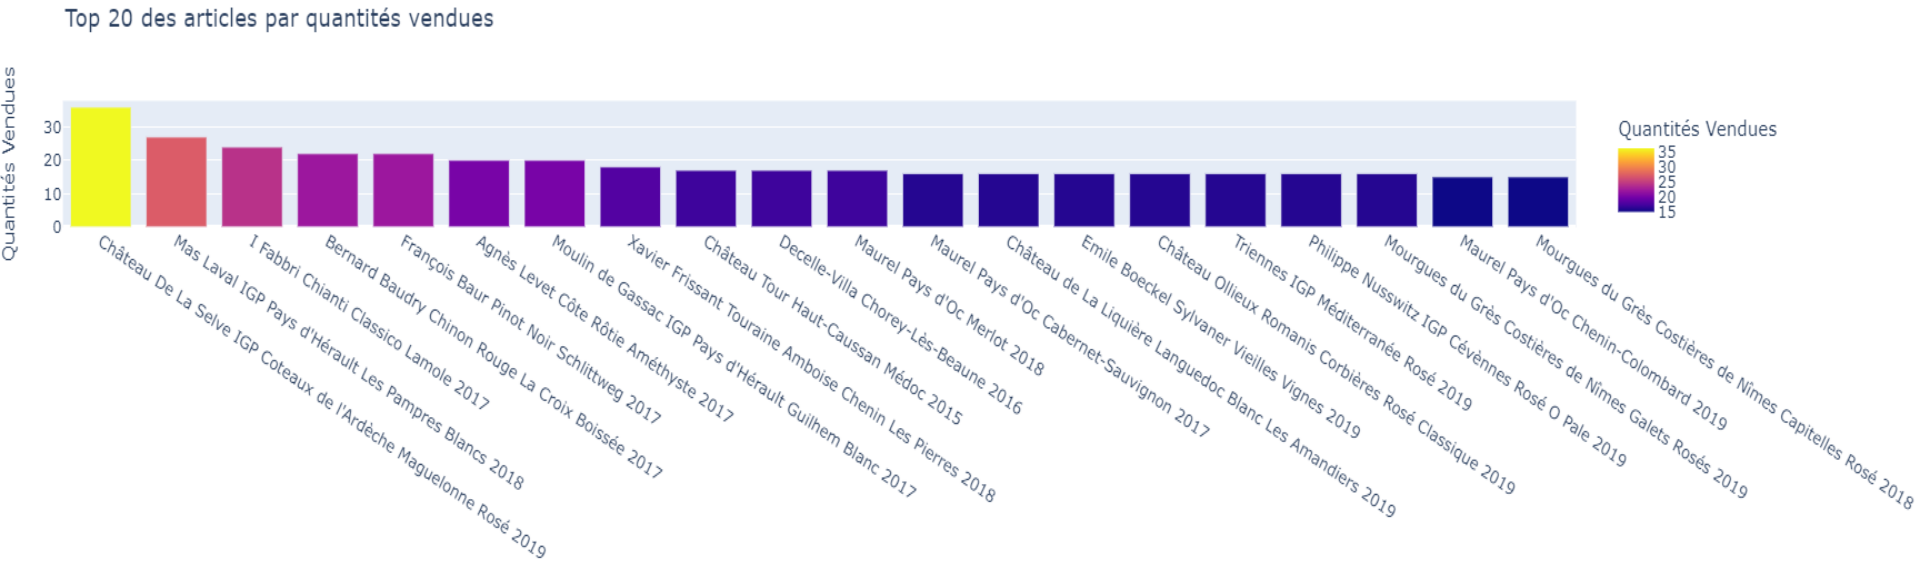

Analyses complémentaires — Quantitiés vendues

```python
# Total des ventes en quantité pour tout le site
total_quantite_ventes = df_web_erp['total_sales'].sum()

# Part en quantité de chaque article
df_web_erp['part_quantite'] = df_web_erp['total_sales'] / total_quantite_ventes

# Calcul de la somme cumulative de la part en quantité
df_web_erp['cumulative_part_quantite'] = df_web_erp['part_quantite'].cumsum()

# Identifier le seuil où 80% des ventes sont atteintes
seuil_80 = df_web_erp[df_web_erp['cumulative_part_quantite'] <= 0.80]

# Calculer le nombre d'articles nécessaires pour atteindre ce seuil
nombre_articles_80pc_ventes = seuil_80.shape[0]

# Calculer la proportion de ces articles dans le catalogue entier
proportion_catalogue = nombre_articles_80pc_ventes / df_web_erp.shape[0]

print(f"Nombre d'articles représentant 80% des quantitées vendus : {nombre_articles_80pc_ventes}")
print(f"Proportion de ces articles dans le catalogue entier : {proportion_catalogue:.2%}")
```

✓ 0.0s

```
Nombre d'articles représentant 80% des quantitées vendus : 559
Proportion de ces articles dans le catalogue entier : 78.40%
```

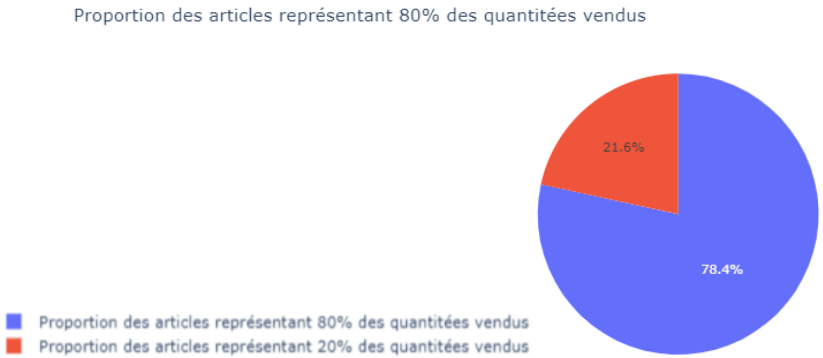

Analyses complémentaires

— Estimation de la durée du stock

```python
# Correction avant division pour éviter division par zéro et gérer les NaN
df_web_erp['vente_quotidienne_moyenne'] = df_web_erp.apply(lambda x: x['total_sales'] / 31 if pd.notna(x['total_sales']) and x['total_sales'] > 0 else 0, axis=1)

# Calcul de 'duree_stock_jours'
df_web_erp['duree_stock_jours'] = df_web_erp.apply(lambda x: x['stock_quantity'] / x['vente_quotidienne_moyenne'] if pd.notna(x['vente_quotidienne_moyenne']) and x['vente_quotidienne_moyenne'] > 0 else np.nan, axis=1)



# Identifier les 20 produits avec la plus longue durée de stock
df_web_erp.sort_values(by='duree_stock_jours', ascending=False, inplace=True)

# Affichage des résultats
df_web_erp[['stock_quantity', 'total_sales', 'duree_stock_jours', 'post_title']].head(20)
```

✓ 0.0s

	stock_quantity	total_sales	duree_stock_jours	post_title
70	125	4	968.750000	Champagne Gosset Grand Millésime 2006
641	138	5	855.600000	Champagne Gosset Célébris Vintage 2007
202	81	3	837.000000	Champagne Egly-Ouriet Premier Cru Les Vignes d...
197	125	5	775.000000	Champagne Egly-Ouriet Grand Cru Brut Tradition
74	71	3	733.666667	Champagne Mailly Grand Cru Brut Rosé
203	115	5	713.000000	Champagne Larmandier-Bernier Latitude
71	91	4	705.250000	Champagne Gosset Grand Rosé
436	136	6	702.666667	Champagne Agrapart & Fils L'Avizoise Extra...
198	145	7	642.142857	Champagne Egly-Ouriet Grand Cru Extra Brut V.P.
76	123	6	635.500000	Champagne Mailly Grand Cru Intemporelle 2010
194	142	7	628.857143	Champagne Gosset Grand Blanc de Blancs
75	101	5	626.200000	Champagne Mailly Grand Cru Intemporelle Rosé 2009
510	19	1	589.000000	Domaine Weinbach Gewurztraminer Grand Cru Furs...
227	18	1	558.000000	Château de Meursault Puligny-Montrachet 1er Cr...
435	103	6	532.166667	Champagne Agrapart & Fils Les 7 Crus Brut ...
414	100	6	516.666667	Champagne Larmandier-Bernier Terre de Vertus P...
586	98	6	506.333333	Coteaux Champenois Egly-Ouriet Ambonnay Rouge ...
205	112	7	496.000000	Champagne Larmandier-Bernier Grand Cru Les Che...
69	123	8	476.625000	Champagne Gosset Grande Réserve
72	86	6	444.333333	Champagne Mailly Grand Cru Brut Réserve

Analyses complémentaires
— Estimation de la durée du stock

Somme de la valorisation total des stocks : 492 835.85 €

Nombre de produits en stock : 16 620 produits

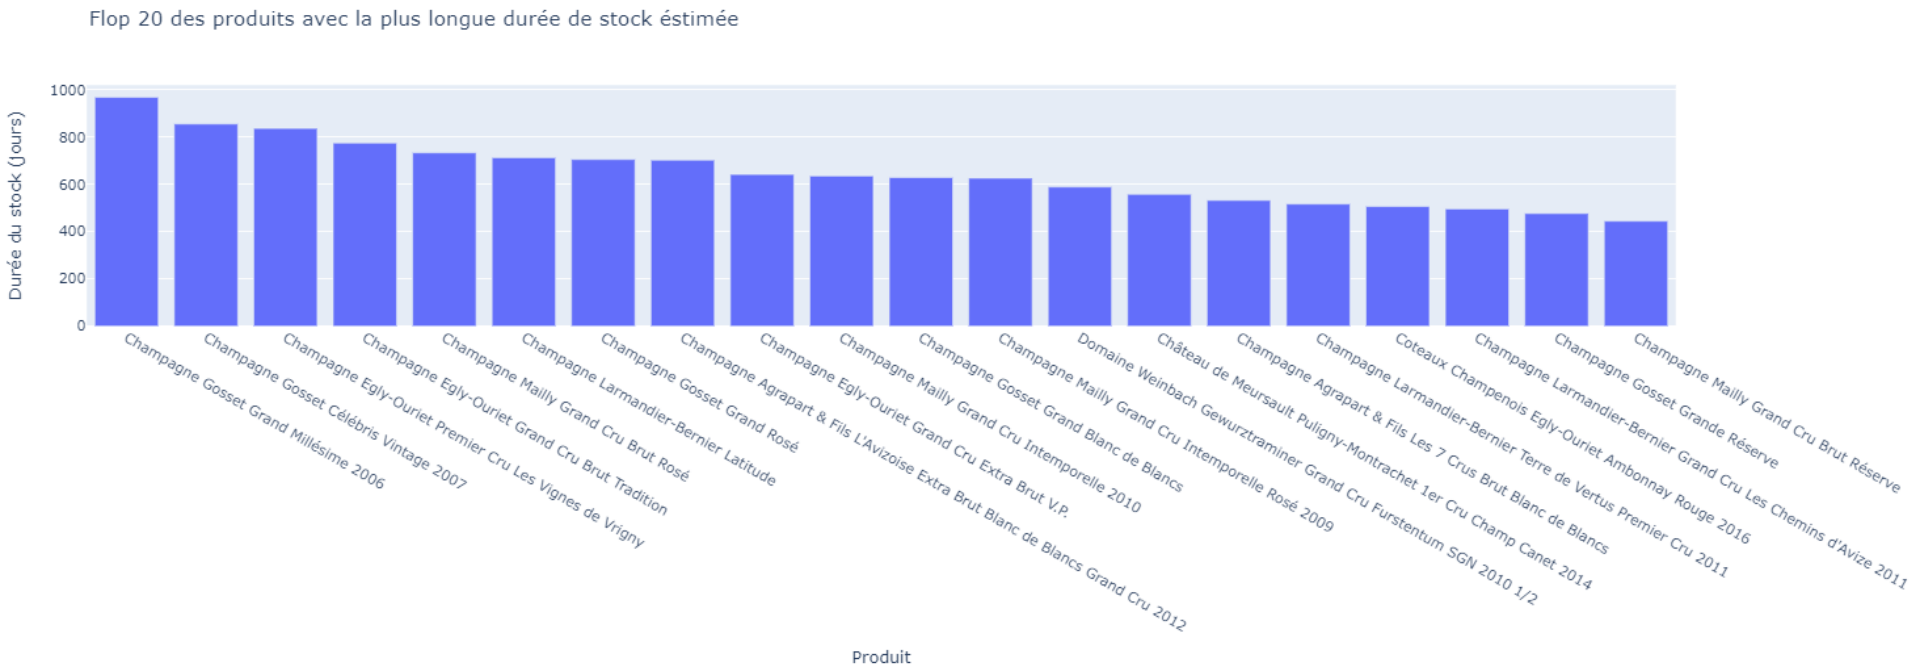

Analyses complémentaires
— Taux de marge

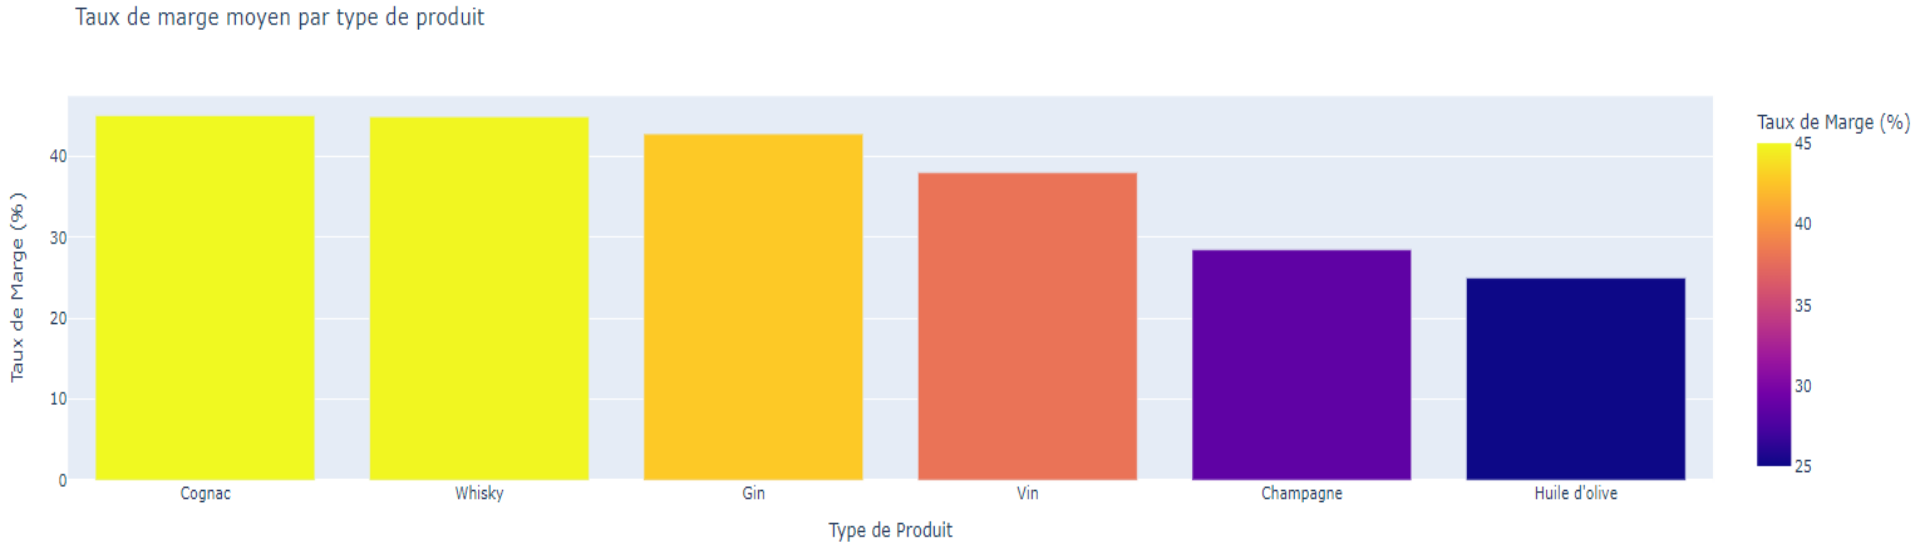

Le taux de marge minimum est de 22,78%

Le taux de marger maximum est de 47,76%

Analyses complémentaires
Etude des corréllations

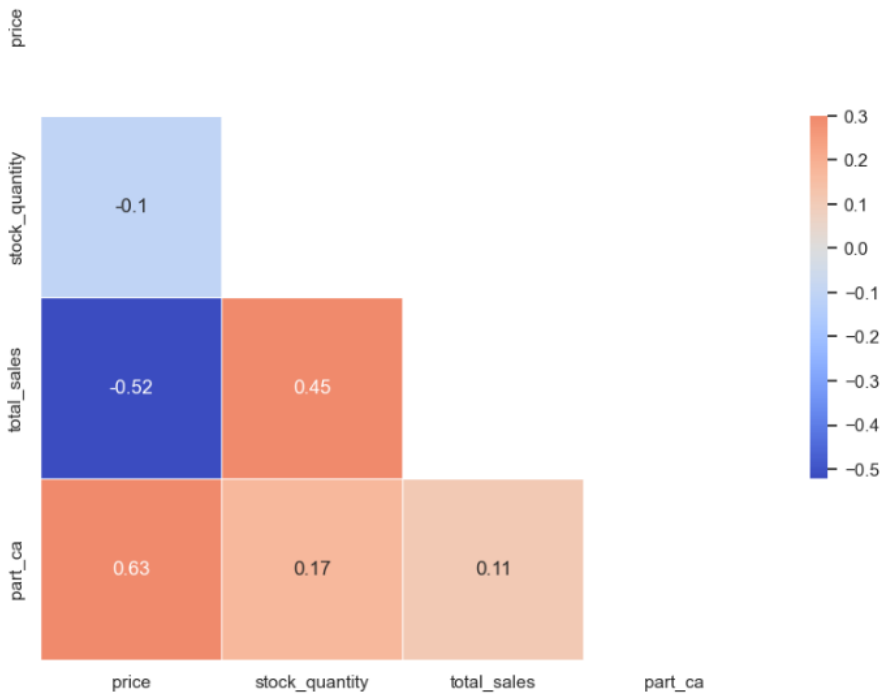

Analyses complémentaires

Analyse Bivariée : CA, Quantités vendues, Prix

Nuage de points entre Prix et Chiffre d'Affaires

Nuage de points entre le prix et les quantités vendues