# Projet 9 : Analysez les ventes d'une librairie avec R ou Python

Cette présentation vise à analyser les chiffres clés de l’entreprise et étudier certaines relation afin de mieux comprendre le comportement des clients.

Nous utiliserons trois ensembles de données clés :

df_transactions : | id_prod | date | session_id | client_id
(Transactions.csv)

df_clients : | client_id | sex | birth |
(customers.csv) | -> | âge |

df_produits : | id_prod | price | categ |
(products.csv)

**Réalisée par :**

**Jason ZBAKH - le 17/06/2025**

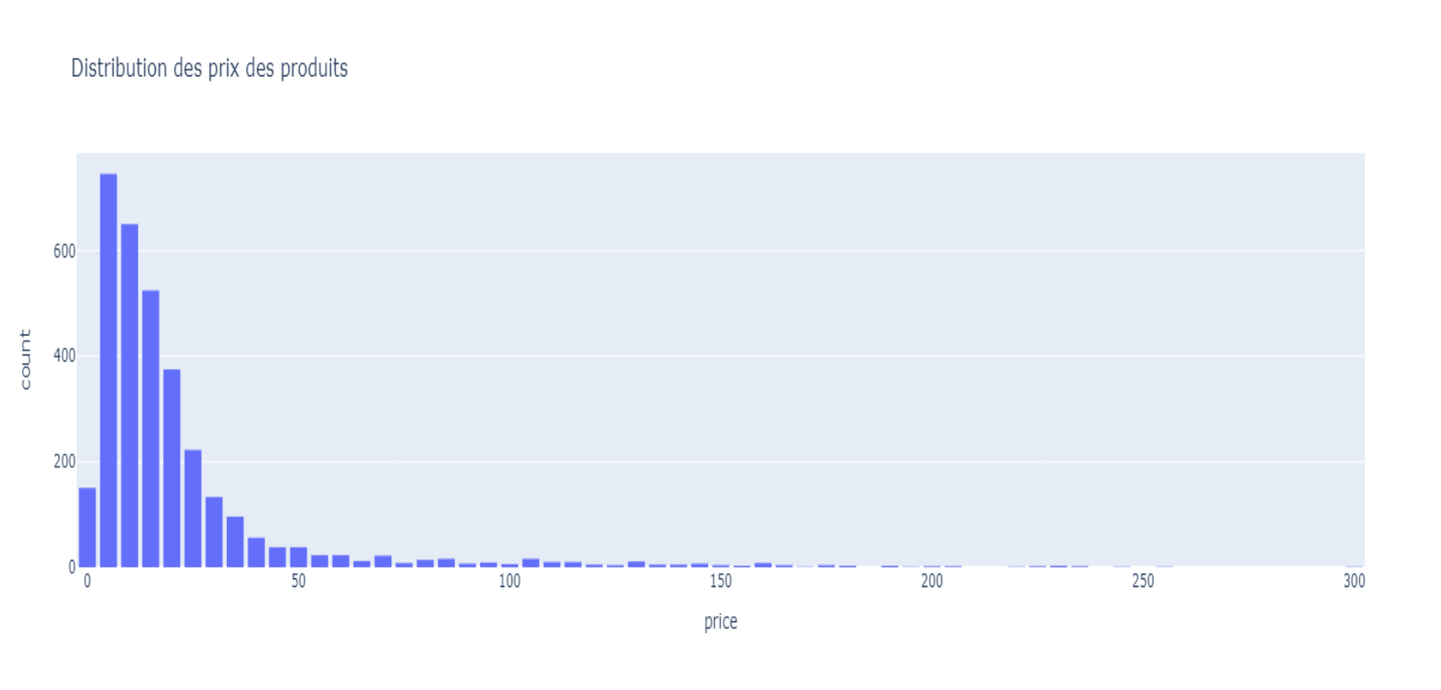
Distribution des prix des produits
count
price
0
200
400
600
0
50
100
150
200
250
300

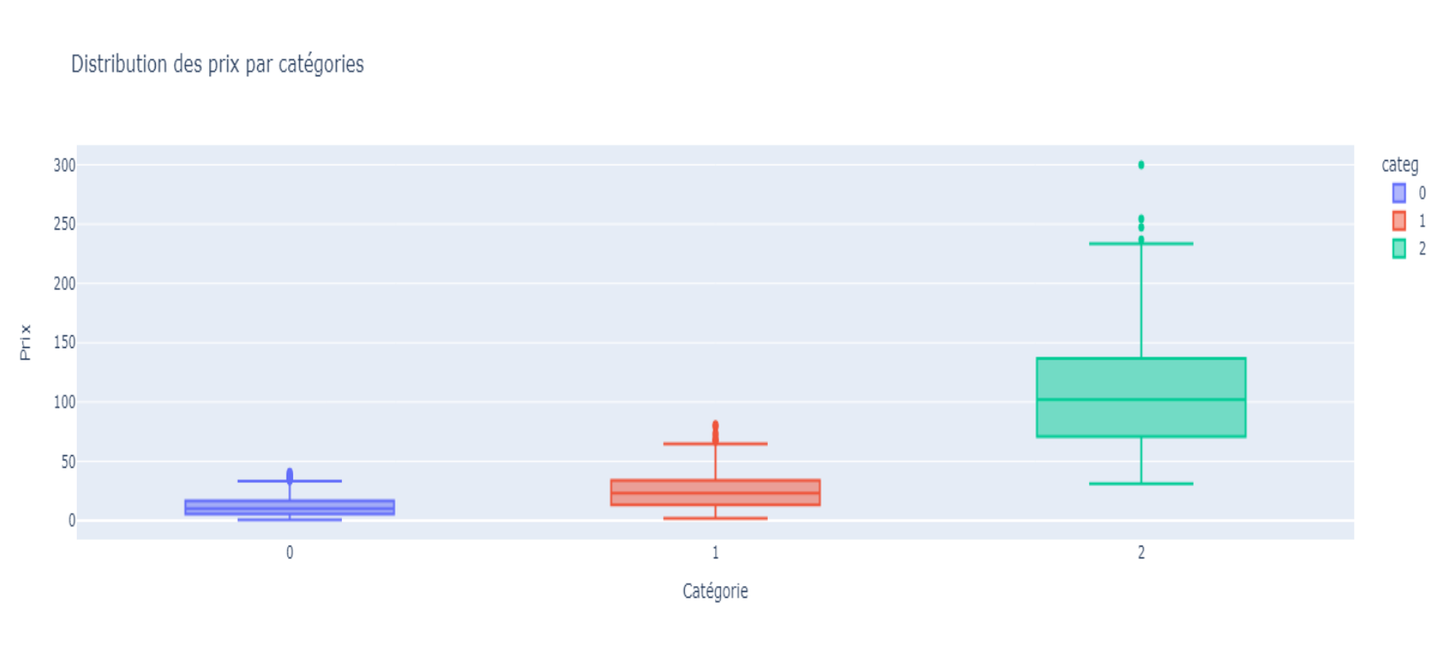
Distribution des prix par catégories
Prix
Catégorie
categ
0
1
2
0
50
100
150
200
250
300
0
1
2

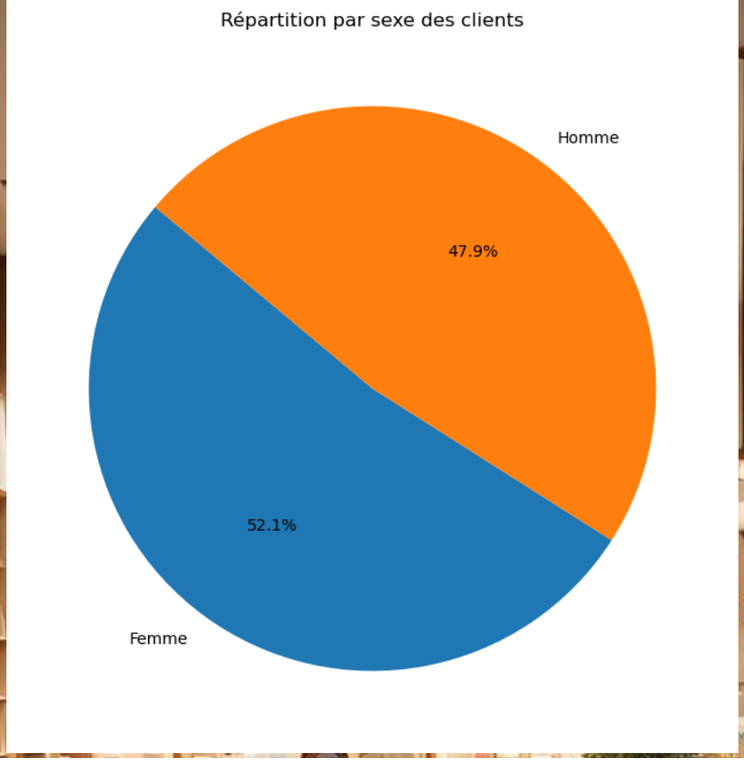
Répartition par sexe des clients
Homme
47.9%
52.1%
Femme

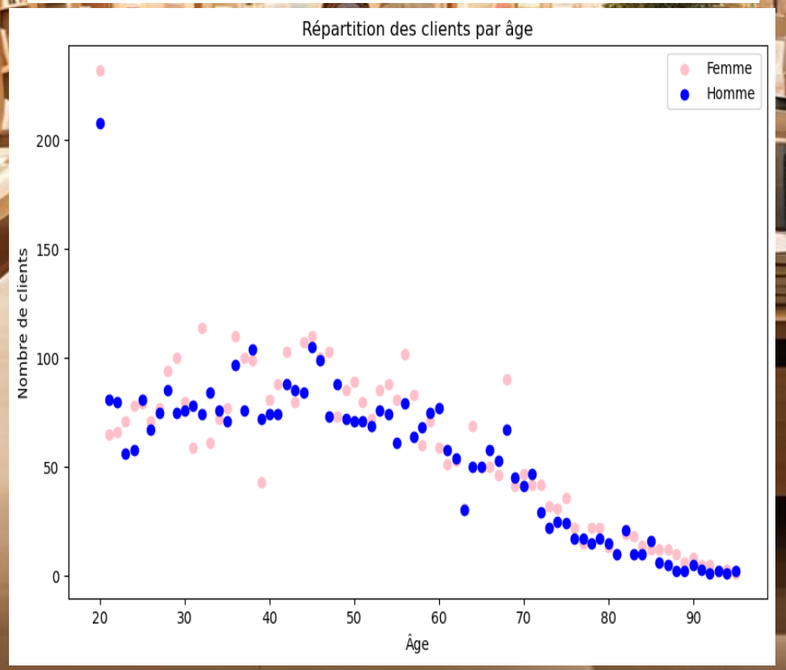
Répartition des clients par âge
Femme
Homme
Nombre de clients
Âge
0
50
100
150
200
20
30
40
50
60
70
80
90

# Liaisons des données

1

- df_clients + df_transactions = df_merge | Clé de jonction : Client_Id

*df_merge : enregistrement de chaques ventes avec données clients*

Nombre id_client uniques dans df_clients: 8621

Nombre id_client uniques dans df_transactions: 8600

-> 21 clients n'ont jamais passés de commande

2

- df_merge + df_produits = df_lapage | Clé de jonction : Id_prod

***Df_lapage :***

```
RangeIndex: 687534 entries, 0 to 687533
Data columns (total 8 columns):
 #   Column      Non-Null Count   Dtype
---  ------      --------------   -----
 0   client_id   687534 non-null  object
 1   sex         687534 non-null  object
 2   age         687534 non-null  int64
 3   id_prod     687534 non-null  object
 4   date        687534 non-null  datetime64[ns]
 5   session_id  687534 non-null  object
 6   price       687534 non-null  float64
 7   categ       687534 non-null  object
dtypes: datetime64[ns](1), float64(1), int64(1), object(5)
```

***Ensemble des données liées***

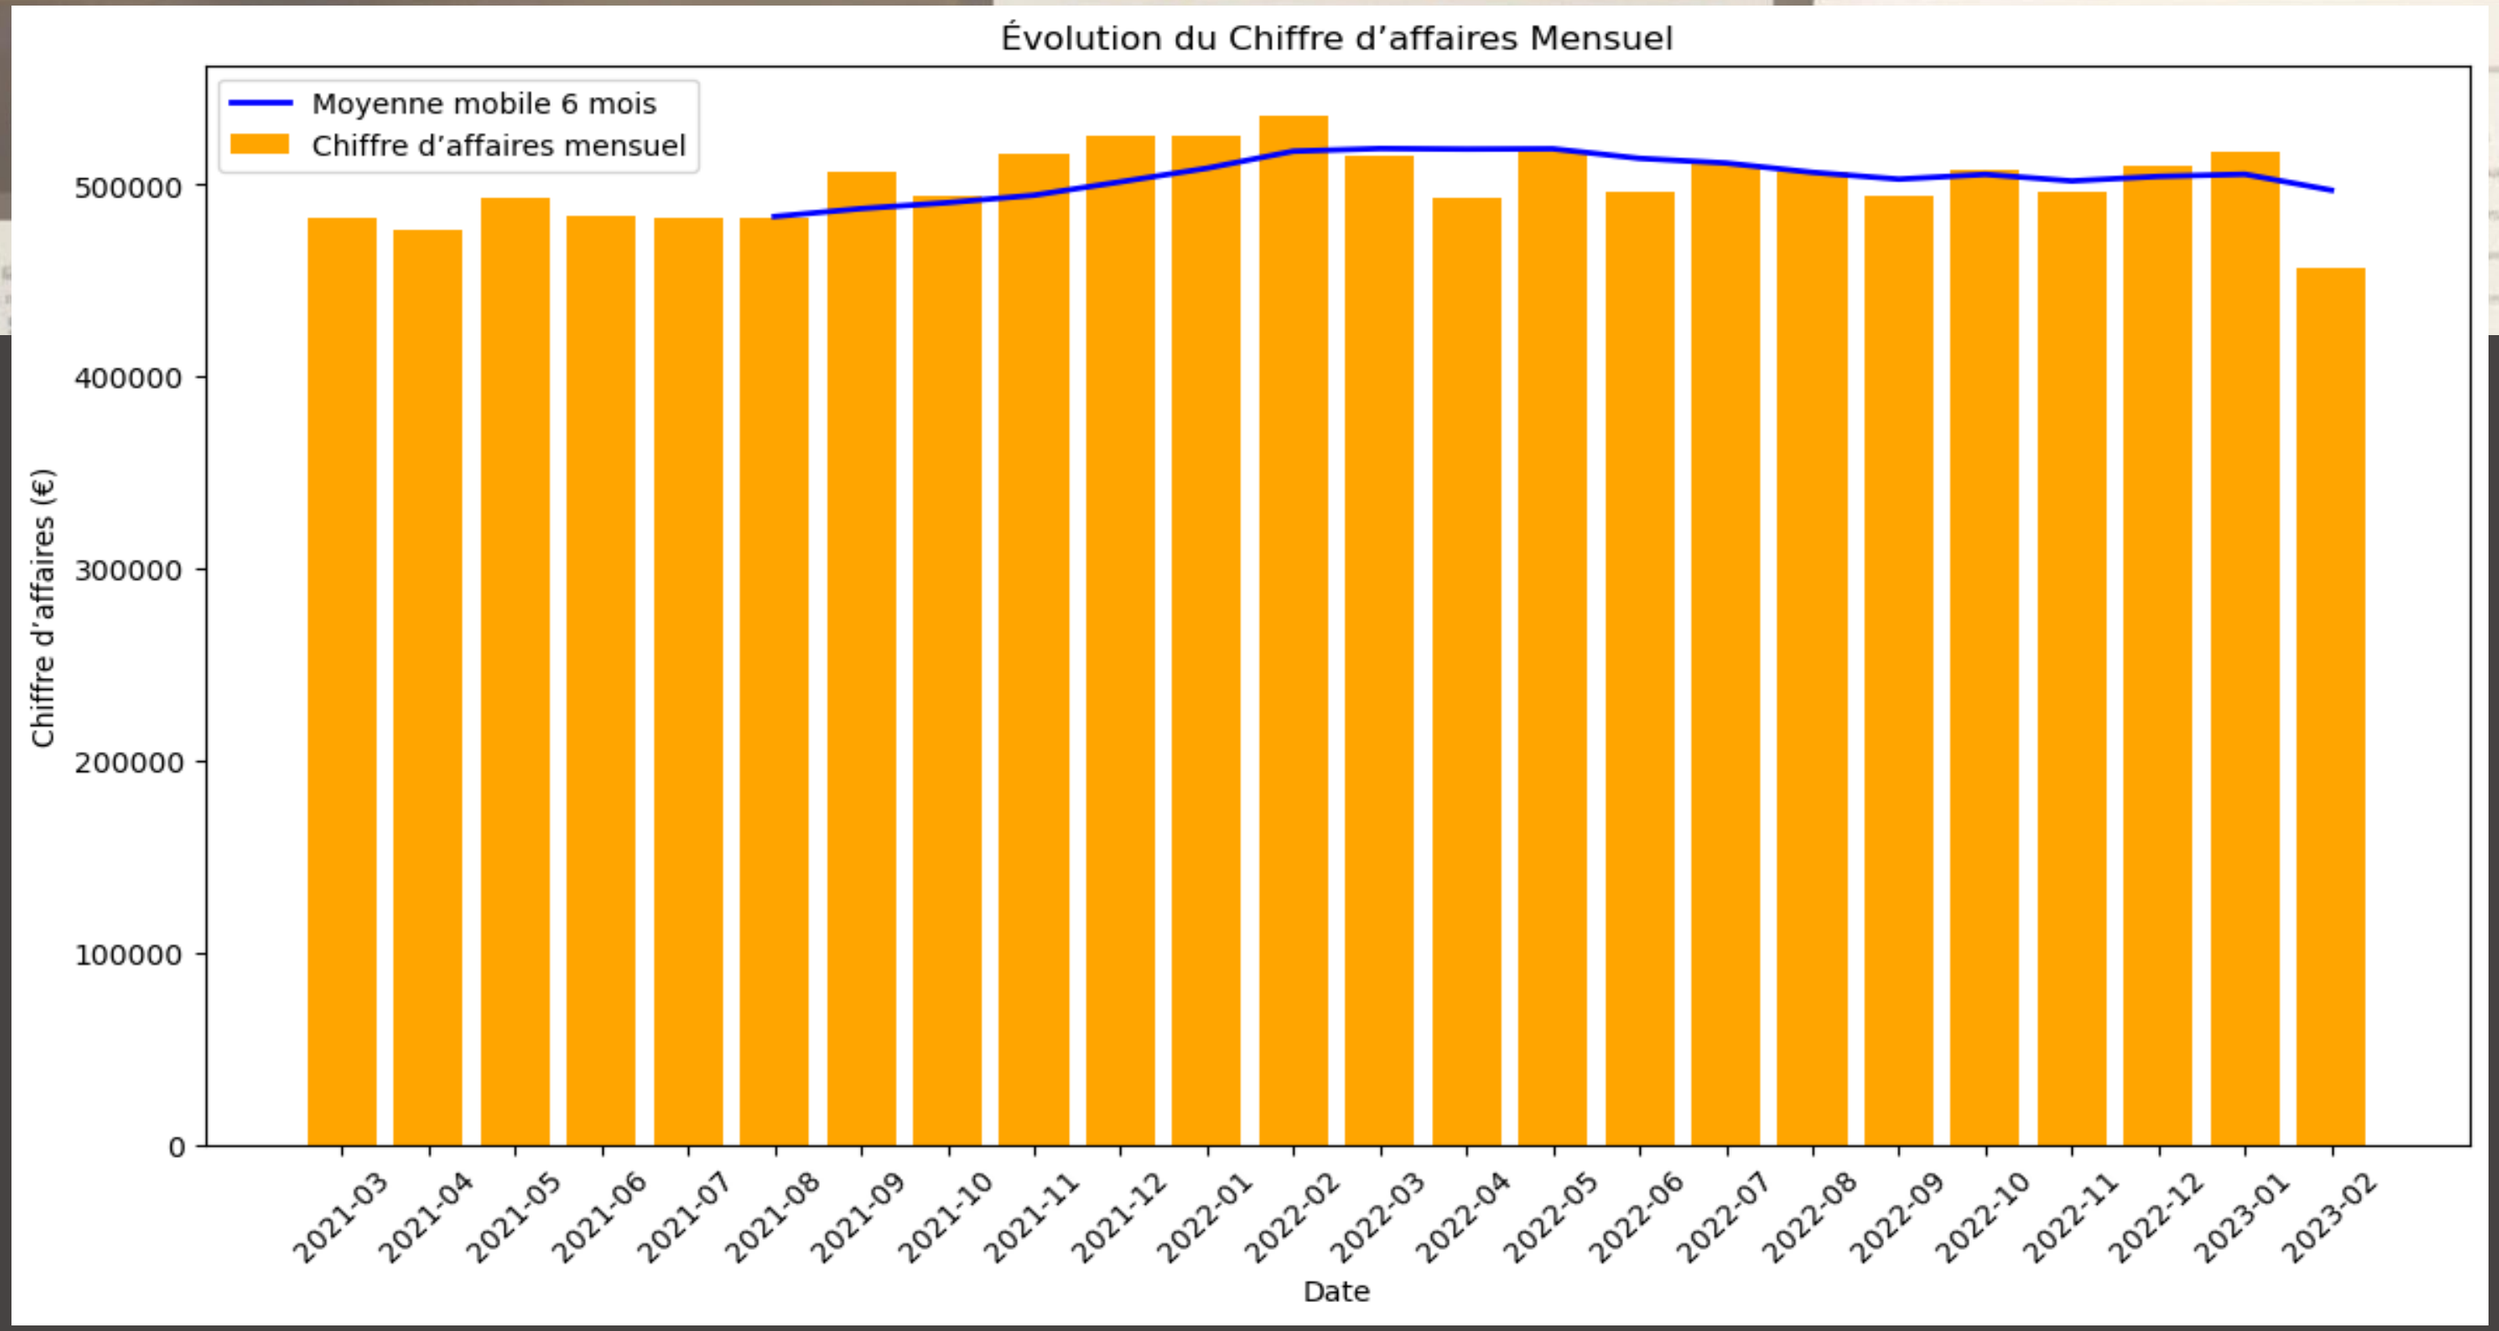
Évolution du Chiffre d'affaires Mensuel
Moyenne mobile 6 mois
Chiffre d'affaires mensuel
Chiffre d'affaires (€)
0
100000
200000
300000
400000
500000
2021-03
2021-04
2021-05
2021-06
2021-07
2021-08
2021-09
2021-10
2021-11
2021-12
2022-01
2022-02
2022-03
2022-04
2022-05
2022-06
2022-07
2022-08
2022-09
2022-10
2022-11
2022-12
2023-01
2023-02
Date

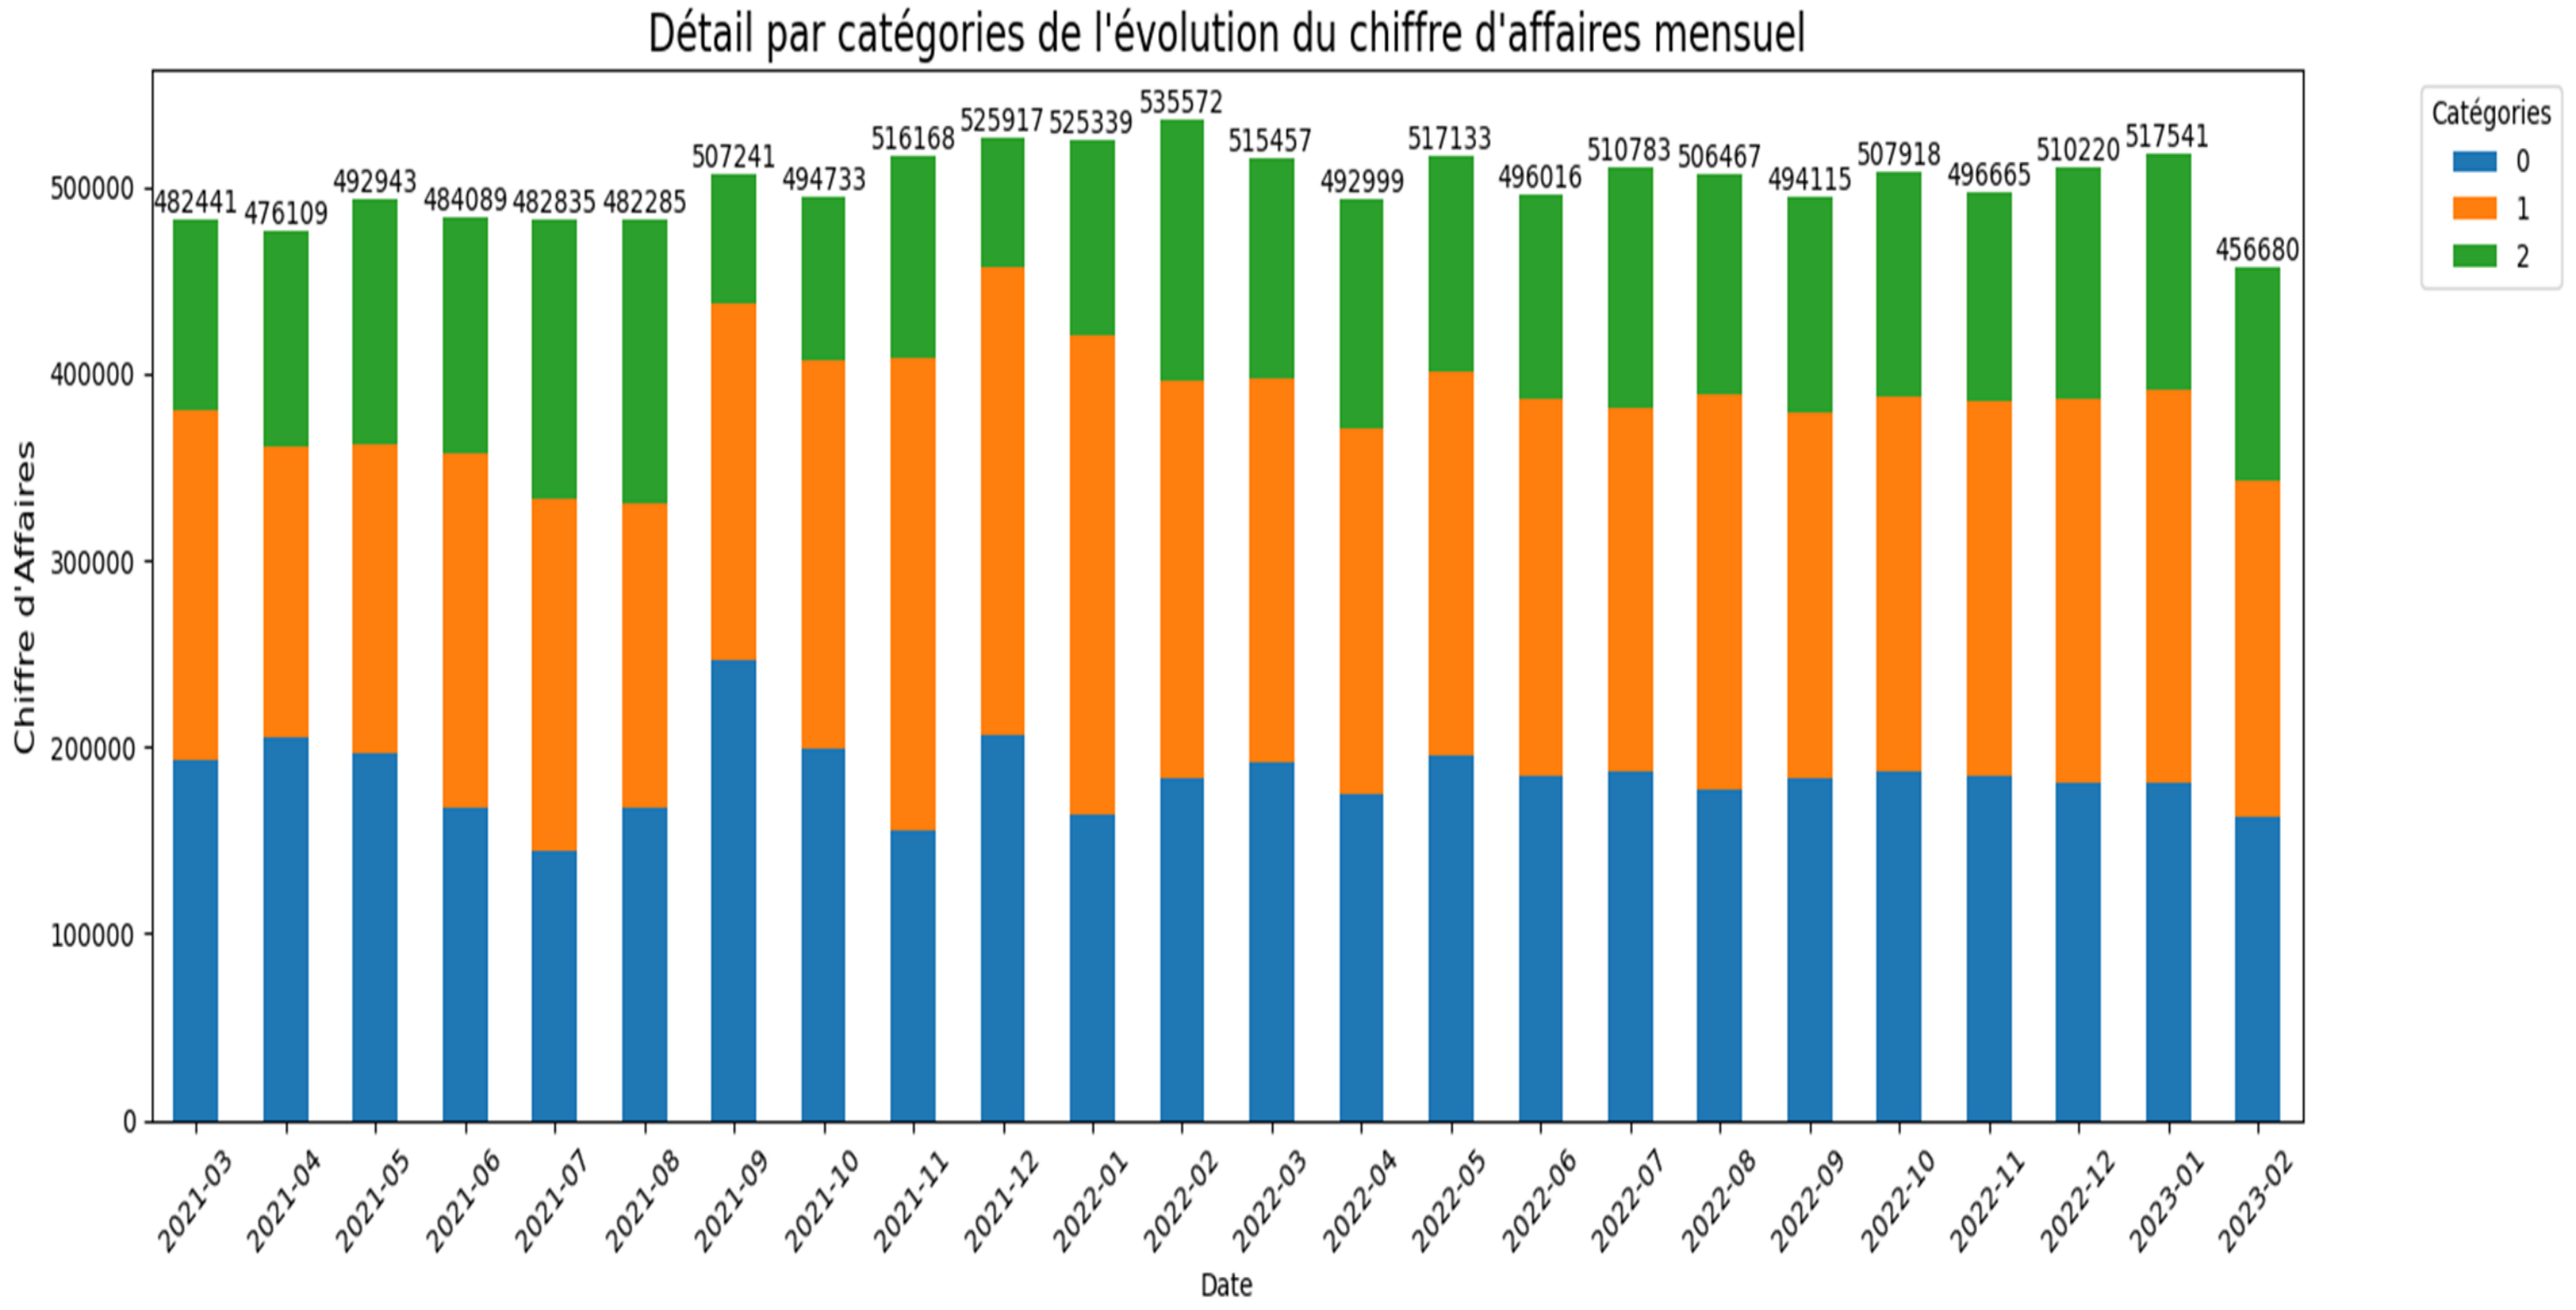
Détail par catégories de l'évolution du chiffre d'affaires mensuel
Chiffre d'Affaires
Date
Catégories
0
1
2
482441
476109
492943
484089
482835
482285
507241
494733
516168
525917
525339
535572
515457
492999
517133
496016
510783
506467
494115
507918
496665
510220
517541
456680
0
100000
200000
300000
400000
500000
2021-03
2021-04
2021-05
2021-06
2021-07
2021-08
2021-09
2021-10
2021-11
2021-12
2022-01
2022-02
2022-03
2022-04
2022-05
2022-06
2022-07
2022-08
2022-09
2022-10
2022-11
2022-12
2023-01
2023-02

Categories 1 :
4 827 657 , 11€

Categories 0 :
4 419 730 , 97 €

Categories 2 :
2 780 275 . 02€

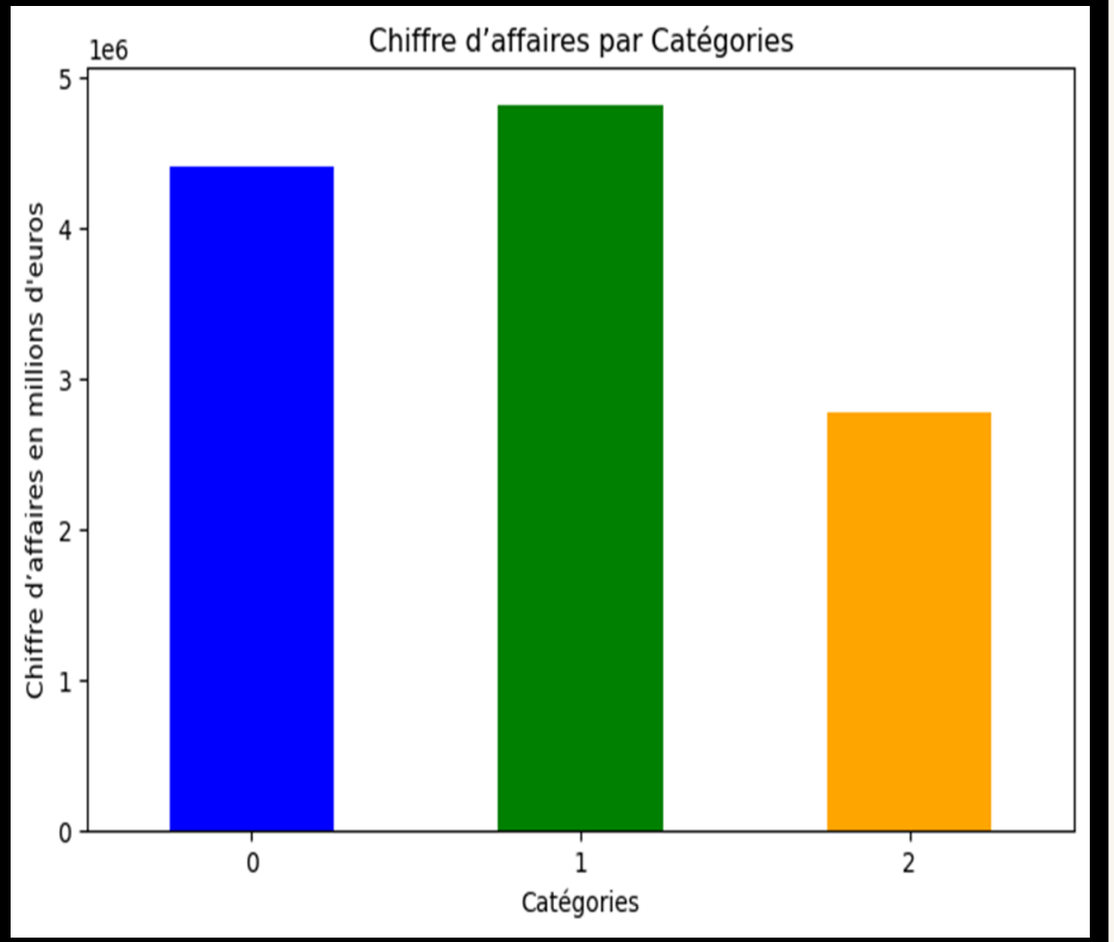


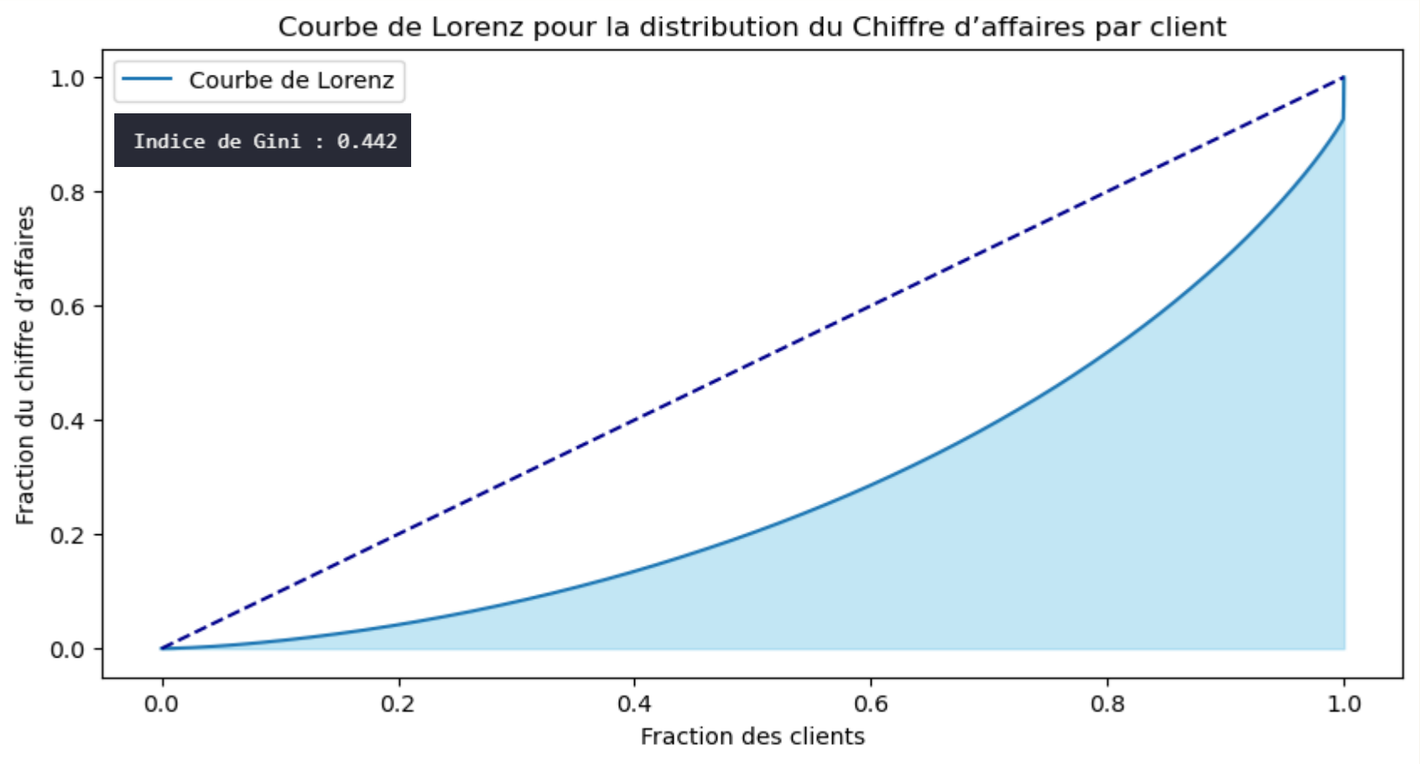


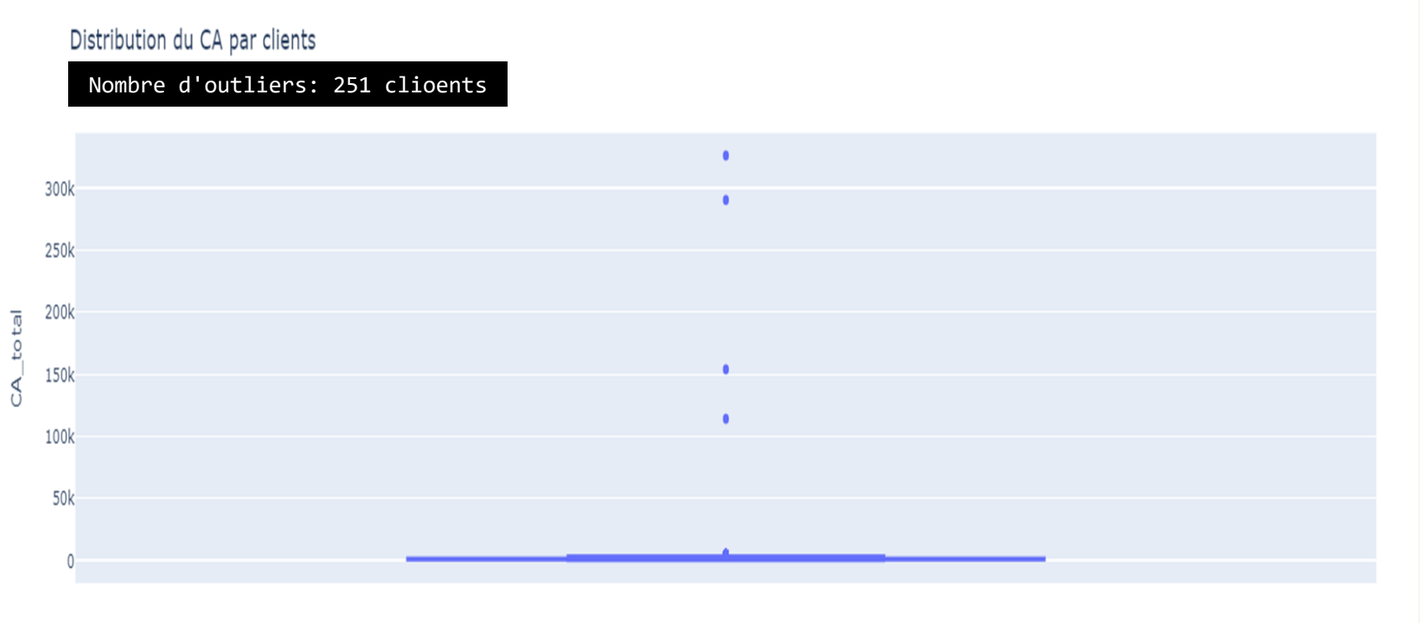

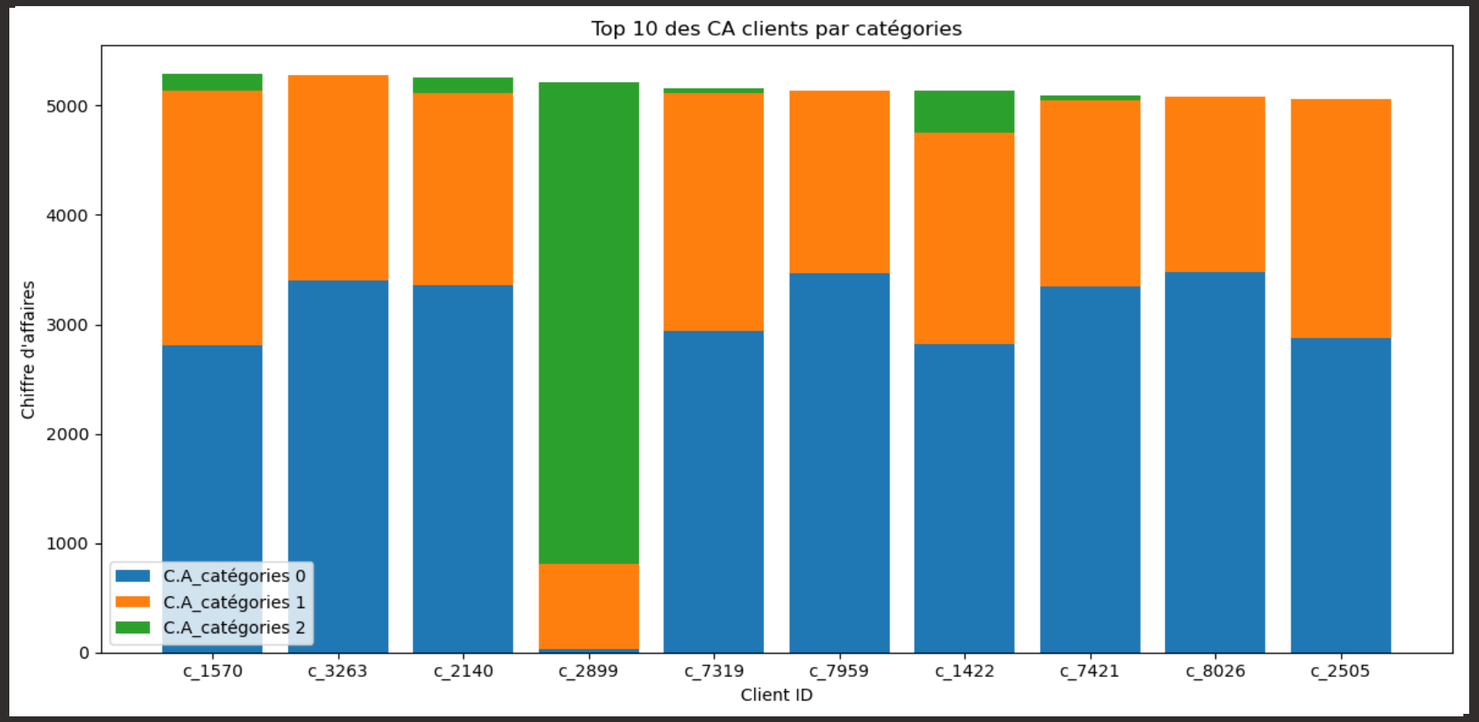


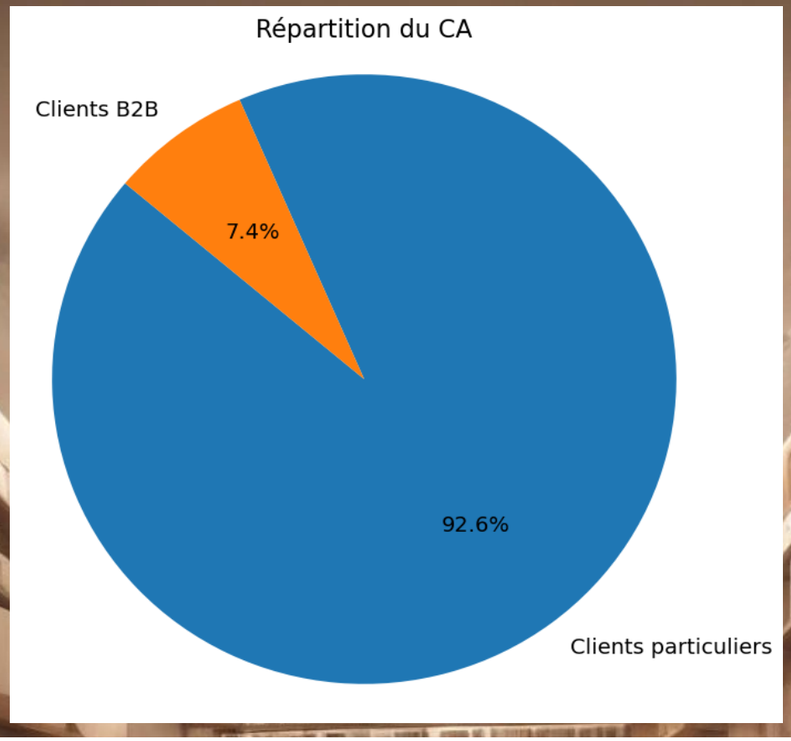


**CLIENTS DÉFINIT COMME 'OUTLIER' PAR LE CA AVEC LE ZSCORE :**

| client_id | CA_total | z_score |
|---|---|---|
| c_3454 | 114110.57 | 21.66 |
| c_6714 | 153918.60 | 29.31 |
| c_4958 | 290227.03 | 55.51 |
| c_1609 | 326039.89 | 62.39 |

Le z-score mesure de combien de déviations standard une donnée est éloignée de la moyenne de l'ensemble

**Un z-score de 62,39 signifie que la valeur du CA_total du client c_4958 se situe à 62.39 fois l'écart-type au-dessus de la moyenne des CA_totals des autres clients,**

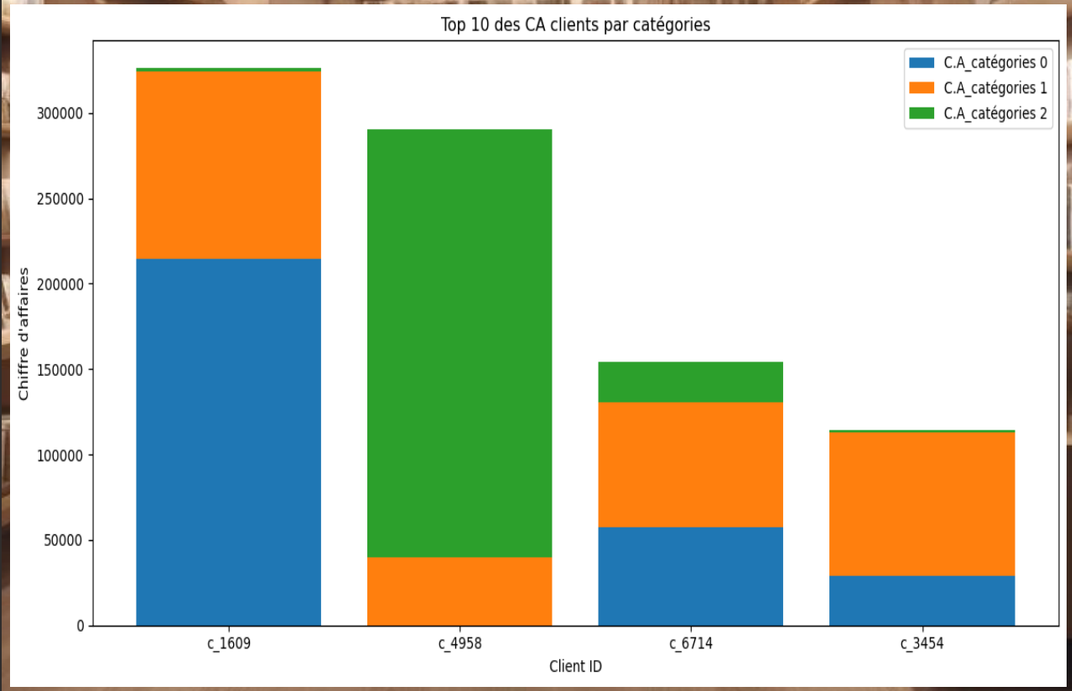

Les clients B2b sont exclut du reste de l’analyse

# 80/20 en Chiffre d'Affaires (Analyse de Pareto)

**Clients**

**80%** — Pourcentage des clients qui génèrent 80% du CA : 79.99%

**20%** — Pourcentage des clients qui génèrent 20% du CA : 20.01%

**Références**

**80%** — Pourcentage des id_prod représentent 80% du CA : 21.49%

**20%** — Pourcentage des id_prod représentent 20% du CA : 78.51%

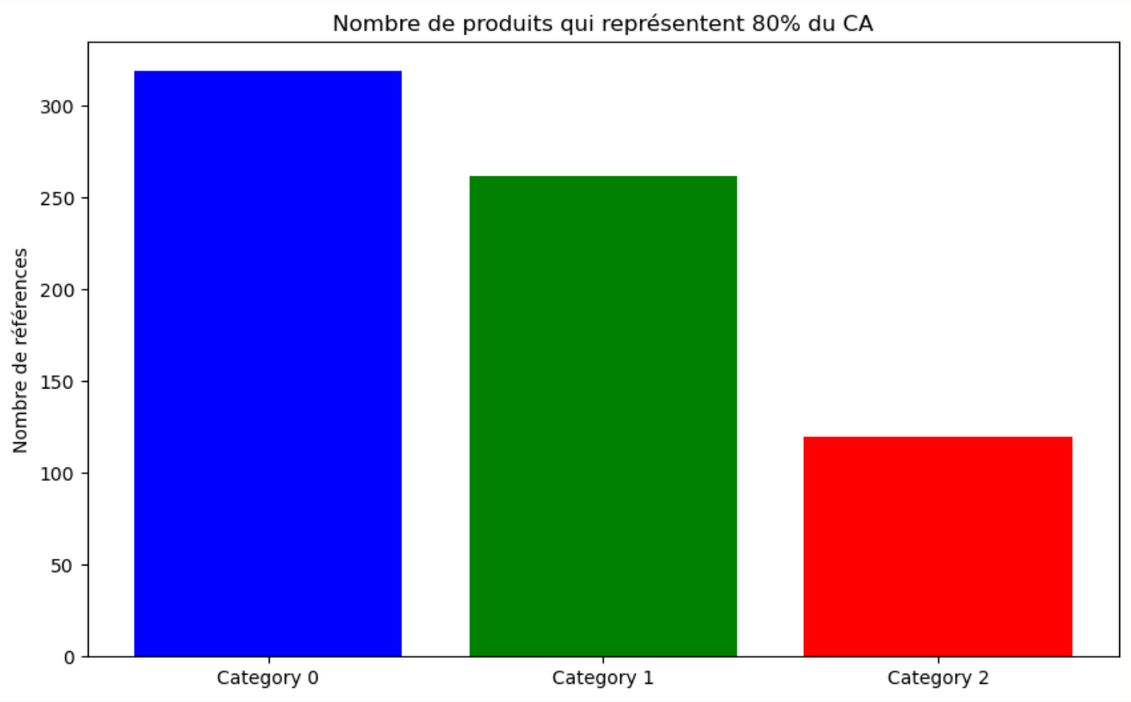

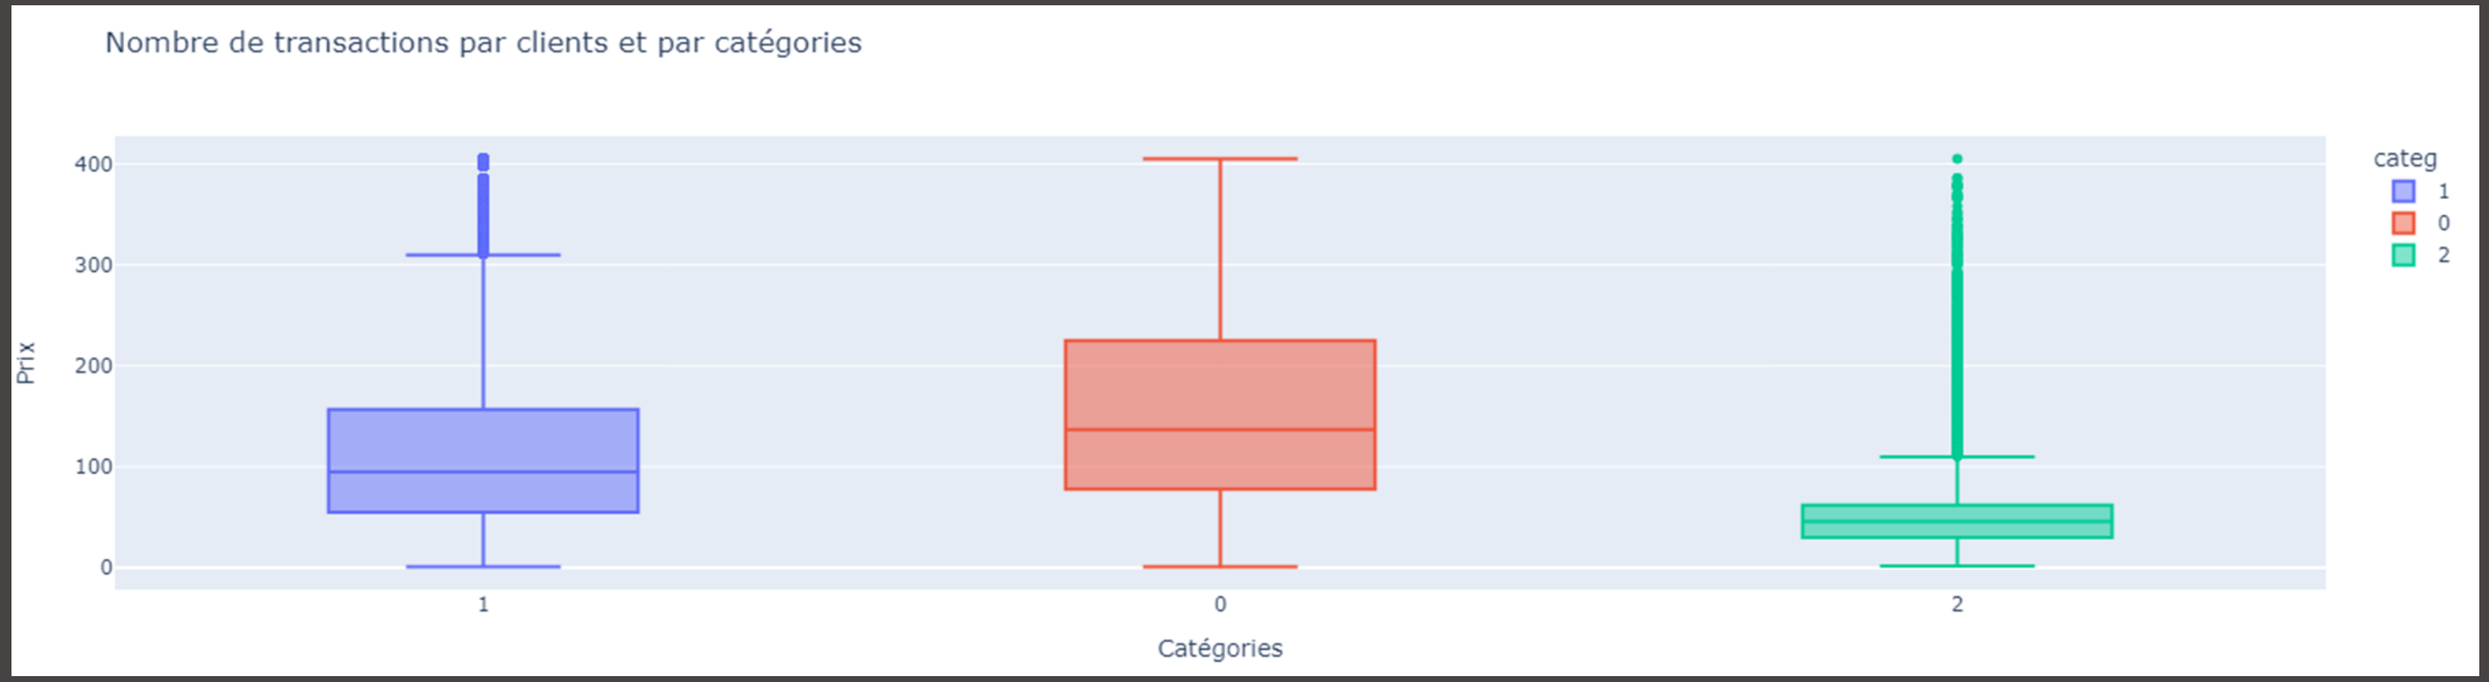
Nombre de transactions par clients et par catégories
Prix
400
300
200
100
0
1
0
2
Catégories
categ
1
0
2

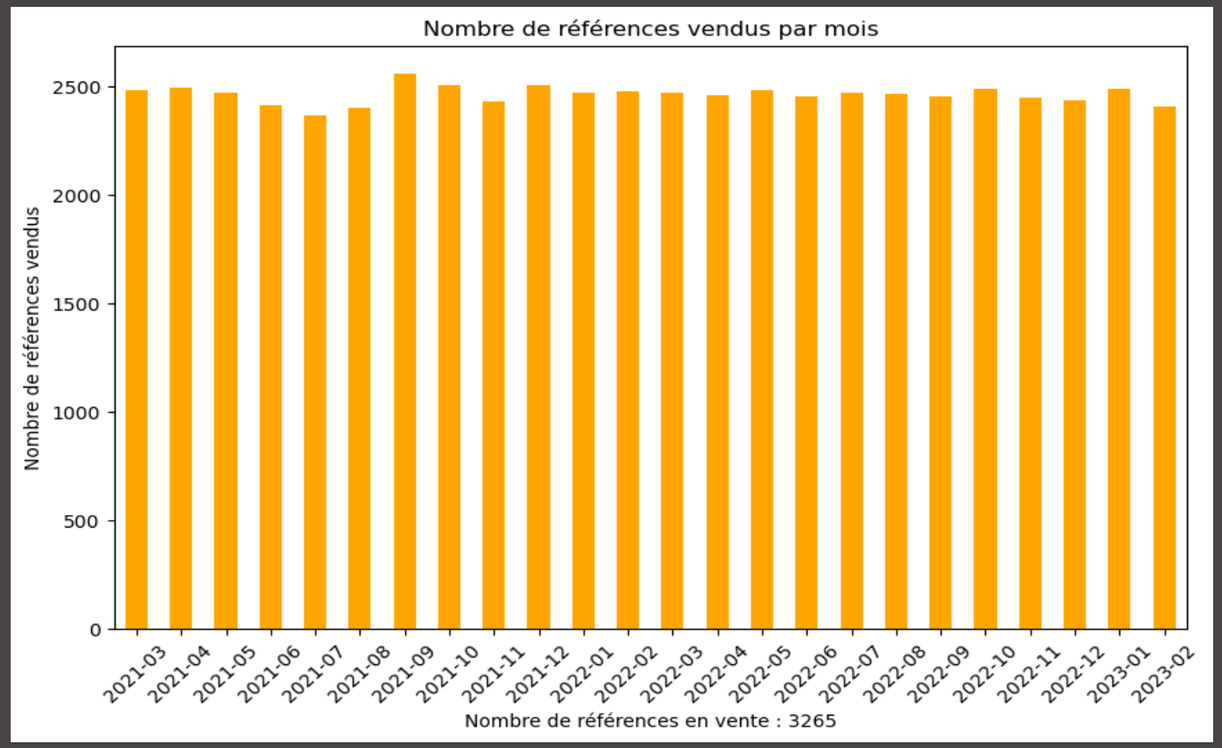
Nombre de références vendus par mois
Nombre de références vendus
2500
2000
1500
1000
500
0
2021-03
2021-04
2021-05
2021-06
2021-07
2021-08
2021-09
2021-10
2021-11
2021-12
2022-01
2022-02
2022-03
2022-04
2022-05
2022-06
2022-07
2022-08
2022-09
2022-10
2022-11
2022-12
2023-01
2023-02
Nombre de références en vente : 3265

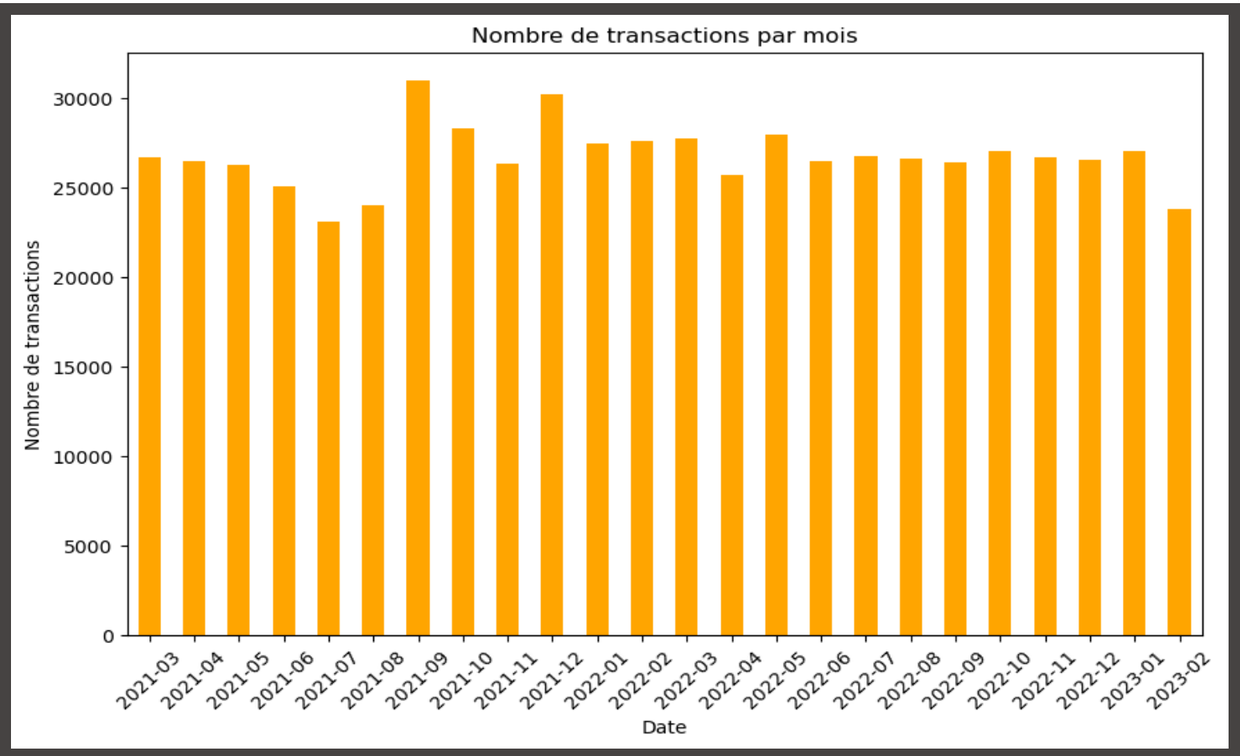
Nombre de transactions par mois
Nombre de transactions
30000
25000
20000
15000
10000
5000
0
2021-03
2021-04
2021-05
2021-06
2021-07
2021-08
2021-09
2021-10
2021-11
2021-12
2022-01
2022-02
2022-03
2022-04
2022-05
2022-06
2022-07
2022-08
2022-09
2022-10
2022-11
2022-12
2023-01
2023-02
Date

Top 10 et Flop 10 des ventes globales

| ID Produit | Ventes |
|---|---|
| 1_369 | 1135 |
| 1_417 | 1114 |
| 1_414 | 1082 |
| 1_498 | 1076 |
| 1_425 | 1068 |
| 1_412 | 983 |
| 1_403 | 981 |
| 1_413 | 977 |
| 1_396 | 961 |
| 1_407 | 960 |
| 0_1071 | 1 |
| 0_1101 | 1 |
| 0_1107 | 1 |
| 0_1116 | 1 |
| 0_1120 | 1 |
| 0_1122 | 1 |
| 0_1150 | 1 |
| 0_1151 | 1 |
| 0_1165 | 1 |
| 0_1191 | 1 |

# Top Flop par années et categories

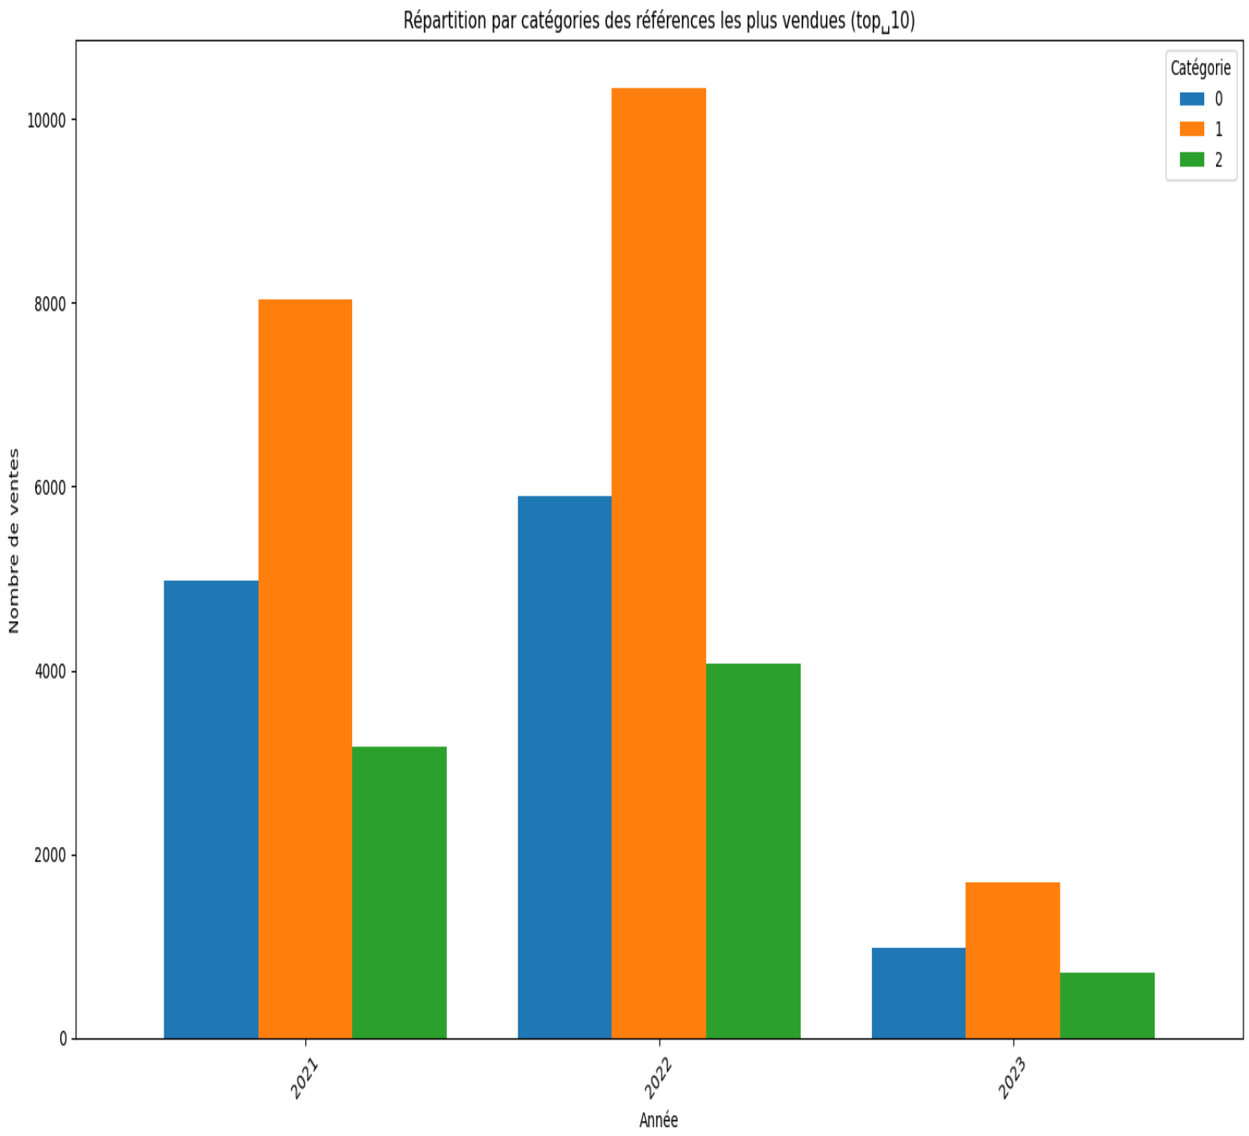


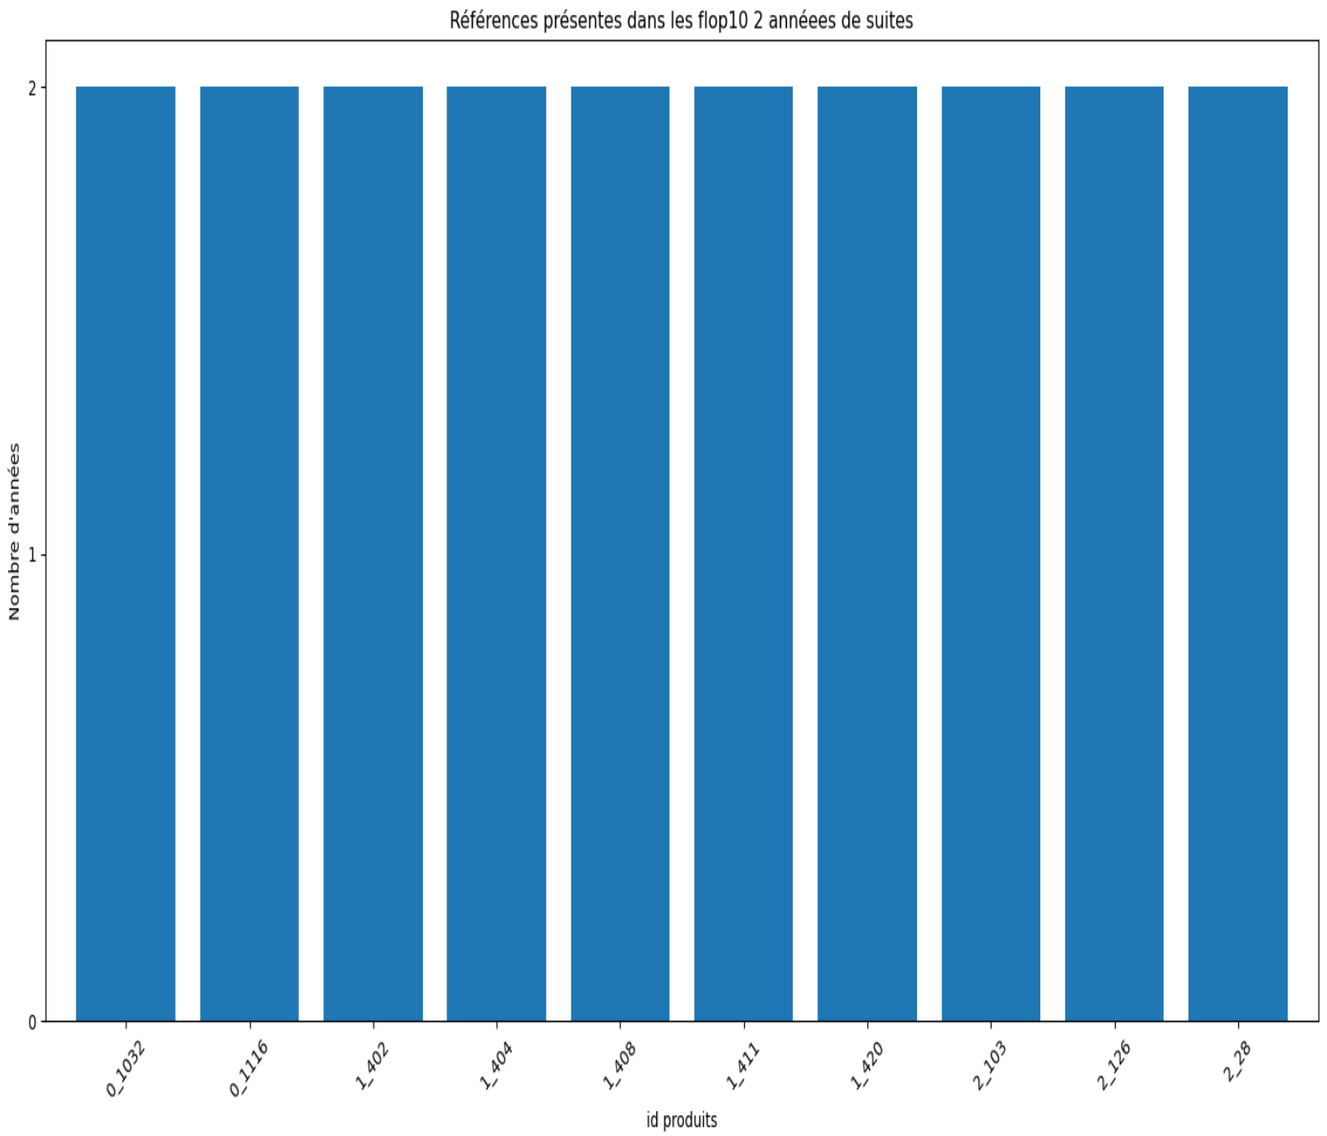

# Etudes des relations

- 1 le lien entre le genre d’un client et les catégories des livres achetés,
- 2 le lien entre l'âge des clients et le montant total des achats,
- 3 le lien entre l'âge des clients et la fréquence d’achat,
- 4 le lien entre l'âge des clients et la taille du panier moyen,
- 5 le lien entre l'âge des clients et la catégorie des livres achetés

# (1) Etude de liens entre le genre d'un client et les catégories des livres achetés

1

Pour étudier le lien entre des variables **Qualitatives** je commence par crée un **tableau de contingence** puis je réalise un **test de Chi_2**

## Variables

- Le genre d'un clients (sexe) : Variable **qualitative**
- Catégories de livres achetées : Variable **qualitative**.

**Deux variables Qualitatives**

| | catégorie 0 | catégorie 1 | catégorie 2 |
|---|---|---|---|
| **sex** | | | |
| Femme | 200793 | 115721 | 16980 |
| Homme | 186488 | 104884 | 15868 |

2

## Test du chi-carré (chi2)

### Hypothèses

**Hypothèse Nulle (H0)** : Il n'y a pas de lien significatif entre le genre d'un client et les catégories des livres achetés.

**Hypothèse Alternative (H1)** : Il existe un lien significatif entre le genre d'un client et les catégories des livres achetés.

3

## Interprétation des résultats du test de chi2

La p-valeur obtenue 1.195928116587024e-05 est bien inférieure au seuil de significativité (0,05%).

La statistique du chi-carré (22.66...) est superieur a la valeur critique du chi-carré.(5.99)

**Nous rejettons l'hypothèse H0 d'indépendance entre le genre et la catégorie, avec un risuqe très minime de se tromper.**

**Par conséquent : Il existe un lien entre le genre d'un client et la categories de livres achetés.**

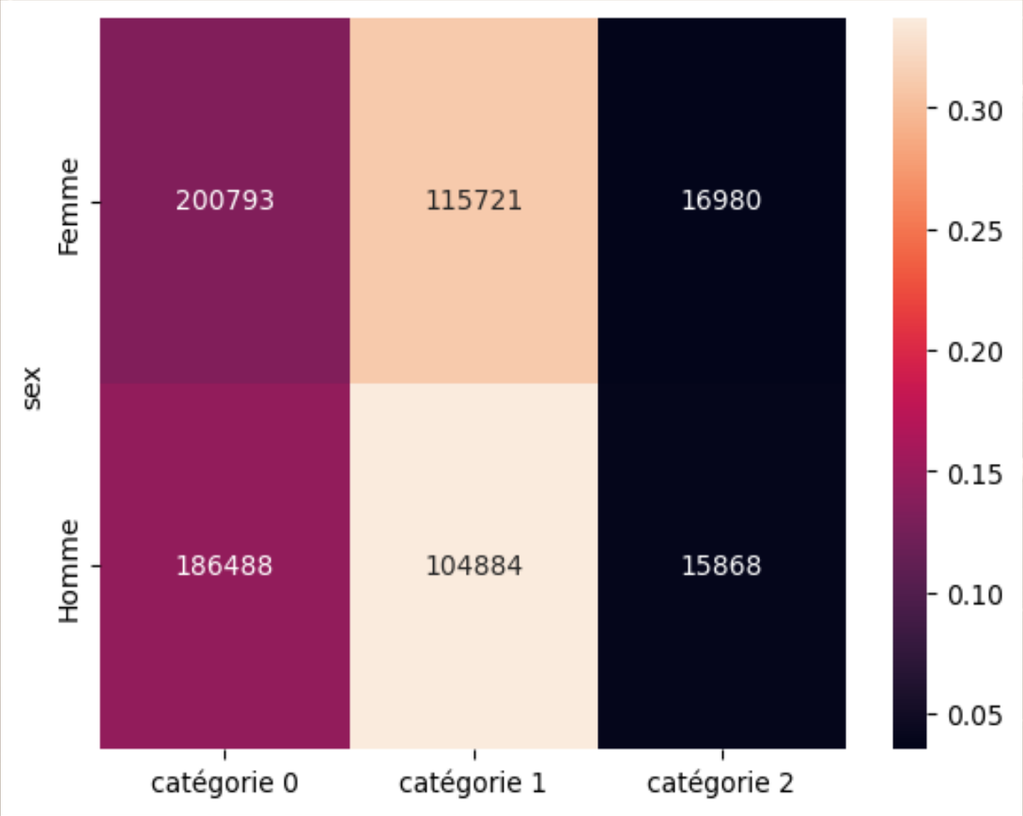


## Analyse de la heatmap

La heatmap montre les contributions normalisées au test du chi-carré pour les transactions par sexe et catégories de livres achetées.
On peut considérer cette valeur comme une contribution à la non-indépendance entre le genre d'un client et les catégories des livres achetés

Plus cette contribution sera proche de 1, plus la case en question sera source de non-indépendance

**-La variation des couleurs indique un lien plus important entre le sexe et la catégorie 1.**

# (2) Etude de liens entre l'âge des clients et le montant total des achats

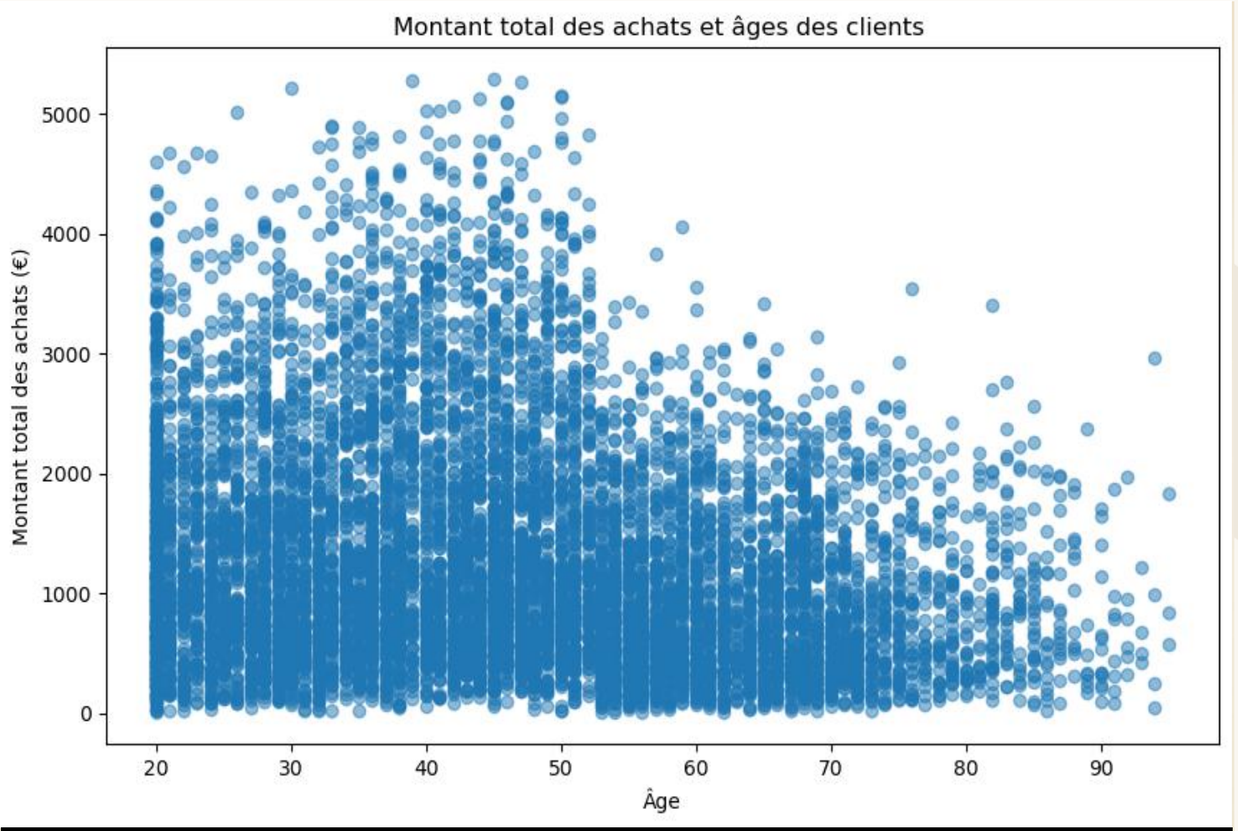


## Analyse graphique du nuage de points

**La tendance générale semble être baissière** Cela pourrait montrer que plus l'âge augmente plus le montant des achats diminue.

**La variaance des montants des achats parait plus grande chez les clients plus jeunes**

1

## Variables

- Âge : Variable **quantitative**
- Montant des achats : Variable **quantitative**

**Deux variables Quantitatives**

2

Pour étudier le lien entre des variables **Quantitatives** je commence par visualiser les données à l'aide d'un **graphique en nuage de points**

```
Corrélation de Pearson entre l'âge et le montant total des achats : -0.19

  - Il n'existe pas de corrélation linéaire entre le montant total des achats et l'âge des clients.
```

3

## Conclusion

Il n'existe pas de corrélation linéaire entre l'age des client et le mopntant total des achats, par conséquent :

**Cela indique que l'âge des clients et le montant total des achats ne sont pas liées par une corrélation linaire.**

# (3) Etude de lien entre l'âge des clients et la fréquence d'achat

## Variables

- Âge : Variable **quantitative**
- Fréquence d'achats : Variable **quantitative**

**Deux variables Quantitatives**

1

Pour étudier le lien entre des variables **Quantitatives** je commence par visualiser les données à l'aide d'un **graphique en nuage de points**

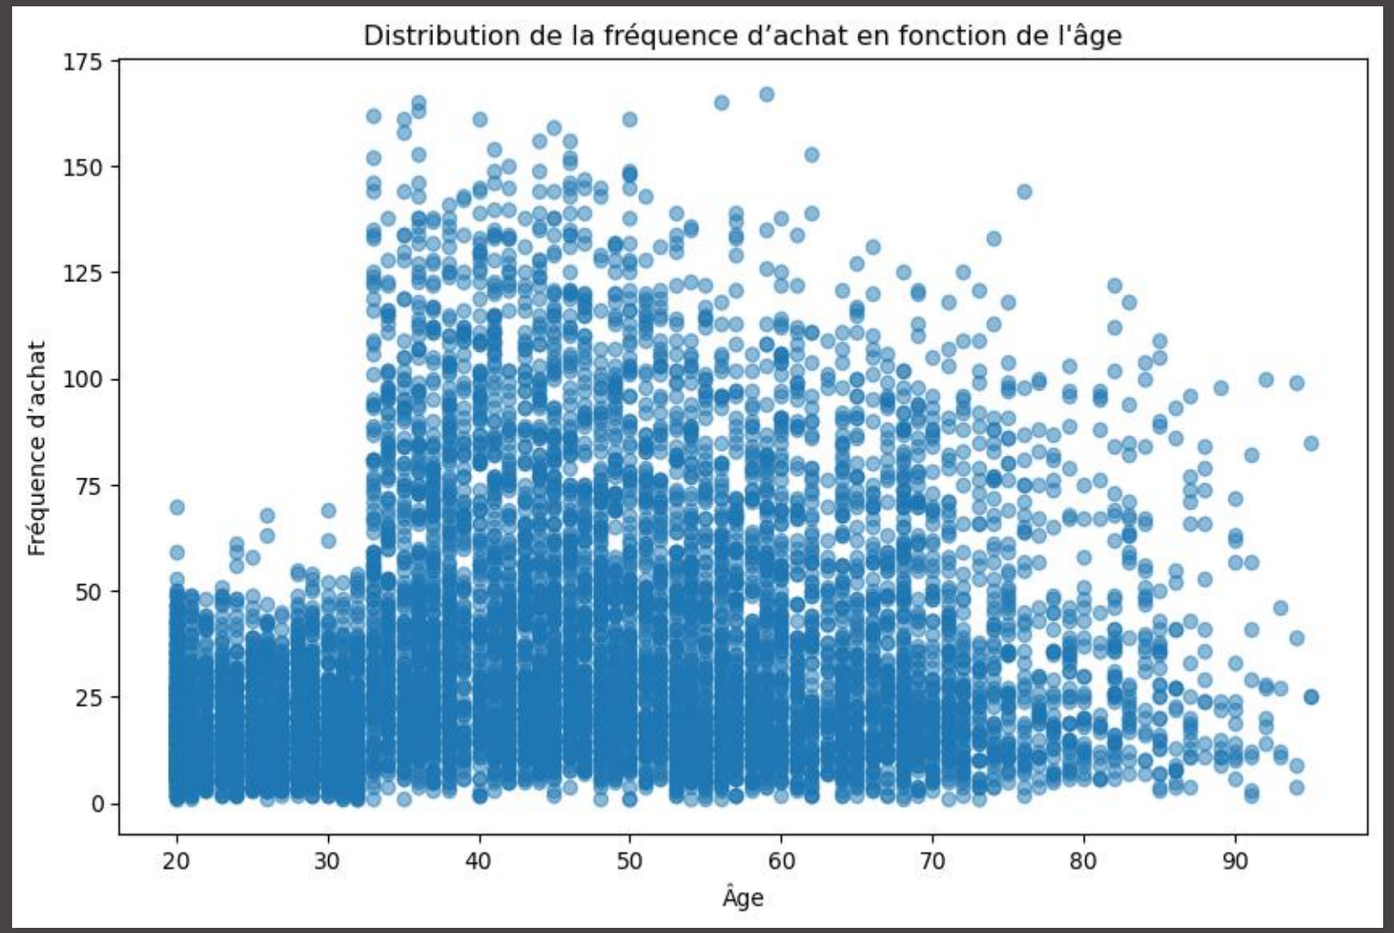


2

```
Corrélation de Pearson entre l'âge et la fréquence d'achat : 0.16

 - Il n'existe pas de corrélation linéaire entre la fréquence d'achat et l'age des clients.
```

3

### Conclusion

Il n'existe pas de corrélation linéaire entre l'age d'un client et la fréquence d'achat, par conséquent :

**Cela indique que l'âge des clients et la fréquence d'achats ne sont pas liées par une corrélation linaire.**

### Analyse visuel du nuage de points

**Tendance générale :** La tendance de la distribution de la fréquence en fonction de l'age parrait baissière.

**Variabilité :** La variabilité des montants des achats est plus importante apres 33ans

# (4) Etude de lien entre l'âge des clients et la taille du panier moyen

## Variables

- Âge : Variable **quantitative**
- Taille du panier moyen : Variable **quantitative**

**Deux variables Quantitatives**

Pour étudier le lien entre des variables **Quantitatives** je commence par visualiser les données à l'aide d'un **graphique en nuage de points**

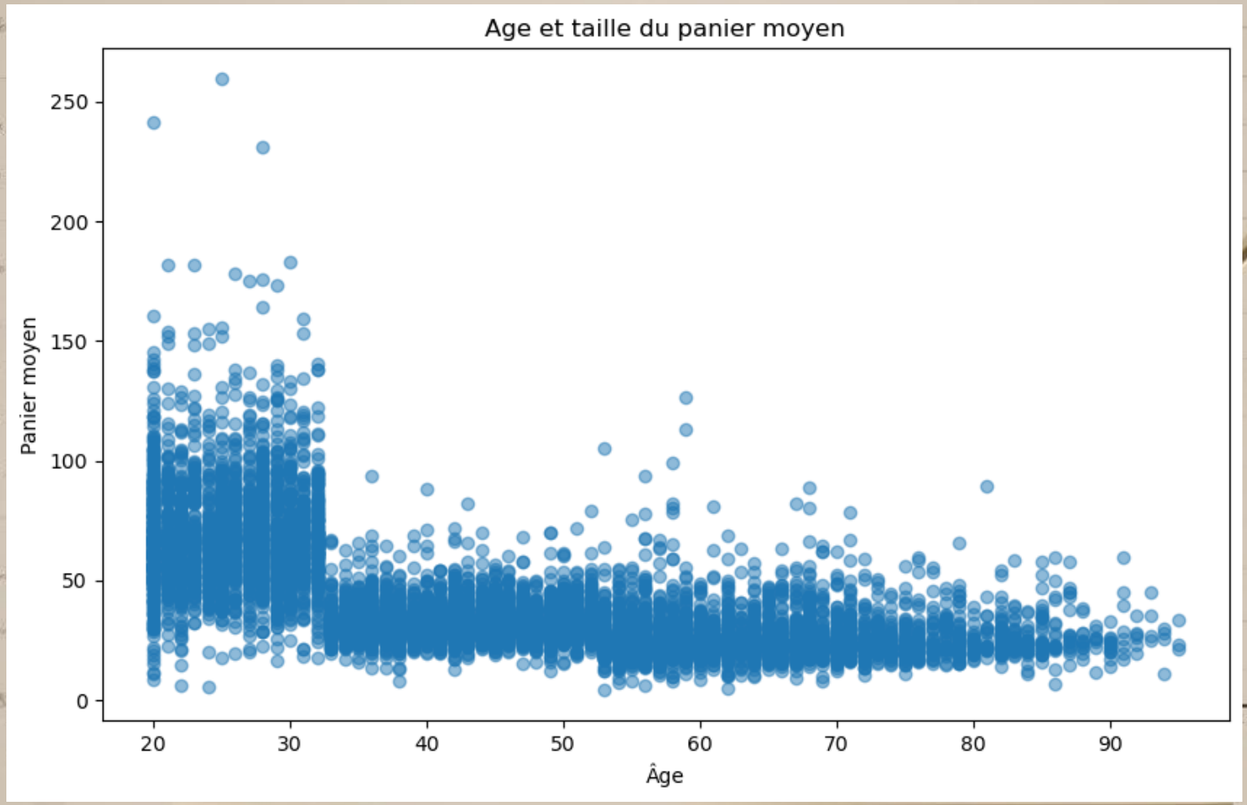


```
Corrélation de Pearson entre l'âge et la taille du panier moyen : -0.62

P-value pour la corrélation de Pearson : 0.0

Il existe une corrélation linéaire entre la taille du panier moyenet l'age des clients.
```

### Analyse visuel du nuage de points

**Tendance générale :** Il y a une tendance générale parrait baissière mais si ont considère deux deux groupe avant et après 33ans elle parrait stable

**Variabilité :** La variabilité du montant de panier moyen diminue fortement apres à 33ans

**Population de clients :** Le montant du manier moyen parrait supperieur avant 33 ans.

## Conclusion

Nous rejetons l'hypothèse nulle H_0 car il existe un lien de corrélation linéaire entre l'age d'un client et la taille du panier moyen, par conséquent :

**Cela indique que l'âge des clients et la taille du panier moyen sont liées par une corrélation linéaire.**

# (4) Etude de lien entre l'âge des clients et la taille du panier moyen

**Discrétiser l'âge en deux groupes :**

## Variables

- Âge (discrétisé) : Après discrétisation, l'âge devient une variable qualitative avec deux niveaux ( <=33 ans et >33 ans).
- Taille du panier moyen : Variable quantitative.

**Variables Quantitative et Qualitative -> Visualisation à l'aide d'un graphique en boîte à moustache :**

## Hypothèses

**Hypothèse Nulle (H0)** : Il n'y a pas de lien entre les deux groupes d'ages et la taille du panier moyen.

**Hypothèse Alternative (H1)** : Il existe un Lien entre les deux groupes d'ages et la taille du panier moyen.

| | sum_sq | df | mean_sq | F | PR(>F) | eta_sq | omega_sq |
|---|---|---|---|---|---|---|---|
| groupes_ages | 2.423443e+06 | 1.0 | 2.423443e+06 | 10257.16631 | 0.0 | 0.544113 | 0.544031 |
| Residual | 2.030490e+06 | 8594.0 | 2.362683e+02 | NaN | NaN | NaN | NaN |

## Conclusion

Le résultat montre que le rapport de corrélation eta-squared (omega carré) 0.54 :

-Cela qui indique que 54% de la taille du panier moyen est expliqué par les différences entre les deux catégories d'ages

Ce niveau de corrélation, confirmé par oméga carré montre qu'il existe **un lien entre la taille du panier moyen et les deux groupes d'âges**

La p-value PR(>F) des groupes d'ages (0) indique que nous pouvons rejetez l'hypothèse nulle (H0), confirmant que'il **existe un lien entre l'age des clients et la taille du panier moyen.**

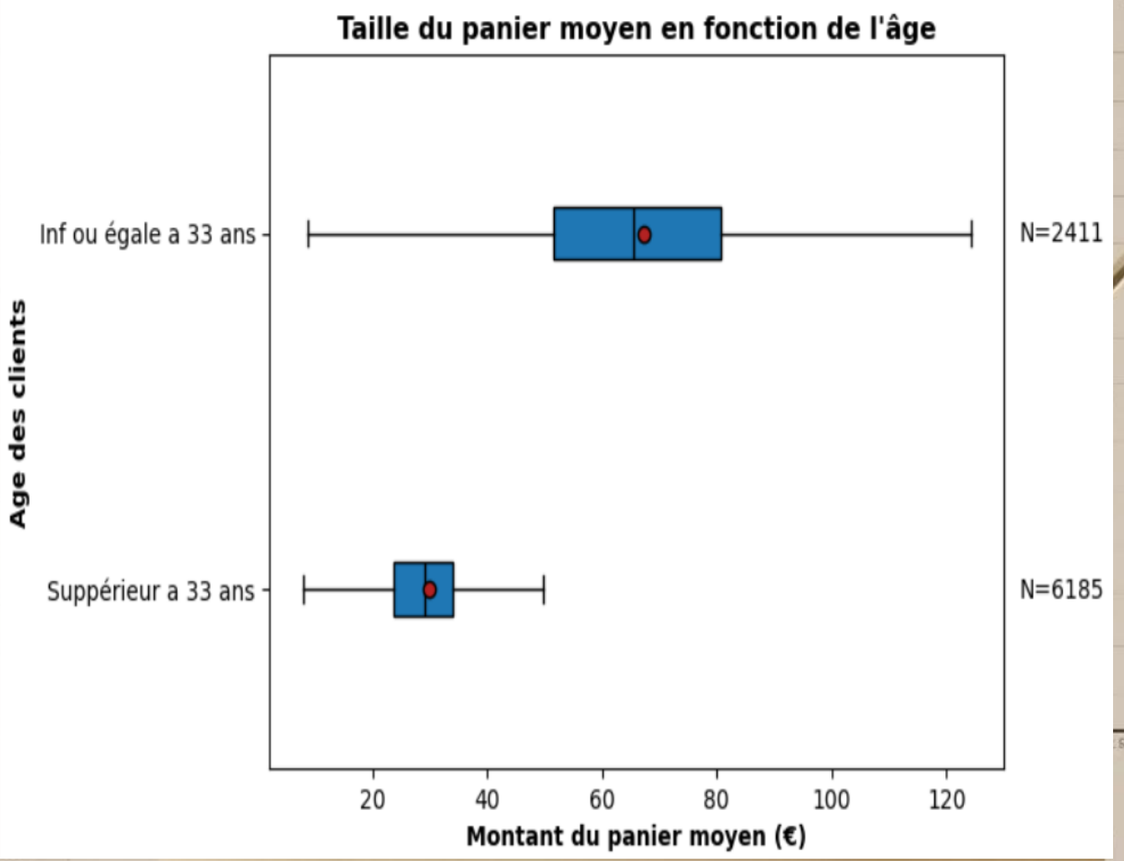


## Analyse visuel des boites à moustaches

Les clients de plus de 33 ans ont une taille de panier moyen globalement plus faible que ceux de 33 ans ou moins.
Le groupe d'âge inf ou égale a 33 ans présente une variabilité plus importante au niveau de la taille du panier moyen.
Le nombre d'observations N est plus élevé pour le groupe > 33 ans (n=6185) par rapport au groupe <= 33 ans (n=2411).

Cela pourrait indiquer un lien entre les deux groupes d'age et la taille du panier moyen.

**Analyse de la normalité des résidus (test de Shapiro)**

Le test est non significatif, W = 0.8787907240619794, p = 4.6606272107621094e-63, ce qui indique que **les résidus sont distribués normalement.**

LeveneResult(statistic=0.0, pvalue=1.0)

**Le test d'homogénéité des variances de Levene n'est pas significatif.**

# (5) Etude de lien entre l'âge des clients et la catégorie des livres achetés

## Variables

- Âge : Variable **quantitative**
- Catégories de livres achetées : Variable **qualitative**.

**Variables Quantitative et Qualitative**

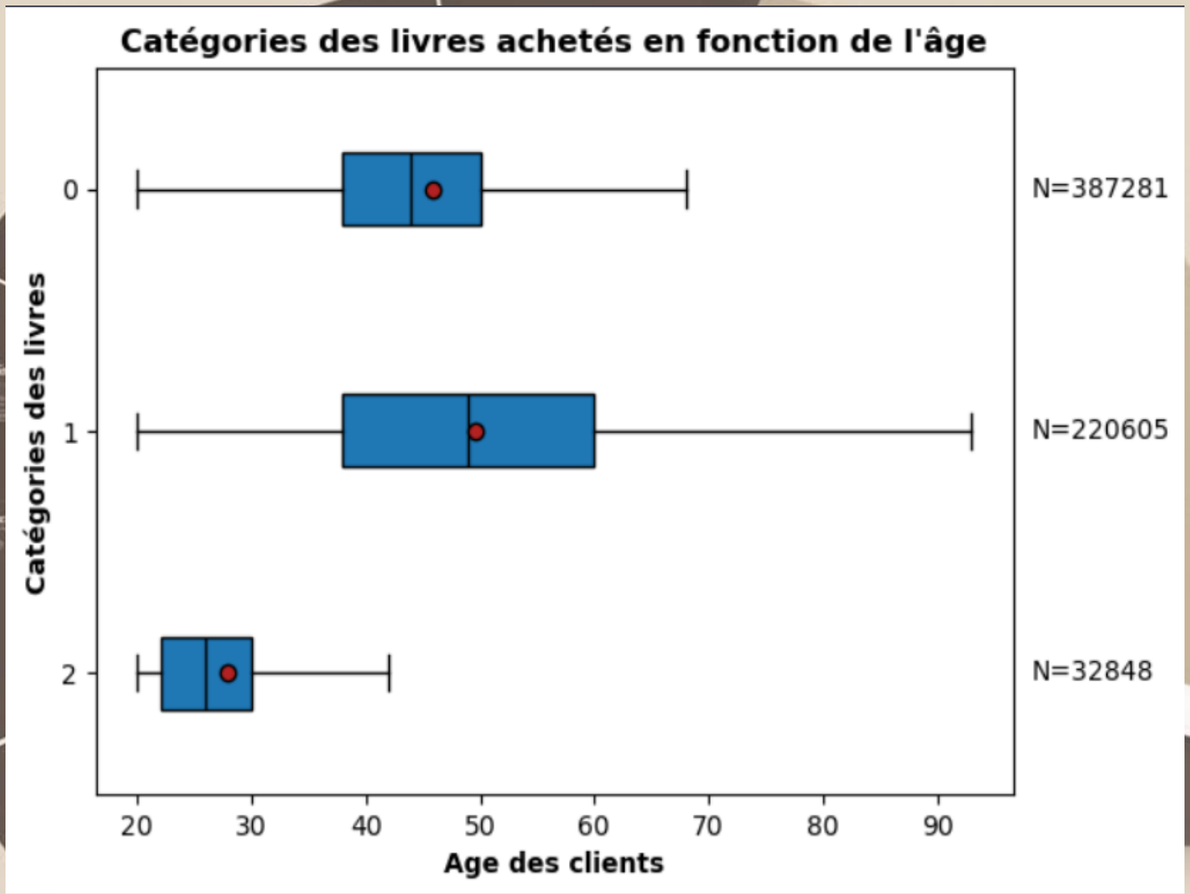


## Analyse visuel des boites à moustaches

La distribution de l'âge des acheteurs varie selon la catégorie, cela pourrait laisser suggérer que différentes catégories de livres sont préférées par des groupes d'âge distincts.

## Hypothèses

**Hypothèse Nulle (H0)** : Il n'y a pas de lien entre l'âge des clients et la catégorie des livres achetés.

**Hypothèse Alternative (H1)** : Il existe un lien entre l'âge des clients et la catégorie des livres achetés.

```
Le rapport de corrélation vaut 0.11
```

## Conclusion

Le résultat montre que le rapport de corrélation (eta-squared) 0.11 :

-Cela qui indique que 11% de la variabilité de l'âge est expliquée par les différences entre les catégories de livres.

Ce niveau de corrélation suggère **qu'il n'y a pas d'association entre l'âge des clients et les catégories de livres qu'ils achètent.**

# Conclusion

- 1 le lien entre le genre d’un client et les catégories des livres achetés : Oui (d’intensité Faible)
- 2 le lien entre l'âge des clients et le montant total des achats : Non
- 3 le lien entre l'âge des clients et la fréquence d’achat : Non
- 4 le lien entre l'âge des clients et la taille du panier moyen : Oui
- 5 le lien entre l'âge des clients et la catégorie des livres achetés: Non